

강의 목표



허깅페이스
플랫폼 소개



다양한 AI
모델 활용



관련
기술 소개



트랜스포머
아키텍처의
미래

허깅페이스 기초

2025년 01월

- 허깅페이스(Hugging Face)
- 모델 사용하기
- Transformer 개선과 미래
- 요약

허깅페이스(Hugging Face)



허깅페이스(Hugging Face) : AI Startup



2023년 8월 24일 - 경제

AI 스타트업 허깅페이스(Hugging Face)는 현재 45억 달러의 가치를 인정받고 있습니다.



기아 코칼리제바, 의 저자 [악시오스 프로 라타](#)

AI 개발을 위한 오픈 소스 도구 제공업체인 허깅페이스(Hugging Face)는 세일즈포스 벤처스(Salesforce Ventures)가 주도하는 45억 달러의 포트 머니 밸류에이션으로 시리즈 D 펀딩에서 2억 3,500만 달러를 조달했습니다.

중요한 이유: 뉴욕에 본사를 둔 이 회사는 성장하는 [AI 개발자 커뮤니티](#)의 중심에 있습니다.

- Hugging Face는 스스로를 "기계 학습을 위한 GitHub"라고 부릅니다.

그들이 말하는 것 : 허깅페이스의 공동 창립자이자 CEO인 클레망 들랑그(Clément Delangue)는 악시오스(Axios)와의 잠재적 경쟁에 대한 질문에 "[깃허브는] 코드에 매우 집중하고 있고, 우리는 AI에 매우 집중하고 있으며, 실제로 그들과 많은 협업을 하고 있다"고 말했다.

- 마이크로소프트 소유의 깃허브(GitHub)에 대한 델랑계의 걱정이 없어 보이는 것은 이 기술 대기업이 AI에 적극적으로 뛰어들 것을 감안할 때 주목할 만하다. 이미 [일부 제품에 이 기술을 배포](#)하고 있습니다([GitHub의 2년 된 AI 비서는 꽤 인기가 있습니다](#)).

큰 그림: Hugging Face의 마지막 펀딩 라운드는 2022년이었습니다. 올해 자금을 조달한 것은 인바운드 관심과 여름까지 2023년 사업 목표를 달성했기 때문이라고 Delangue는 말합니다.

- 포브스(Forbes)와 더 인포메이션(The Information)은 이 회사의 시리즈 D를 처음 보도했다.

확대: 세일즈포스(Salesforce)와 사운드 벤처스(Sound Ventures)와 함께 허깅페이스의 새로운 후원자로는 구글(Google), 아마존(Amazon), 엔비디아(Nvidia), 인텔(Intel), AMD, 퀄컴(Qualcomm), IBM(IBM) 등 주요 기술 기업들이 다수 포함되어 있다.

- "과거에는 전통적인 VC의 길을 더 많이 갔지만, 우리가 정말 흥분한 것은 생태계 라운드를 할 수 있는 능력입니다"라고 Delangue는 설명합니다. "그것은 중립적인 플랫폼으로서 우리의 위치를 공고히합니다 또는 스위스 ... AI를 위해."
- 들랑그는 새로운 자금 조달이 [일부 AI 회사들이](#) 체결한 거래와 달리 기술 자원이나 기업 후원자에 대한 다른 조건에 대한 특별한 접근을 제공하지 않는다고 지적했다.

숫자로 : 이 회사는 현재 500,000개의 모델, 250,000개의 데이터 세트 및 250,000개의 앱을 호스팅하고 있으며 2024년에 그 수를 세 배로 늘리는 것을 목표로 하고 있다고 말합니다.

- 최근 리포지토리 100만 개를 넘어섰으며 내년에는 "수천만 개"에 도달하는 것을 목표로 하고 있습니다.
- Forbes는 2021년에 1,000만 달러의 매출을 올렸고 현재 연간 매출은 3,000만 달러에서 5,000만 달러 사이라고 [보고](#)했습니다. Delangue는 구체적인 수치에 대한 언급을 거부했지만 올해 매출이 5배 증가했으며 현재 10,000명의 유료 고객(엔터프라이즈 기능 판매)을 보유하고 있다고 말했습니다.
- 매출 성장은 더 많은 유료 고객([3월 말 기준 약 3,000명](#))을 확보하고 지출을 늘린 결과입니다.

결론: AI 기업에 대한 괴물 밸류에이션의 메가 라운드가 거의 끝나지 않았습니다.

허깅페이스(Hugging Face) : 미래를 건설하는 AI 커뮤니티



Hugging Face

<https://huggingface.co> ▼



Hugging Face – The AI community building the future.

웹 Give your team the most advanced platform to build AI with enterprise-grade security, access controls and dedicated support. Getting started. Starting at \$20/user/month. Single Sign-On ...

Models

Models - Hugging Face – The AI community building the future.

Datasets

Datasets - Hugging Face – The AI community building the future.

Spaces

Hugging Face. Models; Datasets; Spaces; Posts; Docs; Solutions Pricing Log In ...

Docs

Fast training and inference of HF Transformers with easy to use hardware ...

Pricing

Leveling up AI collaboration and compute. Users and organizations already use the ...

Log In

Log In - Hugging Face – The AI community building the future.

Sign Up

Hugging Face – The AI community building the future.

Stabilityai Stable-Diffusion-X...

Stabilityai Stable-Diffusion-XI-Base-1.0 - Hugging Face – The AI community ...

허깅페이스(Hugging Face) : 미래를 건설하는 AI 커뮤니티



포옹하는 얼굴

<https://huggingface.co> ▼



Hugging Face - 미래를 건설하는 AI 커뮤니티.

웹 엔터프라이즈급 보안, 액세스 제어 및 전담 지원을 통해 AI를 구축할 수 있는 가장 진보된 플랫폼을 팀에 제공하십시오. 시작. 사용자당 월 \$20부터 시작합니다. 싱글 사인온...

모델

모델 - Hugging Face - 미래를 건설하는 AI 커뮤니티.

데이터

데이터 세트 - Hugging Face - 미래를 구축하는 AI 커뮤니티.

공간

포옹하는 얼굴. 모델; 데이터; 공간; 게시물; 문서; 솔루션 가격 로그인 ...

문서

사용하기 쉬운 하드웨어로 HF 변압기의 빠른 교육 및 추론 ...

가격

AI 협업 및 컴퓨팅 수준을 높입니다. 사용자와 조직은 이미 ...

로그인

로그인 - 허깅페이스 - 미래를 건설하는 AI 커뮤니티.

등록하세요

Hugging Face - 미래를 건설하는 AI 커뮤니티.

Stabilityai 안정 확산 -X ...

Stabilityai Stable-Diffusion-XI-Base-1.0 - 허깅 페이스 - AI 커뮤니티 ...

허깅페이스(Hugging Face)



- 트랜스포머 모델 등 다양한 AI 모델, 데이터 셋 등을 공유할 수 있는 플랫폼
- 인공지능 모델을 위한 깃허브
 - ✓ 모델(Model) : 훈련된 모델을 공유 - [Models - Hugging Face](#)
 - ✓ 데이터셋(Datasets) : 훈련 데이터 공유 - [Hugging Face – The AI community building the future.](#)
 - ✓ 스페이스(Spaces) : 머신러닝 앱 테스트 공간 - [Spaces - Hugging Face](#)



Stable Diffusion 2.1 Demo

Stable Diffusion 2.1 is the latest text-to-image model from StabilityAI. [Access Stable Diffusion 1 Space here](#)
For faster generation and API access you can try [DreamStudio Beta](#).

A cute baby cat with glasses

Enter a negative prompt

Generate image

안경 낀 귀여운 새끼 고양이

Enter a negative prompt

Generate image



LLM 선택 : 허깅페이스 내의 LLM



LLM의 기원: 15,821 Large의 진화 트리와 그래프 언어 모델


2023년 7월 19일에 게시 · ★ 2023년 7월 20일 [Daily Papers](#)에 특집 기사

저자: 사라 가오, ● 앤드류 킨 가오

추상적인

2022년 말부터 대규모 언어 모델(LLM)은 ChatGPT 및 Bard와 같은 LLM은 수백만 명의 사용자를 보유하고 있습니다. 수백 개의 새로운 LLM 는 매주 발표되며, 그 중 다수는 Hugging Face에 입금 됩니다. 기계 학습 모델 및 데이터 세트의 리포지토리입니다. 현재까지 약 16,000개의 텍스트 세대 모델이 사이트에 업로드되었습니다. 의 엄청난 유입을 감안할 때 LLM의 경우, 어떤 LLM 백본, 설정, 훈련을 아는 것이 흥미로울 것입니다 방법, 그리고 가족은 인기 있거나 유행입니다. 그러나 없습니다 LLM의 포괄적인 색인을 사용할 수 있습니다. 우리는 상대적으로 계층적 클러스터링을 수행하기 위한 Hugging Face LLM의 체계적인 명명법 n-gram 및 term frequency-inverse를 사용하여 LLM 간의 커뮤니티를 식별합니다. 문서 빈도. 우리의 방법은 LLM 제품군을 성공적으로 식별하고 LLM을 의미 있는 하위 그룹으로 정확하게 클러스터링합니다. 퍼블릭 웹을 제시합니다 15,821개의 LLM으로 구성된 아틀라스인 Constellation을 탐색하고 탐색하기 위한 애플리케이션입니다. Constellation은 다음과 같은 다양한 시각화를 빠르게 생성합니다. 덴드로그램, 그래프, 워드 클라우드 및 산점도. Constellation을 사용할 수 있습니다. 다음 링크에서:

<https://constellation.sites.stanford.edu/>.



Meta Llama 3 릴리즈: GPT4급 Open-Source 모델의 탄생

daewoo kim · Follow
11 min read · Apr 21, 2024

Llama 3의 성능


Llama3는 이전 세대인 Llama2에 비해 모든 벤치마크에서 대폭적인 도약을 이루었다.

Base pretrained models (Llama2 vs Llama3)

- **Llama3 70B:** 모든 모델 벤치마크에서 Llama3 70B의 성능을 증가한다.
- **Llama3 8B:** 모든 모델 벤치마크에서 Llama2 7B, 13B보다 더 우수한 성능을 보인다. BoolQ 벤치마크의 경우, Llama3 8B이 Llama2 70B보다 더 우수한 성능을 나타낸다.

Category	Benchmark	Llama2 7B	Llama2 13B	Llama2 70B	Llama 3 8B	Llama 3 70B
General	MMLU (5-shot)	45.7	53.8	69.7	66.6	79.5
	AGIEval English (3-5 shot)	28.8	38.7	54.8	45.9	63
	CommonSenseQA (7-shot)	57.6	67.6	78.7	72.6	83.8
	Winogrande (5-shot)	73.3	75.4	81.8	76.1	83.1
	BIG-Bench Hard (3-shot, CoT)	38.1	47	65.7	61.1	81.3
	ARC-Challenge (25-shot)	53.7	67.6	85.3	78.6	93
Knowledge reasoning	TriviaQA-Wiki (5-shot)	72.1	79.6	87.5	78.5	89.7
Reading comprehension	SQuAD (1-shot)	72.2	72.1	82.6	76.4	85.6
	QuAC (1-shot, F1)	39.6	44.9	49.4	44.4	51.1
	BoolQ (0-shot)	65.5	66.9	73.1	75.7	79
	DROP (3-shot, F1)	37.9	49.8	70.2	58.4	79.7

Base Pretrained Models(Llama2 vs Llama3)



Meta Llama 3 Instruct Human Evaluation

Pre-training 시 scaling law 개발

Meta는 downstream 벤치마크 평가를 위해 일련의 scaling law을 개발하였다. 이 scaling law를 통해 모델을 실제로 학습하기 전에 주요 task(e.g. HumanEval 벤치마크)에 대해 가장 큰 모델의 성능을 예측할 수 있었다.

새로운 관찰 결과

- Meta는 Llama3 개발 시 scaling law에 대한 새로운 사실을 관찰하였다.
- Chinchilla-optimal에 따라 8B 모델의 최적 학습 토큰량은 약 200B 개지만, 200B보다 더 많은 토큰을 학습하였을 때 모델 성능은 계속 증가한다.
 - Llama3 8B, 70B를 최대 15T 토큰으로 학습하였을 때 모델 성능 로그 선형적으로 계속 개선되었다.

LLM 선택 : LLM 모델 계통도





Fig. 1. The evolutionary tree of modern LLMs traces the development of language models in recent years and highlights some of the most well-known models. Models on the same branch have closer relationships. Transformer-based models are shown in non-grey colors: decoder-only models in the blue branch, encoder-only models in the pink branch, and encoder-decoder models in the green branch. The vertical position of the models on the timeline represents their release dates. Open-source models are represented by solid squares, while closed-source models are represented by hollow ones. The stacked bar plot in the bottom right corner shows the number of models from various companies and institutions.

Encoder, Decoder, Encoder-Decoder 모델



모델 찾기 : Tasks



작업

Hugging Face Search models, datasets

Models Datasets Spaces Docs Enterprise Pricing

Tasks Libraries Datasets Languages Licenses Other

Filter Tasks by name

Multimodal

- Audio-Text-to-Text
- Image-Text-to-Text
- Visual Question Answering
- Document Question Answering
- Video-Text-to-Text
- Any-to-Any

Computer Vision

Models 1,165,879 Filter by name Full-text search Sort: Trending

- Qwen/QwQ-32B-Preview**
Text Generation • Updated 2 days ago • 14.8k • 783
- AIDC-AI/Marco-o1**
Text Generation • Updated 8 days ago • 7.51k • 565
- Lightricks/LTX-Video**
Image-to-Video • Updated 8 days ago • 26.8k • 499
- Djirango/Qwen2vl-Flux**

1. 자연어 처리 (NLP)

텍스트 분류 (Text Classification): 텍스트를 특정 카테고리로 분류.

개체명 인식 (Named Entity Recognition, NER):

텍스트에서 인물, 장소 등의 특정 단어를 추출.

질의응답 (Question Answering): 텍스트에서 질문에 대한 답을 추출.

텍스트 생성 (Text Generation):

주어진 텍스트를 기반으로 새로운 텍스트 생성.

요약 (Summarization): 긴 텍스트를 짧게 요약.

2. 컴퓨터 비전 (CV)

이미지 분류 (Image Classification): 이미지를 특정 카테고리로 분류.

객체 탐지 (Object Detection): 이미지에서 객체의 위치와 종류를 탐지.

이미지 분할 (Image Segmentation): 이미지의 각 픽셀을 객체별로 분할.

이미지 설명 (Image-to-Text): 이미지를 설명하는 텍스트 생성.

시각적 질의응답 (Visual Question Answering): 이미지와 관련된 질문에 답변.

3. 음성 처리 (Speech)

음성 인식 (Speech Recognition): 음성을 텍스트로 변환.

텍스트 음성 변환 (Text-to-Speech, TTS): 텍스트를 음성으로 변환.

음성 번역 (Speech-to-Speech Translation): 음성을 다른 언어로 번역.

오디오 분류 (Audio Classification): 오디오를 특정 카테고리로 분류.

감정 분석 (Emotion Detection): 음성을 기반으로 감정 식별.

4. 멀티모달 (Multimodal)

이미지 캡셔닝 (Image Captioning): 이미지에 대한 설명 텍스트 생성.

시각적 질의응답 (Visual Question Answering):

이미지와 관련된 질문에 텍스트로 답변.

텍스트-이미지 검색 (Text-to-Image Retrieval):

텍스트를 기반으로 관련 이미지를 검색.

이미지-텍스트 검색 (Image-to-Text Retrieval):

이미지를 기반으로 관련 텍스트를 검색.

텍스트-비디오 설명 (Text-to-Video Description): 비디오를 텍스트로 설명.

5. 추천 및 검색 (Recommendation and Retrieval)

정보 검색 (Information Retrieval): 대규모 데이터에서 관련 문서를 검색.

추천 시스템 (Recommendation Systems):

사용자 데이터를 기반으로 항목 추천.

문서 유사도 계산 (Document Similarity): 두 텍스트 간의 유사도 측정.

의도 분석 (Intent Detection): 텍스트의 의도를 파악.

질의 확장 (Query Expansion): 검색어를 더 관련성 높은 형태로 확장.

모델 찾기 : 대표적인 tasks



Task	대표 모델	설명
자연어 처리 (NLP)	BERT, GPT, T5	텍스트 생성, 문장 분류, 질의응답, 기계번역 등 다양한 NLP 작업에 활용.
기계 번역	Transformer (원 논문)	영어-프랑스어, 영어-독일어 등 기계 번역 작업.
텍스트 요약	T5, PEGASUS	문서 요약 및 추출 기반 요약.
텍스트 생성	GPT 시리즈, OPT, LLaMA	고품질 텍스트 생성, 대화 모델 등.
감성 분석	BERT, RoBERTa	문장의 감정이나 톤을 분류하는 작업.
질의 응답 (QA)	ALBERT, BERT, T5	사용자의 질문에 적절한 답변 생성.
자연어 추론 (NLI)	RoBERTa, DeBERTa	두 문장의 논리적 관계를 분석 (모순, 중립, 함의).

음성 인식	Wav2Vec, Whisper	음성 데이터를 텍스트로 변환.
이미지 생성	DALL-E, Stable Diffusion	텍스트 기반 이미지 생성.
이미지 분류	ViT (Vision Transformer), Swin	Transformer를 활용한 이미지 분류.
물체 검출	DETR (Detection Transformer)	Transformer 기반의 객체 검출.
비디오 이해	TimeSformer, Video Swin Transformer	비디오 데이터의 의미를 분석.
멀티모달 작업	CLIP, Flamingo	이미지와 텍스트를 동시에 처리하여 문맥 이해.
추천 시스템	SASRec, BERT4Rec	사용자 행동 시퀀스를 기반으로 추천 시스템을 구현.
강화 학습	Decision Transformer	시퀀스 모델링으로 강화 학습 작업 수행.

모델 찾기 : Libraries



사용 라이브러리

Hugging Face Search models, dataset

Models Datasets Spaces Docs Enterprise Pricing

Tasks **Libraries 2** Datasets Languages Licenses

Other

Filter Libraries by name Reset Libraries

PyTorch TensorFlow JAX

Transformers Safetensors PEFT

TensorBoard GGUF Diffusers

stable-baselines3 ONNX

sentence-transformers ml-agents TF-Keras

Adapters setfit timm sample-factory MLX MLX

Flair Keras Transformers.js

OpenVINO spaCy fastai ESPnet

Joblib NeMo Core ML BERTopic TF Lite

Models 172,494 Filter by name Full-text search Sort: Trending

- meta-llama/Llama-3.2-1B
Text Generation • Updated Oct 25 • 1.58M • 1.08k
- meta-llama/Llama-3.1-8B-Instruct
Text Generation • Updated Sep 26 • 6.62M • 3.15k
- briiaai/RMBG-2.0
Image Segmentation • Updated 11 days ago • 53.7k • 456
- jinaai/jina-clip-v2
Feature Extraction • Updated 1 day ago • 5.61k • 89
- meta-llama/Llama-3.2-3B-Instruct

모델 찾기 : Datasets



사용 데이터셋

Hugging Face Search models, dataset Models Datasets Spaces Docs Enterprise Pricing

Tasks Libraries **Datasets** Languages Licenses Other

Filter Datasets by name

- mozilla-foundation/common_voice_7_0
- mozilla-foundation/common_voice_11_0
- HuggingFaceH4/ultrafeedback_binarized
- teknium/OpenHermes-2.5
- cis-lmu/Glot500
- HuggingFaceH4/ultrachat_200k
- fka/awesome-chatgpt-prompts
- allenai/MADLAD-400
- Open-Orca/OpenOrca
- marsyas/gtzan
- allenai/c4
- LDJnr/Capybara

Models 1,165,923 Filter by name Full-text search Sort: Trending

- Qwen/QwQ-32B-Preview**
Text Generation • Updated 2 days ago • 14.8k • 785
- AIDC-AI/Marco-o1**
Text Generation • Updated 8 days ago • 7.51k • 565
- Lightricks/LTX-Video**
Image-to-Video • Updated 8 days ago • 26.8k • 500
- Djrango/Qwen2v1-Flux**
Text-to-Image • Updated 4 days ago • 280

모델 찾기 : Languages



지원 언어

Hugging Face Search models, datasets, spaces, docs, enterprise, pricing

Tasks Libraries Datasets **Languages 2** Licenses Other

Filter Languages by name Reset Languages

English × Chinese French German Spanish Japanese Korean × Italian Portuguese Russian Hindi Arabic Thai Indonesian Polish Turkish Dutch Vietnamese multilingual Finnish Romanian Swedish Czech Persian Ukrainian Greek Danish Catalan Bengali Hebrew Bulgarian Tamil Hungarian Swahili

Models 2,770 Filter by name Full-text search Sort: Trending

- OuteAI/OuteTTS-0.2-500M
Text-to-Speech • Updated 2 days ago • 7.73k • 196
- OuteAI/OuteTTS-0.2-500M-GGUF
Text-to-Speech • Updated 2 days ago • 3.1k • 57
- mistralai/Pixtral-Large-Instruct-2411
Updated 11 days ago • 382 • 345
- jinaai/jina-clip-v2
Feature Extraction • Updated 1 day ago • 5.61k • 89
- openai/whisper-large-v3

모델 찾기 : Licenses



라이선싱 방식

Hugging Face Search models, datasets, spaces, docs, enterprise, pricing

Tasks Libraries Datasets Languages **Licenses** Other

Filter Licenses by name

- apache-2.0 mit other openrail
- creativeml-openrail-m cc-by-nc-4.0 llama2
- llama3 cc-by-4.0 openrail++ gemma
- llama3.1 cc-by-nc-sa-4.0 afl-3.0
- cc-by-sa-4.0 gpl-3.0 llama3.2 cc
- artistic-2.0 bsd-3-clause
- bigscience-openrail-m bigscience-bloom-rail-1.0
- cc-by-nc-nd-4.0 bigcode-openrail-m wtfpl
- agpl-3.0 cc0-1.0 unlicense

Models 1,165,927 Filter by name Full-text search Sort: Trending

- Qwen/QwQ-32B-Preview
Text Generation • Updated 2 days ago • 14.8k • 785
- AIDC-AI/Marco-o1
Text Generation • Updated 8 days ago • 7.51k • 565
- Lightricks/LTX-Video
Image-to-Video • Updated 8 days ago • 26.8k • 500
- Djrrango/Qwen2v1-Flux
Text-to-Image • Updated 4 days ago • 280
- black-forest-labs/FLUX.1-dev

대표적인 오픈소스 라이선스 정책



라이선스	주요 특징	소스코드 공개 의무	상업적 사용 가능 여부	복제(left) 조항
MIT License	자유롭게 사용, 수정, 배포 가능. 저작권 및 라이선스 표시 유지 필수.	없음	가능	없음
Apache License 2.0	특허 사용 허가 포함, 변경 내용 명시 필수, 상표권 보호는 제외.	없음	가능	없음
GPL (General Public License)	수정 및 배포 시 동일한 GPL 유지 필수. 소스코드 공개 의무.	필수	가능	강함
LGPL (Lesser GPL)	GPL 완화 버전. 라이브러리 사용 시 소스 공개 의무 없음. 수정 시 공개 필요.	수정된 라이브러리만 필수	가능	약함
BSD License	사용, 수정, 배포 가능. 저작권 및 라이선스 표시 유지. 일부 버전은 광고 문구 요구.	없음	가능	없음

라이선스	주요 특징	소스코드 공개 의무	상업적 사용 가능 여부	복제(left) 조항
Creative Commons (CC)	콘텐츠 전용. 저작자 표시, 비상업적 사용, 변경 금지 등 조건 설정 가능.	조건에 따라 다름	조건에 따라 다름	없음
MPL (Mozilla Public License)	소스코드 파일 단위로 공개 의무. 독립적인 부분은 비공개 가능.	수정된 파일만 필수	가능	약함
EPL (Eclipse Public License)	수정된 소스코드 공개 의무. 특허 조항 포함.	필수	가능	약함
AGPL (Afero GPL)	네트워크 제공 소프트웨어도 소스코드 공개 필수. 클라우드 환경에 적합.	필수	가능	강함
Unlicense	퍼블릭 도메인 배포. 사용, 수정, 배포에 제한 없음.	없음	가능	없음

대표적인 오픈소스 라이선스 정책



GNU AGPLv3

Permissions of this strongest copyleft license are conditioned on making available complete source code of licensed works and modifications, which include larger works using a licensed work, under the same license. Copyright and license notices must be preserved. Contributors provide an express grant of patent rights. When a modified version is used to provide a service over a network, the complete source code of the modified version must be made available.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- Disclose source
- License and copyright notice
- Network use is distribution
- Same license
- State changes

Limitations

- Liability
- Warranty

[View full GNU Affero General Public License v3.0 »](#)

GNU GPLv3

Permissions of this strong copyleft license are conditioned on making available complete source code of licensed works and modifications, which include larger works using a licensed work, under the same license. Copyright and license notices must be preserved. Contributors provide an express grant of patent rights.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- Disclose source
- License and copyright notice
- Same license
- State changes

Limitations

- Liability
- Warranty

[View full GNU General Public License v3.0 »](#)

GNU LGPLv3

Permissions of this copyleft license are conditioned on making available complete source code of licensed works and modifications under the same license or the GNU GPLv3. Copyright and license notices must be preserved. Contributors provide an express grant of patent rights. However, a larger work using the licensed work through interfaces provided by the licensed work may be distributed under different terms and without source code for the larger work.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- Disclose source
- License and copyright notice
- Same license (library)
- State changes

Limitations

- Liability
- Warranty

[View full GNU Lesser General Public License v3.0 »](#)

Mozilla Public License 2.0

Permissions of this weak copyleft license are conditioned on making available source code of licensed files and modifications of those files under the same license (or in certain cases, one of the GNU licenses). Copyright and license notices must be preserved. Contributors provide an express grant of patent rights. However, a larger work using the licensed work may be distributed under different terms and without source code for files added in the larger work.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- Disclose source
- License and copyright notice
- Same license (file)

Limitations

- Liability
- Trademark use
- Warranty

[View full Mozilla Public License 2.0 »](#)

Apache License 2.0

A permissive license whose main conditions require preservation of copyright and license notices. Contributors provide an express grant of patent rights. Licensed works, modifications, and larger works may be distributed under different terms and without source code.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- License and copyright notice
- State changes

Limitations

- Liability
- Trademark use
- Warranty

[View full Apache License 2.0 »](#)

MIT License

A short and simple permissive license with conditions only requiring preservation of copyright and license notices. Licensed works, modifications, and larger works may be distributed under different terms and without source code.

Permissions

- Commercial use
- Distribution
- Modification
- Private use

Conditions

- License and copyright notice

Limitations

- Liability
- Warranty

[View full MIT License »](#)

Boost Software License 1.0

A simple permissive license only requiring preservation of copyright and license notices for source (and not binary) distribution. Licensed works, modifications, and larger works may be distributed under different terms and without source code.

Permissions

- Commercial use
- Distribution
- Modification
- Private use

Conditions

- License and copyright notice for source

Limitations

- Liability
- Warranty

[View full Boost Software License 1.0 »](#)

The Unlicense

A license with no conditions whatsoever which dedicates works to the public domain. Unlicensed works, modifications, and larger works may be distributed under different terms and without source code.

Permissions

- Commercial use
- Distribution
- Modification
- Private use

Conditions

Limitations

- Liability
- Warranty

[View full The Unlicense »](#)

모델 찾기 : Licenses



기 타

Warm 모델:
즉시 사용 가능

Cold 모델:
필요 시 로딩

Frozen 모델:
API로 실행할 수 없음

The screenshot shows the Hugging Face website interface. At the top, there's a navigation bar with 'Hugging Face' logo, a search bar, and links for Models, Datasets, Spaces, Docs, Enterprise, and Pricing. Below the navigation bar, there's a secondary navigation bar with 'Tasks', 'Libraries', 'Datasets', 'Languages', and 'Licenses'. The 'Licenses' tab is selected, and a red box highlights the 'Other' button. Below the 'Other' button, there's a section for 'Inference status' with three buttons: 'Warm' (orange), 'Cold' (blue), and 'Frozen' (grey). A red box also highlights this section. Below the 'Inference status' section, there's a 'Misc' section with various filters like 'Inference Endpoints', 'AutoTrain Compatible', 'text-generation-inference', 'Eval Results', '4-bit precision', 'Merge', 'text-embeddings-inference', 'custom_code', '8-bit precision', 'Carbon Emissions', and 'Mixture of Experts'. On the right side of the page, there's a list of models. The first model is 'Qwen/QwQ-32B-Preview' with details like 'Text Generation', 'Updated 2 days ago', '14.8k', and '785'. Other models listed include 'AIDC-AI/Marco-o1', 'Lightricks/LTX-Video', 'Django/Qwen2v1-Flux', and 'black-forest-labs/FLUX.1-dev'.

실습 : 5분

한국어를 지원하는
상업적 이용 가능한
STT (Sound To Text) 모델 찾기

데이터셋(datasets)




- dataset download

```
1 from datasets import load_dataset
2
3 str_dataset = "yelp_review_full"
4 # dataset = load_dataset(str_dataset)
5
6 # or load the separate splits if the dataset has train/validation/test splits
7 train_dataset = load_dataset(str_dataset, split="train")
8 # valid_dataset = load_dataset(str_dataset, split="validation")
9 test_dataset = load_dataset(str_dataset, split="test")
```

예제 : https://colab.research.google.com/drive/17rAF6KwD_0R1oE5V8X6MOhXjA89Io4Y6#scrollTo=FduMZ9wQqC6A

- 데이터셋의 상세 내용은 데이터셋 카드(Dataset Card)에서 확인



Data Fields

- 'text': The review texts are escaped using double quotes ("), and any internal double quote is escaped by 2 double quotes ("). New lines are escaped by a backslash followed with an "n" character, that is "\n".
- 'label': Corresponds to the score associated with the review (between 1 and 5).

Data Splits

The Yelp reviews full star dataset is constructed by randomly taking 130,000 training samples and 10,000 testing samples for each review star from 1 to 5. In total there are 650,000 training samples and 50,000 testing samples.

스페이스(Spaces)



 **Spaces**
Discover amazing AI apps made by the community!

Create new Space or [Learn more about Spaces](#)

Browse [ZeroGPU Spaces](#) Full-text search [Sort: Most likes](#)

Running on CPU UPGRADE 11.9k

Open LLM Leaderboard 2

Track, rank and evaluate open LLMs and chatbots

open-llm-leaderboard 17 days ago

Running on CPU UPGRADE 10.8k

Stable Diffusion 2-1

stabilityai Oct 8

Running on CPU UPGRADE 8.71k

AI Comic Factory

Create your own AI comic with a single prompt

jbilcke-hf Oct 16

 **Open LLM Leaderboard**
The previous Leaderboard version is live [here](#) Feeling lost? Check out our [documentation](#)
You'll notably find explanations on the evaluations we are using, reproducibility guidelines, best practices on how to submit a model, and our [FAQ](#).

LLM Benchmark Submit Model Vote

Separate multiple queries with ";"

Select Columns to Display:

☒ Average ☒ IFEval ☐ IFEval Raw ☒ BBH ☐ BBH Raw ☒ MATH Lvl 5 ☐ MATH Lvl 5 Raw

☒ GPQA ☐ GPQA Raw ☒ MUSR ☐ MUSR Raw ☒ MMLU-PRO ☐ MMLU-PRO Raw ☐ Type

☐ Architecture ☐ Precision ☐ Not_Merged ☐ Hub License ☐ #Params (B) ☐ Hub ☒ Heart

☐ Model sha ☐ Submission Date ☐ Upload To Hub Date ☐ Chat Template ☐ Generation

☐ Base Model ☒ CO2 cost (kg)

Model types

☒ chat models (RLHF, DPO, IFT, ...)

☒ fine-tuned on domain-specific datasets ☒ base merges and moerges

☒ pretrained ☒ multimodal ☒ continuously pretrained

Precision

☒ bfloat16 ☒ float16 ☒ 4bit



Select the number of parameters (B)


Hide models

☒ Deleted/incomplete ☒ Merge/MoErg ☐ MoE ☒ Flagged ☐ Show only maintainer's highlight

T	Model	Average	IFEval	BBH	MATH Lvl 5	GPQA	MUSR	MMLU-PRO	CO2 cost (kg)
	dfuxman/CalmeRys-78B-Orpo-v0.1	51.24	81.63	61.92	40.71	20.02	36.37	66.8	13
	MaziyarPanahi/calme-3.1-instruct-78b	51.2	81.36	62.41	38.75	19.46	36.5	68.72	32.22
	MaziyarPanahi/calme-2.4-ys-78b	50.71	80.11	62.16	40.41	20.36	34.57	66.69	12.98
	xombodawg/Rombos-LLM-V2.5-Open-72b	45.91	71.55	61.27	50.68	19.8	17.32	54.83	16.03

 **Stable Diffusion 2.1 Demo**
Stable Diffusion 2.1 is the latest text-to-image model from StabilityAI. [Access Stable Diffusion 1 Space here](#)
For faster generation and API access you can try [DreamStudio Beta](#).





The screenshot shows the Hugging Face website's 'Leaderboards and Evaluations' page. The top navigation bar includes the Hugging Face logo, a search bar for models, datasets, and users, and links to Models, Datasets, Spaces, and Posts. The left sidebar features a 'Leaderboards' dropdown menu with a search bar and a 'MAIN' tab. Below this, there's a 'Leaderboards' section with a list of links: 'Introduction to leaderboards', 'Finding leaderboards', 'Building your leaderboard', 'Extras', 'OPEN LLM LEADERBOARD', 'About', 'How to submit your model', 'FAQ', 'Scores Normalization', 'CO2 calculation', and 'Archived versions'. The main content area is titled 'Leaderboards and Evaluations' and contains a paragraph explaining the purpose of these projects. It lists two bullet points: 'the Open LLM Leaderboard evaluates and ranks open source LLMs and chatbots, and provides reproducible scores separating marketing fluff from actual progress in the field.' and 'Leaderboards on the Hub aims to gather machine learning leaderboards on the Hugging Face Hub and support evaluation creators.' Below this, there's a paragraph encouraging users to explore machine learning rankings. At the bottom, there are two call-to-action buttons: 'Leaderboards on the Hub' (green) and 'Open LLM Leaderboard' (orange). The footer includes a link to 'Update on GitHub'.

Hugging Face Search models, datasets, users... Models Datasets Spaces Posts

Leaderboards Search documentation Ctrl+K

MAIN EN 15

Leaderboards

LEADERBOARDS ON THE HUB

- Introduction to leaderboards
- Finding leaderboards
- Building your leaderboard
- Extras

OPEN LLM LEADERBOARD

- About
- How to submit your model
- FAQ
- Scores Normalization
- CO2 calculation
- Archived versions

Leaderboards and Evaluations

As the number of open and closed source machine learning models explodes, it can be very hard to find the correct model for your project. This is why we started our evaluations projects:

- the **Open LLM Leaderboard** evaluates and ranks open source LLMs and chatbots, and provides reproducible scores separating marketing fluff from actual progress in the field.
- Leaderboards on the Hub** aims to gather machine learning leaderboards on the Hugging Face Hub and support evaluation creators.

Explore machine learning rankings to find the best model for your use case, or build your own leaderboard, to test specific capabilities which interest you and the community!

Leaderboards on the Hub

A small introduction to all things leaderboards on the hub.

Open LLM Leaderboard

Curious about the Open LLM Leaderboard? Start here!

[Update on GitHub](#)

HuggingFace Leaderboards



The previous Leaderboard version is live [here](#) 🇺🇸

🚀 The Open Ko-LLM Leaderboard2 KR objectively evaluates the performance of Korean Large Language Model (LLM). When you submit a model on the "Submit here!" page, it is automatically evaluated.

This leaderboard is co-hosted by [Upstage](#), and [NIA](#) that provides various Korean Data Sets through [AI-Hub](#), and operated by [Upstage](#). The GPU used for evaluation is operated with the support of [KT](#) and [AICA](#). If Season 1 focused on evaluating the capabilities of the LLM in terms of reasoning, language understanding, hallucination, and commonsense through academic benchmarks, Season 2 will focus on assessing the LLM's practical abilities and reliability. The datasets for this season are sponsored by [Flitto](#), [SELECTSTAR](#), and [KAIST AI](#). The evaluation dataset is exclusively private and only available for evaluation process. More detailed information about the benchmark dataset is provided on the "About" page.

You'll notably find explanations on the evaluations we are using, reproducibility guidelines, best practices on how to submit a model, and our FAQ.

🏆 LLM Benchmark About Submission Info

🔍 Search for your model (separate multiple queries with `;`) and press ENTER...

Select columns to show

- ☒ Average 📊
- ☒ Ko-GPQA
- ☒ Ko-Winogrande
- ☒ Ko-GSM8k
- ☒ Ko-EQ Bench
- ☒ Ko-IFEval
- ☒ KorNAT-CKA
- ☒ KorNAT-SVA
- ☒ Ko-Harmlessness
- ☒ Ko-Helpfulness
- ☐ Type
- ☐ Architecture
- ☐ Precision
- ☐ Merged
- ☐ Hub License
- ☐ #Params (B)
- ☐ Hub ❤️
- ☐ Available on the hub
- ☐ Model sha
- ☐ Flagged

☐ Show private/deleted models☐ Show merges☐ Show flagged models

Model types

- ☒ pretrained
- ☒ continuously pretrained
- ☒ fine-tuned on domain-specific datasets
- ☒ chat models (RLHF, DPO, IFT, ...)
- ☒ base merges and moerges
- ☒ ? other

Precision

- ☒ float16
- ☒ bfloat16
- ☒ 8bit
- ☒ 4bit
- ☒ GPTQ
- ☒ ?

Model sizes (in billions of parameters)

- ☒ Unknown
- ☒ 0~3B
- ☒ 3~7B
- ☒ 7~13B
- ☒ 13~35B
- ☒ 35~60B
- ☒ 60B+

T ▲	Model1 ▲	Average 📊 ▲	Ko-GPQA ▲	Ko-Winogrande ▲	Ko-GSM8k ▲	Ko-EQ Bench ▲	Ko-IFEval ▲	KorNAT-CKA ▲	KorNAT-SVA ▲	Ko-Harmlessness ▲	Ko-Help: ▲
🗨	nbeerbower/gemma2-gutenberg-27B	55.93	27.27	70.24	71.72	58.56	74.68	38.05	45.89	65.86	51.1
🔥	byroneverson/gemma-2-27b-it-abliterated	55.5	27.27	69.69	70.81	57.84	72.87	38.75	48.67	63.09	50.52
🗨	unsloth/gemma-2-27b-it	55.49	27.78	70.09	71.11	58.38	72.48	37.57	44.87	65.88	51.3

출처 : <https://huggingface.co/spaces/upstage/open-ko-llm-leaderboard>

Hugging Face and Pollen Robotics show off first project: an open source robot that does chores



Reachy Full Kit + Mobile Base - €39,990



Reachy Full Kit - €27,990



Reachy Starter Kit - €19,990



Reachy Arm Kit - €9,990






Remi Cadene · Jun 7, 2024

@RemiCadene · [Follow](#)

We made Reachy2 from @pollenrobotics autonomously doing household chores and interacting with us. It can move its full body, including its neck. Even the dog was impressed! 🐕 You can do the same at home on smaller robots with github.com/huggingface/le... and github.com/dora-rs/dora



허깅페이스 오픈소스 휴머노이드



Walkthrough

```
.
├── examples                    # contains demonstration examples, start here to learn about LeRobot
│   └── advanced                # contains even more examples for those who have mastered the basics
├── lerobot
│   ├── configs                # contains hydra yaml files with all options that you can override in the comm
│   │   ├── default.yaml      # selected by default, it loads pusht environment and diffusion policy
│   │   ├── env                # various sim environments and their datasets: aloha.yaml, pusht.yaml, xarm.
│   │   └── policy             # various policies: act.yaml, diffusion.yaml, tdmpc.yaml
│   ├── common                 # contains classes and utilities
│   │   ├── datasets           # various datasets of human demonstrations: aloha, pusht, xarm
│   │   ├── envs               # various sim environments: aloha, pusht, xarm
│   │   ├── policies           # various policies: act, diffusion, tdmpc
│   │   └── utils              # various utilities
│   └── scripts                 # contains functions to execute via command line
│       ├── eval.py            # load policy and evaluate it on an environment
│       ├── train.py           # train a policy via imitation learning and/or reinforcement learni
│       ├── push_dataset_to_hub.py # convert your dataset into LeRobot dataset format and upload it to
│       └── visualize_dataset.py # load a dataset and render its demonstrations
├── outputs                    # contains results of scripts execution: logs, videos, model checkpoints
└── tests                      # contains pytest utilities for continuous integration
```

허깅페이스 허브의 기업 활용



•허깅페이스 허브


- ✓ 모델, 데이터셋, 스페이스

•프라이빗 허브

- ✓ A
 - ✓ A
 - ✓ S
 - ✓ I
 - ✓ P
- 2023년 6월 업데이트: 이제 프라이빗 허브를 엔터프라이즈 허브라고 합니다.
- Enterprise Hub는 클라우드 관리 서비스(SaaS)와 엔터프라이즈 보안의 장점을 결합한 호스팅 솔루션입니다. 이를 통해 고객은 **Inference Endpoints**와 같은 특정 서비스를 온클라우드에서 온프레미스에 이르기까지 다양한 컴퓨팅 옵션에 배포할 수 있습니다. SSO를 통한 고급 사용자 관리 및 액세스 제어 기능을 제공합니다.
- 이 실험은 이제 중단되므로 더 이상 **Private Hub** 온-프레미스 배포를 제공하지 않습니다.
- Enterprise 팀에 연락하여 귀사에 가장 적합한 솔루션을 찾으십시오.

•종류

- ✓ 관리형 프라이빗 허브(SaaS)
- ✓ 클라우드 내 프라이빗 허브
- ✓ 온-프레미스 Private Hub



모델 사용하기

모델 사용 : pipeline (= processor + model)




- Task : 수행할 작업
- model : task를 수행을 위한 훈련된 모델
- processor(tokenizer) : model에 따른 토큰화 모듈
- pipeline : AI 모델 + 토큰나이저

```
from transformers import pipeline
```

```
camembert_fill_mask = pipeline("fill-mask", model="camembert-base")  
results = camembert_fill_mask("Le camembert est <mask> :)")
```

```
[  
  {'sequence': 'Le camembert est délicieux :)', 'score': 0.49091005325317383, 'token': 7200, 'token_str': 'délicieux'},  
  {'sequence': 'Le camembert est excellent :)', 'score': 0.1055697426199913, 'token': 2183, 'token_str': 'excellent'},  
  {'sequence': 'Le camembert est succulent :)', 'score': 0.03453313186764717, 'token': 26202, 'token_str': 'succulent'},  
  {'sequence': 'Le camembert est meilleur :)', 'score': 0.0330314114689827, 'token': 528, 'token_str': 'meilleur'},  
  {'sequence': 'Le camembert est parfait :)', 'score': 0.03007650189101696, 'token': 1654, 'token_str': 'parfait'}  
]
```

Tasks



모델 사용법 : model, processor(tokenizer)



- 클래스 지정


```
from transformers import CamembertTokenizer, CamembertForMaskedLM

tokenizer = CamembertTokenizer.from_pretrained("camembert-base")
model = CamembertForMaskedLM.from_pretrained("camembert-base")
```

- 클래스 자동 선택


```
from transformers import AutoTokenizer, AutoModelForMaskedLM

tokenizer = AutoTokenizer.from_pretrained("camembert-base")
model = AutoModelForMaskedLM.from_pretrained("camembert-base")
```



모델의 상세 내용은 모델 카드(Model Card)에서 확인

pipeline = model + processor(tokenizer)



모델 사용법 : FastLanguageModel



특징	AutoModel 계열	FastLanguageModel
지원하는 모델 아키텍처	다양한 모델 아키텍처(BERT, GPT, T5 등)를 자동으로 식별하고 로드할 수 있습니다.	주로 Llama, Mistral 등 특정 아키텍처의 모델을 지원합니다.
메모리 최적화 기능	기본적으로 메모리 최적화 기능을 제공하지 않으며, 추가적인 설정이나 도구가 필요할 수 있습니다.	4비트 양자화와 같은 메모리 최적화 기능을 내장하여, 대형 모델을 단일 GPU에서도 효율적으로 활용할 수 있습니다.
사용 편의성	Hugging Face의 표준 인터페이스를 따르므로, 기존 Transformers 생태계와의 호환성이 높습니다.	Unsloth 라이브러리에 특화되어 있어, 해당 라이브러리의 기능을 활용하려는 경우에 적합합니다.
최대 시퀀스 길이 지원	모델에 따라 다르며, RoPE 스케일링과 같은 기능은 기본적으로 제공되지 않습니다.	RoPE 스케일링을 통해 최대 시퀀스 길이를 조정할 수 있는 기능을 제공합니다.
커뮤니티 및 지원	Hugging Face의 넓은 사용자 기반과 커뮤니티 지원을 받을 수 있습니다.	Unsloth는 비교적 새로운 프로젝트로, 커뮤니티 지원이 제한적일 수 있습니다.

```
pip install unsloth
```

```
from unsloth import FastLanguageModel

model_name = "unsloth/mistral-7b-bnb-4bit" # 사용할 모델 이름
max_seq_length = 2048 # 최대 시퀀스 길이 설정
load_in_4bit = True # 4비트 양자화 로드 설정

model, tokenizer = FastLanguageModel.from_pretrained(
    model_name=model_name,
    max_seq_length=max_seq_length,
    load_in_4bit=load_in_4bit,
)
```

0. 초기 GPT : SKT KoGPT2(skt/kogpt2-base-v2)



```
1 str_model_name = "skt/kogpt2-base-v2"
2
3 from transformers import GPT2LMHeadModel
4 base_model = GPT2LMHeadModel.from_pretrained(
5     str_model_name,
6 )
7 base_model.eval()
8
```

```
GPT2LMHeadModel(
  (transformer): GPT2Model(
    (wte): Embedding(51200, 768)
    (wpe): Embedding(1024, 768)
    (drop): Dropout(p=0.1, inplace=False)
    (h): ModuleList(
      (0-11): 12 x GPT2Block(
        (ln_1): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
        (attn): GPT2Attention(
          (c_attn): Conv1D()
          (c_proj): Conv1D()
          (attn_dropout): Dropout(p=0.1, inplace=False)
          (resid_dropout): Dropout(p=0.1, inplace=False)
        )
        (ln_2): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
        (mlp): GPT2MLP(
          (c_fc): Conv1D()
          (c_proj): Conv1D()
          (act): NewGELUActivation()
          (dropout): Dropout(p=0.1, inplace=False)
        )
      )
    )
    (ln_f): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
  )
  (lm_head): Linear(in_features=768, out_features=51200, bias=False)
)
```

Model Test

```
[17] 1 # Test Prompt
2
3 test_input = "안녕하세요?"
4 # test_input = "조선시대 최고의 장군은 누구야?"
5 # test_input = "Who is the best general in Chosun Dynasity?"
6 input_ids = tokenizer.encode(test_input, return_tensors="pt")
```

```
[18] 1 # Greedy Search
2 #
3 with torch.no_grad():
4     generated_ids = base_model.generate(
5         input_ids,
6         do_sample=False,
7         min_length=10,
8         max_length=50,
9     )
10    print(tokenizer.decode([el.item() for el in generated_ids[0]]))
```

```
안녕하세요?
"그럼, 그건 뭐예요?"
"그럼, 그건 뭐예요?"
"그럼, 그건 뭐예요?"
"그럼, 그건 뭐예요?"
```

모델 카드 : <https://huggingface.co/skt/kogpt2-base-v2>

실습 링크 : <https://colab.research.google.com/drive/1wHdK0G7a57JwvO2l2AYldvndCN3fOwl4?usp=sharing>

1. 음악 생성 모델 : MusicGen - Small - 300M (facebook/musicgen-small)



모델을 개발한 조직: Meta AI의 FAIR 팀.

모델 날짜: MusicGen은 2023년 4월부터 2023년 5월 사이에 훈련되었습니다.

모델 버전: 이는 모델의 버전 1입니다.

모델 유형: MusicGen은 오디오 토큰화를 위한 EnCodec 모델, 음악 모델링을 위한 트랜스포머 아키텍처를 기반으로 하는 자동 회귀 언어 모델로 구성됩니다. 이 모델은 300M, 1.5B 및 3.3B 매개변수의 다양한 크기로 제공되며, 두 가지 변형이 있습니다. 텍스트-음악 생성 작업을 위해 훈련된 모델과 멜로디 가이드 음악 생성을 위해 훈련된 모델입니다.

더 많은 정보가 있는 논문이나 자료: 더 많은 정보는 [Simple and Controllable Music Generation](#) 논문에서 찾아볼 수 있습니다.

데이터: 모델을 훈련하는 데 사용된 데이터 소스는 음악 전문가가 생성하고 권리 보유자와의 법적 계약으로 보호됩니다. 모델은 20,000시간 분량의 데이터로 훈련되었으며, 더 큰 데이터 세트로 모델을 확장하면 모델의 성능을 더욱 개선할 수 있다고 생각합니다.

완화책: 해당 태그를 사용하여 데이터 소스에서 보컬을 제거한 다음, 오픈 소스 [Hybrid Transformer for Music Source Separation](#) (HT-Demucs) 이라는 최첨단 음악 소스 분리 방법을 사용했습니다.

제한 사항:

- 이 모델은 현실적인 보컬을 생성할 수 없습니다.
- 이 모델은 영어 설명을 바탕으로 훈련되었기 때문에 다른 언어로는 성능이 좋지 않습니다.
- 이 모델은 모든 음악 스타일과 문화에 동일하게 적용되지는 않습니다.
- 이 모델은 가끔 노래가 끝나갈 즈음에 갑자기 침묵 속으로 사라지기도 합니다.
- 어떤 유형의 텍스트 설명이 가장 좋은 세대를 제공하는지 평가하기 어려울 때가 있습니다. 만족스러운 결과를 얻으려면 신속한 엔지니어링이 필요할 수 있습니다.

- Text-to-Music : 텍스트 설명이나 오디오 프롬프트에 따라 고품질 음악 샘플 생성
- 4 가지 버전 : small(300M), medium(1.5B), large(3.3B), melody (1.5B)
- MIT 라이선스

라이선스	주요 특징	소스코드 공개 의무	상업적 사용 가능 여부	복제(left) 조항
MIT License	자유롭게 사용, 수정, 배포 가능. 저작권 및 라이선스 표시 유지 필수.	없음	가능	없음

모델 카드 : <https://huggingface.co/facebook/musicgen-small>


실습 링크 : <https://colab.research.google.com/drive/1mElktUpSG8IBqvpBT5Ctrg5FLSAZHlpO?usp=sharing>

Self Test & Review : 5분

2. 언어 모델 : FLAN-T5 (`google/flan-t5-xl`)



- Google FLAN(Finetuned LAnguage Models are zero-shot Learners)
- T5 (Text-to-Text Transfer Transformer), Apache 2.0 라이선스



Model Variant	Number of Parameters	Model Size (GB)
google/flan-t5-small	80M	0.3
google/flan-t5-base	250M	1
google/flan-t5-large	780M	4
google/flan-t5-xl	3B	12
google/flan-t5-xxl	10B	40


출처 : <https://huggingface.co/google/flan-t5-xl>


모델 카드 : <https://huggingface.co/google/flan-t5-xl>

실습 링크 : https://colab.research.google.com/drive/1_qKOPkKkKYvMneQt0SSTYdAXYZhy00Se?usp=sharing

Self Test & Review : 5분

LLM 선택 : LLaMA 계열





Example seed task

Instruction: Brainstorm a list of possible New Year's resolutions.

Output:


- Lose weight
- Exercise more
- Eat healthier

Example Generated task

Instruction: Brainstorm creative ideas for designing a conference room.

Output:

... incorporating flexible components, such as moveable walls and furniture ...



Instruction Finetuning 결과 예시



```
[14] 1 input_text = "Tell me how to train my dog to sit"
      2
      3 # 텍스트 토큰화
      4 inputs = tokenizer_untuned(input_text, return_tensors="pt").to("cuda")
      5
      6 # 텍스트 생성
      7 outputs = model_untuned.generate(inputs["input_ids"], max_length=50, num_return_sequences=1, temperature=0.7)
      8
      9 # 결과 디코딩
     10 generated_text = tokenizer_untuned.decode(outputs[0], skip_special_tokens=True)
     11 print(generated_text)
```

🔄 Tell me how to train my dog to sit
Asked by Anonymous in Dogs and Puppies, September 20, 2012
Tell me how to train my dog to sit.
You need

```
[16] 1 input_text = "Tell me how to train my dog to sit"
      2
      3 # 텍스트 토큰화
      4 inputs = tokenizer_tuned(input_text, return_tensors="pt").to("cuda")
      5
      6 # 텍스트 생성
      7 outputs = model_tuned.generate(inputs["input_ids"], max_length=50, num_return_sequences=1, temperature=0.7)
      8
      9 # 결과 디코딩
     10 generated_text = tokenizer_untuned.decode(outputs[0], skip_special_tokens=True)
     11 print(generated_text)
```

🔄 Tell me how to train my dog to sit and stay!
Sure, I can help you with that! Training your dog to sit and stay is a basic obedience command that can be achieved with patience, consistency,

Chat Completions vs. Completions

The chat completions format can be made similar to the completions format by constructing a request using a single user message. For example, one can translate from English to French with the following completions prompt:

```
Translate the following English text to French: "{text}"
```



And an equivalent chat prompt would be:

```
[{"role": "user", "content": 'Translate the following English text to French'}]
```




Likewise, the completions API can be used to simulate a chat between a user and an assistant by formatting the input [accordingly](#).

The difference between these APIs derives mainly from the underlying GPT models that are available in each. The chat completions API is the interface to our most capable model (`gpt-4`), and our most cost effective model (`gpt-3.5-turbo`). For reference, `gpt-3.5-turbo` performs at a similar capability level to `text-davinci-003` but at 10% the price per token! See pricing details [here](#).

OpenAI ChatCompletion API



- System
 - ✓ 전반적인 AI 역할 지시
- user
 - ✓ 사용자의 요청
- assistant
 - ✓ AI 답변




Role

```
messages =  
[  
  {"role": "system",  
    "content": "You are an assistant... "},  
  {"role": "user",  
    "content": "tell me a joke "},  
  {"role": "assistant",  
    "content": "Why did the chicken... "},  
  ...  
]
```

OpenAI API call

```
def get_completion(prompt,
                    model="gpt-3.5-turbo") :
    messages = [{"role": "user",
                  "content": prompt}]

    response = openai.ChatCompletion.create(
        model=model,
        messages=messages,
        temperature=0)
```



Token	Description
< begin_of_text >	This is equivalent to the BOS token.
< eot_id >	This signifies the end of the message in a turn.
< start_header_id >{role}< end_header_id >	These tokens enclose the role for a particular message. The possible roles can be: system, user, assistant.
< end_of_text >	This is equivalent to the EOS token. On generating this token, Llama 3 will cease to generate more tokens

<|begin_of_text|>

<|start_header_id|>system<|end_header_id|>

You are a honest and unbiased AI assistant who answers User queries with accurate responses.

<|eot_id|>

<|start_header_id|>user<|end_header_id|>


What's the capital of Australia?

<|eot_id|>

<|start_header_id|>assistant<|end_header_id|>

The capital of Australia is Canberra.

Temperature : 출력 결과 변화



Temperature

Word	Logits	Softmax	Softmax with temperature 0.1
flowers	20	0.881	1.000
trees	18	0.119	0.000
herbs	5	0.000	0.000
bugs	2	0.000	0.000

Softmax

$$\text{Softmax}_{\theta}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}}$$

Softmax with temperature θ

$$\text{Softmax}_{\theta}(z_i) = \frac{e^{\frac{z_i}{\theta}}}{\sum_{j=1}^n e^{\frac{z_j}{\theta}}}$$

3. 언어 생성 모델: LLaMA 3 Endpoint(meta-llama/Meta-Llama-3-8B-



Instruct)

모델 세부 정보

Meta는 8B 및 70B 크기의 사전 훈련되고 명령어 조정된 생성 텍스트 모델 모음인 대규모 언어 모델(LLM)의 Meta Llama 3 제품군을 개발 및 출시했습니다. Llama 3 명령어 조정 모델은 대화 사용 사례에 최적화되어 있으며 일반적인 업계 벤치마크에서 사용 가능한 많은 오픈 소스 채팅 모델보다 성능이 뛰어납니다. 또한 이러한 모델을 개발할 때 유용성과 안전성을 최적화하기 위해 세심한 주의를 기울였습니다.

모델 개발자 메타

변형 Llama 3는 8B 및 70B 매개변수의 두 가지 크기로 제공되며 사전 훈련 및 명령 조정 변형으로 제공됩니다.

입력 모델은 입력 텍스트만 입력합니다.

출력 모델은 텍스트와 코드만 생성합니다.

모델 아키텍처 Llama 3는 최적화된 트랜스포머 아키텍처를 사용하는 자동 회귀 언어 모델입니다. 조정된 버전은 SFT(Supervised Micro-Tuning) 및 RLHF(Reinforcement Learning with Human Feedback)를 사용하여 유용성과 안전성에 대한 인간의 선호도에 맞춥니다.

라마 3 모델 제품군. 토큰 수는 사전 학습 데이터만 참조합니다. 8 및 70B 버전 모두 향상된 추론 확장성을 위해 GQA(Grouped-Query Attention)를 사용합니다.

모델 출시일 2024년 4월 18일.

상태 오프라인 데이터 세트에서 학습된 정적 모델입니다. 조정된 모델의 향후 버전은 커뮤니티 피드백을 통해 모델 안전성을 개선하는 대로 출시될 예정입니다.

면허 맞춤형 상업용 라이선스는 다음에서 사용할 수 있습니다

<https://llama.meta.com/llama3/license>

모델에 대한 질문이나 의견을 보낼 수 있는 위치 모델에 대한 피드백이나 의견을 제공하는 방법에 대한 지침은 모델 [README](#)에서 찾을 수 있습니다. 생성 매개 변수 및 애플리케이션에서 Llama 3를 사용하는 방법에 대한 자세한 기술 정보는 여기에서 확인할 수 [있습니다](#).

- Text-to-Text : 텍스트 지시에 따른 텍스트 생성
- 2 가지 버전 : 8B, 70B, llama 3.3 라이선스

모델 카드 : <https://huggingface.co/meta-llama/Meta-Llama-3-8B-Instruct>


실습 링크 : https://colab.research.google.com/drive/1R3fbsoPhlic-Bb26b_jCc1nAeowEvdnf?usp=sharing

Self Test & Review : 5분

[참고] Data Type 에 따른 메모리 요구 사항



What is a model parameter?



It is possible to inspect each parameter's data type!

(a) fp32: Single-precision IEEE Floating Point Format

Range: $\sim 1e^{-38}$ to $\sim 3e^{38}$




(b) fp16: Half-precision IEEE Floating Point Format

Range: $\sim 5.96e^{-8}$ to 65504



(c) bfloat16: Brain Floating Point Format

Range: $\sim 1e^{-38}$ to $\sim 3e^{38}$



- 딥러닝 모델의 매개변수 : FP32 ➔ 4 Bytes
- Inference 시에 메모리 절약을 위해 FP16을 사용할 수 있음 : 약간의 오류

실습 링크 : <https://colab.research.google.com/drive/1LXeCDc6fCix9sawOkwoH37CWqT3HRG0s?usp=sharing>

운영을 위한 GPU 메모리



Numbers ¹⁰⁰ every LLM Developer should know *

Prompts

40-90% Amount saved by appending "Be Concise" to your prompt

1.3 Average tokens per word

Training and Fine Tuning

~\$1 million Cost to train a 13 billion parameter model on 1.4 trillion tokens

< 0.001 Cost ratio of fine tuning vs training from scratch

Price

~50 Cost Ratio of GPT-4 to GPT-3.5 Turbo

5 Cost Ratio of generation of text using GPT-3.5-Turbo vs OpenAI embedding

10 Cost Ratio of OpenAI embedding to Self-Hosted embedding

6 Cost Ratio of OpenAI base vs fine tuned model queries

1 Cost Ratio of Self-Hosted base vs fine-tuned model queries

GPU Memory

16GB V100 GRAM capacity
24GB A10G GRAM capacity
40/80GB A100 GRAM capacity

2x number of parameters Typical GPU memory requirements of an LLM for serving

~1GB Typical GPU memory requirements of an embedding model

>10x Throughput improvement from batching LLM requests

1 MB GPU Memory required for 1 token of output with a 13B parameter model

* Check out bit.ly/llm-dev-numbers for how we calculated the numbers

Presented by  RAY &  anyscale with  Join the community ray.io or Request a Trial anyscale.com/signup today

출처 : <https://www.anyscale.com/blog/num-every-llm-developer-should-know>

운영을 위한 GPU 메모리



Numbers ¹⁰⁰ every LLM Developer should know *

Prompts

40-90% Amount saved by appending "Be Concise" to your prompt

1.3 Average tokens per word

Price

~50

5

10

6

1

Training and Fine Tuning

~\$1 million Cost to train a 13 billion parameter model on 1.4 trillion tokens

60,001 Cost ratio of fine tuning vs training

Word	Abbreviation	Approximate Size (Number of Bytes)	Approximate (Word)	Actual Bytes
Kilo	K or KB	1,000	Thousand	2 ¹⁰ or 1,024
Mega	M or MB	1,000,000	Million	2 ²⁰ or 1,048,576
Giga	G or GB	1,000,000,000	Billion	2 ³⁰ or 1,073,741,824
Tera	T or TB	1,000,000,000,000	Trillion	2 ⁴⁰ or 1,099,511,627,776
Peta	P or PB	1,000,000,000,000,000	Quadrillion	2 ⁵⁰ or 1,125,899,906,842,624
Exa	E or EB	1,000,000,000,000,000,000	Quintillion	2 ⁶⁰ or 1,152,921,504,606,846,976

Cost Ratio of Self-Hosted base vs fine-tuned model queries

1 MB

GPU Memory required for 1 token of output with a 13B parameter model

* Check out bit.ly/llm-dev-numbers for how we calculated the numbers

GPU 메모리 구성




(GPU Memory) =
(모델 크기) * 정밀도 +
(Forward 계산 용량 : 배치 크기 유동적) +
(Gradient 계산 메모리 : 모델 크기) +
(Optimizer 특성에 따른 메모리 :
SGD : 0, RMSProp : 1, Adam : 2)

- FP32 정밀도 : (파라미터 수) * 4
- FP16 정밀도 : (파라미터 수) * 2
- INT8 Quantization : (파라미터 수) * 1

예) 7B FP16 모델 : $2 * (7G) = 14GB$


- Forward 계산 연관성 : batch size, 입력 크기, Precision



Model Quantization

PEFT (parameter-efficient finetuning techniques)

[참고] Quantization 과 LoRA



Loading a Model in 4-bit Quantization

One of the key features of this integration is the ability to load models in 4-bit quantization. This can be done by setting the `load_in_4bit=True` argument when calling the `.from_pretrained` method. By doing so, you can reduce memory usage by approximately fourfold.

Loading a Model in 8-bit Quantization

For further memory optimization, you can load a model in 8-bit quantization. This can be achieved by using the `load_in_8bit=True` argument when calling `.from_pretrained`. This reduces the memory footprint by approximately half.

QLoRA : Quantized LLMs with Low-Rank Adapters




Figure 1: Different finetuning methods and their memory requirements. QLoRA improves over LoRA by quantizing the transformer model to 4-bit precision and using paged optimizers to handle memory spikes.

4. 언어 생성 모델: EXAONE(beomi/EXAONE-3.5-2.4B-Instruct-Llamafied)



EXAONE-3.5-2.4B-지시

소개

우리는 LG AI Research에서 개발 및 출시한 2.4B에서 32B 매개변수에 이르는 명령어 조정 이중 언어(영어 및 한국어) 생성 모델 컬렉션인 EXAONE 3.5를 소개합니다. EXAONE 3.5 언어 모델은 다음과 같습니다. 1) 소규모 또는 리소스가 제한된 장치에 배포하도록 최적화된 **2.4B 모델**, 2) **이전 모델**과 크기가 동일하지만 성능이 향상된 7.8B 모델, 3) 강력한 성능을 제공하는 **32B 모델**. 모든 모델은 최대 32K 토큰의 장기 컨텍스트 처리를 지원합니다. 각 모델은 실제 사용 사례와 장기 컨텍스트 이해에서 최첨단 성능을 보여주는 동시에 최근에 출시된 비슷한 크기의 모델과 비교했을 때 일반 도메인에서 경쟁력을 유지합니다.

자세한 내용은 [기술 보고서](#), [블로그](#), [GitHub](#) 을 참조하세요.

이 저장소에는 다음과 같은 기능을 갖춘 명령어 조정 2.4B 언어 모델이 포함되어 있습니다.

- 매개변수 수(임베딩 없음): 2.14B
- 레이어 수: 30
- 주의 헤드 수: 32개 Q 헤드와 8개 KV 헤드가 있는 GQA
- 어휘 크기: 102,400
- 컨텍스트 길이: 32,768 토큰
- Tie Word Embeddings: True(7.8B 및 32B 모델과 달리)

빠른 시작

`transformers` v4.43 이상을 사용하는 것이 좋습니다.

- Text-to-Text : 텍스트 지시에 따른 텍스트 생성, exaone 라이선스

모델 카드 : <https://huggingface.co/beomi/EXAONE-3.5-2.4B-Instruct-Llamafied>

실습 링크 : <https://colab.research.google.com/drive/1HZ9p0haSZNdTDXIECvf3IngqBsDMiX63?usp=sharing>

Self Test & Review : 5분

5. 언어 생성 모델: LLaMA 3(meta-llama/Meta-Llama-3-8B-Instruct)



meta-llama/**Meta-Llama-3-8B-Instruct** like 3.74k Follow Meta Llama 17.5k

Text Generation Transformers Safetensors PyTorch English llama facebook meta llama-3 conversational text-generation-inference Inference Endpoints License: llama3

Model card Files and versions Community 200

Edit model card

A newer version of this model is available: [meta-llama/Llama-3.1-8B-Instruct](#)

Gated model You have been granted access to this model

Model Details

Meta developed and released the Meta Llama 3 family of large language models (LLMs), a collection of pretrained and instruction tuned generative text models in 8 and 70B sizes. The Llama 3 instruction tuned models are optimized for dialogue use cases and outperform many of the available open source chat models on common industry benchmarks. Further, in developing these models, we took great care to optimize helpfulness and safety.

Model developers Meta

Variations Llama 3 comes in two sizes — 8B and 70B parameters — in pre-trained and instruction tuned variants.

Downloads last month **1,062,304**

Safetensors Model size 8.03B params Tensor type BF16

Inference API Warm

Text Generation Examples

Input a message to start chatting with meta-llama/Meta-Llama-3-8B-Instruct.

- LLaMA 와 LangChain 연동 테스트 , llama 3.3 라이선스

모델 카드 : <https://huggingface.co/meta-llama/Meta-Llama-3-8B-Instruct>

실습 링크 : https://colab.research.google.com/drive/1T41ZhIMFKR5rFxtZf_bt8chpr6eFuEkZ?usp=sharing

Self Test & Review : 5분

6. 음성 생성 (1) : VITS (kakao-enterprise/vits-ljs)



카카오엔터프라이즈 / 비츠-LJS

TTS(텍스트 음성 변환) 트랜스포머 파이토치 세이프텐서 VITS(영문) 텍스트를 오디오로 변환 추론 엔드포인트 면허: MIT (미트)

모델 카드 파일 및 버전 커뮤니티 1

기차 전개시키다 이 모델 사용

모델 카드 편집

VITS: 엔드투엔드 TTS(Text-to-End)를 위한 적대적 학습을 통한 조건부 변분 오토 인코더

BITS는 입력 텍스트 시퀀스에 따라 음성 파형을 예측하는 엔드 투 엔드 음성 합성 모델입니다. 그것은 이 조건부 변이 오토인코더(VAE)는 사후 인코더, 디코더 및 조건부 사전으로 구성됩니다. 이 저장소 [LJ Speech](#) 데이터 세트에서 훈련된 공식 VITS 체크포인트에 대한 가중치가 포함되어 있습니다.

모델 세부 정보

VITS(V, 종단 간 Text-to-Speech에 대한 적대적 학습을 사용한 Variational Inference)는 종단 간 분석입니다. 입력 텍스트 시퀀스에 따라 음성 파형을 예측하는 음성 합성 모델입니다. 조건부 변이입니다. 오토인코더(VAE)는 사후 인코더, 디코더 및 조건부 사전으로 구성됩니다.

지난달 다운로드 수
1,404

세이프텐서 모델 크기 36.3M 매개변수 텐서 유형 F32 키

추론 예제 TTS(텍스트 음성 변환)

이 모델에는 아직 Inference API(서버리스)에 배포할 수 있는 충분한 활동이 없습니다. 소셜을 늘리십시오. 가시성을 확보하고 나중에 다시 확인하거나, 대신 [추론 엔드포인트\(전용\)](#)에 배포할 수 있습니다.

모델 트리 카카오엔터프라이즈 / VITS-LJS



- Text-to-Speech : 주어진 문장을 음성으로 변환
- 영어 만 지원 (영어 훈련 데이터셋)
- MIT 라이선스

모델 카드 : <https://huggingface.co/kakao-enterprise/vits-ljs>

실습 링크 : <https://colab.research.google.com/drive/1-dNKchuhO5TAbW65tzuAj724hFqmWeG0?usp=sharing>

한국어를 지원하는 TTS 찾기 : 5분

7. 음성 생성 (2) : Suno Bark (suno/bark)



- Text-to-Speech : 주어진 문장을 음성으로 변환
- 한국어 지원, MIT 라이선스

모델 카드 : <https://huggingface.co/suno/bark>

실습 링크 : https://colab.research.google.com/drive/1bELEs_k4P2SvqicLPsdJinWKb55MJ0hr?usp=sharing

Self Test & Review : 5분

8. 객체 탐지 : Meta 의 DETR (facebook/detr-resnet-50)



객체 감지 변압기 파이토치 세이프텐서 머리 데트르 비전 추론 엔드포인트

모델 카드 파일 및 버전 지역 사회 23


ResNet-50 백본을 사용한 DETR(End-to-End Object Detection) 모델

Detection Transformer(DETR) 모델은 COCO 2017 객체 감지(118k 주석 이미지)에서 종단간 학습되었습니다. 이 모델은 Carion 등이 작성한 [End-to-End Object Detection with Transformers](#) 논문에서 소개되었으며 [이 저장소](#)에 처음 공개되었습니다.

면책 조항: DETR을 출시한 팀은 이 모델에 대한 모델 카드를 작성하지 않았으므로 이 모델 카드는 Hugging Face 팀에서 작성했습니다.

모델 설명

DETR 모델은 합성곱 백본을 갖춘 인코더-디코더 변환기입니다. 객체 감지를 수행하기 위해 디코더 출력 위에 두 개의 헤드가 추가됩니다. 클래스 레이블을 위한 선형 레이어와 바운딩 박스를 위한 MLP(다중 레이어 퍼셉트론)입니다. 이 모델은 소위 객체 쿼리를 사용하여 이미지에서 객체를 감지합니다. 각 객체 쿼리는 이미지에서 특정 객체를 찾습니다. COCO의 경우 객체 쿼리 수는 100으로 설정됩니다.



- ObjectDetection : 이미지 내의 객체 탐지
- ResNet-50 기반 DETR(End-to-End Object Detection) , Apache 2.0 라이선스

모델 카드 : <https://huggingface.co/facebook/detr-resnet-50>

실습 링크 : <https://colab.research.google.com/drive/1CYebuAHD9t27qiqvchROv2AikquEMBrJ?usp=sharing>

Self Test & Review : 5분

9. 화자 구분/분할 : pyannote/speaker-diarization-3.1, speechbrain/sepformer-wham



이 오픈 소스 모델을 프로덕션에서 사용하고 계신가요?
더 빠르고 더 나은 옵션을 위해 [pyannoteAI](#)로 전환하는 것을 고려하십시오.

스피커 디아리제이션 3.1

이 파이프라인은 문제가 있는 사용을 제거한다는 점을 제외하고는 [pyannote/speaker-diarization-3.0](#)과 동일합니다.

이제 스피커 세분화와 임베딩이 모두 순수 PyTorch에서 실행됩니다. 이렇게 하면 배포가 쉬워지고 추론 속도가 빨라질 수 있습니다.

pyannote.audio 버전 3.1 이상이 필요합니다.`onnxruntime`

16kHz로 샘플링된 모노 오디오를 인제스트하고 화자 분할을 [Annotation](#) 인스턴스로 출력합니다.

- 스테레오 또는 다중 채널 오디오 파일은 채널 평균을 계산하여 자동으로 모노로 다운믹스됩니다.
- 다른 속도로 샘플링된 오디오 파일은 로딩 시 자동으로 16kHz로 리샘플링됩니다.

SepFormer는 WHAM에서 훈련되었습니다!

이 저장소는 SpeechBrain으로 구현되고 [WHAM!](#) 데이터 세트는 기본적으로 환경 노이즈가 있는 WSJ0-Mix 데이터 세트 버전인 [SepFormer](#) 모델을 사용하여 오디오 소스 분리를 수행하는 데 필요한 모든 도구를 제공합니다. 더 나은 경험을 위해 [SpeechBrain](#)에 대해 자세히 알아보는 것이 좋습니다. 모델 성능은 WHAM의 테스트 세트에서 16.3dB SI-SNRi입니다! 데이터 세트.

석방	테스트 세트 SI-SNRi	SDRi 테스트 세트
09-03-21	16.3 데시벨	16.7 데시벨

SpeechBrain 설치

먼저 다음 명령을 사용하여 SpeechBrain을 설치하십시오.

```
pip install speechbrain
```

- 음성 파일(.wav) 에서 화자 별로 발성 부분 탐지(pyannote/speaker-diarization-3.1), MIT 라이선스
- 음성 파일에서 화자 별로 음성 분리 (speechbrain/sepformer-wham), Apache 2.0 라이선스

모델 카드 : <https://huggingface.co/pyannote/speaker-diarization-3.1>, <https://huggingface.co/speechbrain/sepformer-wham>

9. 화자 구분/분할 : deepseek-ai/DeepSeek-V3, openai/whisper-large-v3-turbo



조리스코스/ConvTasNet_Libri2Mix_sepclean_16k

오디오-오디오 소행성 파이토치 리브리2믹스 sep_clean 오디오

모델 카드 파일 및 버전 커뮤니티

소행성 모델 JorisCos/ConvTasNet_Libri2Mix_sepclean_16k

묘사:

이 모델은 Joris Cosentino가 Asteroid의 librimix 레시피를 사용하여 훈련했습니다. Libri2Mix 데이터 세트의 작업에 대해 훈련되었습니다. sep_clean

Whisper는 자동 음성 인식(ASR) 및 음성 번역을 위한 최첨단 모델로, Alec Radford의 Robust Speech Recognition via Large-Scale Weak Supervision 논문에서 제안되었습니다. OpenAI. >5M 시간의 레이블이 지정된 데이터로 훈련된 Whisper는 많은 사람들에게 일반화할 수 있는 강력한 능력을 보여줍니다. 제로샷(zero-shot) 설정의 데이터 세트 및 도메인.

Whisper large-v3-turbo는 정리된 Whisper large-v3의 미세 조정 버전입니다. 즉, 디코딩 계층의 수가 32개에서 4개로 줄어든 것을 제외하고는 정확히 동일한 모델입니다. 결과적으로, 모델은 훨씬 더 빠르지만 약간의 품질 저하가 발생합니다. 이에 대한 자세한 내용은 이 GitHub 토론에서 확인할 수 있습니다.

면책 조항: 이 모델 카드의 콘텐츠는 부분적으로 Hugging Face 팀에 의해 작성되었으며 일부는 복사되었으며 원래 모델 카드에서 붙여 넣습니다.

- 음성 파일에서 화자 별로 음성 분리 (JorisCos/ConvTasNet_Libri2Mix_sepclean_16k), CC 라이선스
- 음성 파일의 내용을 문자로 변환 (openai/whisper-large-v3-turbo), MIT 라이선스


모델 카드 : https://huggingface.co/JorisCos/ConvTasNet_Libri2Mix_sepclean_16k ,
<https://huggingface.co/openai/whisper-large-v3-turbo>

실습 링크 : https://colab.research.google.com/drive/1L4y8TBcv_QQI9algyCcKEhgyH5_zHUmW?usp=sharing

[openai](#)/whisper-large-v3-turbo 사용한
STT 부분구현하기 : 10분

Self Test & Review : 5분

Transformer 기반 모델



- 트랜스포머 기반 모델 : ChatGPT, LLaMA . 자기지도 학습을 수행함.
- 일반화가 뛰어나며 파인튜닝도 가능함 (예: BERT).
- 대부분의 LLM과 FM(Foundation Model)은 트랜스포머 기반.
- NLP 이외에도 많이 활용하는 트랜스포머 모델 : **ViT**, **SAM**
- 트랜스포머의 핵심은 **자기-어텐션(self-attention)** 개념임.

SAM (Segment Anything Model) : 이미지 분할의 FM




Figure 1: We aim to build a foundation model for segmentation by introducing three interconnected components: a promptable segmentation *task*, a segmentation *model* (SAM) that powers data annotation and enables zero-shot transfer to a range of tasks via prompt engineering, and a *data* engine for collecting SA-1B, our dataset of over 1 billion masks.

1. Zero-shot Generalization을 가능하게 하는 Task는 무엇인가? → promptable segmentation
2. 대응되는 모델 아키텍처는 무엇인가? → prompt encoder(MAE, CLIP, Dense Prompt) Mask Decoder, Mask와 IoU
3. 어떤 데이터로 훈련시키면 될까? → Base Model 을 위한 대량 데이터셋 구성

SAM (Segment Anything Model) : 이미지 분할의 FM





Figure 4: Segment Anything Model (SAM) overview. A heavyweight image encoder outputs an image embedding that can then be efficiently queried by a variety of input prompts to produce object masks at amortized real-time speed. For ambiguous prompts corresponding to more than one object, SAM can output multiple valid masks and associated confidence scores.


- SAM은 이미지 임베딩을 생성하고 다양한 입력 프롬프트로 객체 마스크를 출력
- 실시간 속도로 동작하며, 애매한 프롬프트에 대해 다중 마스크와 신뢰도를 제공

10. Open Vocabulary Object Detection, SAM

Image-level contrastive pre-training



Transfer to open-vocabulary detection



모델 카드 1 : <https://huggingface.co/google/owlvit-base-patch32>

모델 카드 2 : <https://huggingface.co/CIDAS/clipseg-rd64-refined>

실습 링크 : <https://colab.research.google.com/drive/1XFQGXUXsezM88B0p6tAoSU6yykKZPIj?usp=sharing>

Self Test & Review : 5분

Transformer 개선과 미래

Attention is All You need - 2017



Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com

Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu

Łukasz Kaiser*
Google Brain
lukaszkaizer@google.com

Illia Polosukhin* ‡
illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature. We show that the Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.



Money Is All You Need

Nick Debu
Tokyo Institute of Bamboo Steamer

Abstract

Transformer-based models routinely achieve state-of-the-art results on a number of tasks but training these models can be prohibitively costly, especially on long sequences. We introduce one technique to improve the performance of Transformers. We replace NVIDIA P100s by TPUs, changing its memory from huge GB to piyo GB. The resulting model performs on par with Transformer-based models while being much more "TSUYO TSUYO".

Attention is All You need - 2017





Figure 1: The Transformer - model architecture.

Scaled Dot-Product Attention



Multi-Head Attention






Figure 2: (left) Scaled Dot-Product Attention. (right) Multi-Head Attention consists of several attention layers running in parallel.

G(P)T 와 BERT



[복습] LLM 선택 : LLM 모델 계통도






Fig. 1. The evolutionary tree of modern LLMs traces the development of language models in recent years and highlights some of the most well-known models. Models on the same branch have closer relationships. Transformer-based models are shown in non-grey colors: decoder-only models in the blue branch, encoder-only models in the pink branch, and encoder-decoder models in the green branch. The vertical position of the models on the timeline represents their release dates. Open-source models are represented by solid squares, while closed-source models are represented by hollow ones. The stacked bar plot in the bottom right corner shows the number of models from various companies and institutions.

[복습] Encoder, Decoder, Encoder-Decoder 모델



Token Activation : Hallucination 탐지 가능?



Token Activation : Hallucination 탐지 가능?



Question: Who was the first Nigerian to win the Nobel Prize, in which year?

트랜스포머 논문 오류?



Sebastian Raschka ✓

@rasbt

Fun fact: did you know that the original Attention Is All You Need transformer figure is wrong?

It places the layer normalization between the residual blocks, which doesn't match the code: [github.com/tensorflow/ten...](https://github.com/tensorflow/tensorflow)

PS: This is known as Post-LN Transformer

1/3

계시를 번역하기

Post-LN Transformer




Figure 1: The Transformer - model architecture.

Attention Is All You Need, <https://arxiv.org/abs/1706.03762>

Places the layer normalization between the residual blocks: the expected gradients of the parameters near the output layer are large

트랜스포머 논문 오류?




Fun fact: did you know that the original Attention Is All Your Need transformer figure is wrong?

It places the layer normalization between the residual blocks, which doesn't match the code: [github.com/tensorflow/ten...](https://github.com/tensorflow/tensorflow)

PS: This is known as Post-LN Transformer

1/3

게시물 번역하기



오후 11:09 · 2023년 5월 8일 · 25.5만 조회수




재미있는 사실: 원래 Attention Is All Your Need 변압기 수치가 잘못되었다는 것을 알고 계셨습니까?

... 추신: 이것은 Post-LN 변압기로 알려져 있습니다.

1/3

게시물 번역하기




오후 11:09 · 2023년 5월 8일 · 25.5만 조회수

183 재게시 14 인용 1,144 마음에 들어요 632 북마크

출처 : <https://twitter.com/rasbt/status/1655575611979489282>

Transformer Layers : Pre-LN, Post-LN, Dual-Residual Transformer



Transformer Layers : Pre-LN, Post-LN, Dual-Residual Transformer



Post-LN Transformer




Figure 1: The Transformer - model architecture.
Attention Is All You Need, <https://arxiv.org/abs/1706.03762>

Pre-LN Transformer

Better gradients if LayerNorm is placed inside residual connection, before the attention and fully connected layers






Figure 1: The Transformer - model architecture.

Dual-Residual Transformer






Method	Gradient Vanishing	Representation Collapse
Post-LN	☹️	☹️
Pre-LN	☹️	☹️
ResiDual	😊	😊

ResiDual: Transformer with Dual Residual Connections, <https://arxiv.org/abs/2304.14802>




On Layer Normalization in the Transformer Architecture, <https://arxiv.org/abs/2002.04745>



Transformer Layers : Pre-LN, Post-LN, Dual-Residual Transformer




Dual-Residual Transformer



Method	Gradient Vanishing	Representation Collapse
Post-LN	☹️	😄
Pre-LN	😄	☹️
Residual	😄	😄

Residual: Transformer with Dual Residual Connections,
<https://arxiv.org/abs/2304.14802>

트랜스포머를 대체할 맘바(Mamba?)




트랜스포머를 대체할 맘바(Mamba?)



출처 : [What is Mamba?. The following article will just... | by Joe El khoury | Dec, 2023 | Medium](#)

트랜스포머와 맘바의 결합 : SAMBA




트랜스포머와 맘바를 결합한 잠바(Jamba)



	TRANSFORMER	+	MAMBA	
	Transformer		Mamba	Jamba
Highest Quality Output	✓			✓
High Throughput			✓	✓
Low Memory Footprint			✓	✓


公众号 · 量子位

트랜스포머와 맘바를 결합한 잠바(Jamba)




출처 : <https://medium.com/@nimritakoul01/mamba-and-jamba-simply-explained-d9924b564ea1>

트랜스포머와 맘바를 결합한 잠바(Jamba)



(a) Jamba block



(b) Different types of layers defined by Jamba architecture

Diagram showing (a) a single Jamba block, (b) Different types of layers. Jamba implementation includes 4 Jamba blocks, each containing 8 layers, a 1/7 ratio of attention/Mamba layers, and MoE applied every 2 layers

AI21Studio

Chat

Conversational RAG

RAG Engine

Settings

Organization

Members

Usage

API key

Plans & Billing

My Account

Documentation

승우 My organization

Chat Playground

Build with Jamba models

Improve an email draft

Summarize text according to instructions

Extract answers from text

Message...

Jamba can make mistakes. Please verify information.

No upcoming bill You're on a free trial of the Pay

Plans

Pay As You Go

Access all features through usage-based pricing, no minimum subscription fee is applied.

Upgrade

89 days left on your free trial

`트랜스포머` 잇는 ~~초초거대 AI 오나...~~ 구글, `타이탄즈` 공개

Titans: Learning to Memorize at Test Time

새 아키텍처
"LLM-RNN"
더 적은 파라미터

최근 구글 연구진은

short-term memory model

성과 공유 사이.

이 등 구글 연구

석, 시계열 작업

논문은 현재 L

접목, 각각이 2

으로 저장하고

따라 대량의 종

평가에 쓰인 코

어텐션 기반 트

이 길어지면 연

트랜스포머 방

실을 초래하고

구글의 새 아키텍

적 구조를 모방

리하는 단기메


(retrieve)도 하

터인 지속(Pers


Model	Wiki. ppl ↓	LMB. ppl ↓	LMB. acc ↑	PIQA acc ↑	Hella. acc_n ↑	Wino. acc ↑	ARC-e acc ↑	ARC-c acc_n ↑	SIQA acc ↑	BoolQ acc ↑	Avg. ↑
340M params / 15B tokens											
Transformer++	21.52	41.08	20.76	62.08	24.76	50.52	45.21	24.05	26.81	58.24	42.02
400M params / 15B tokens											
Transformer++	30.63	37.37	29.64	64.27	37.72	51.52	54.95	27.36	38.07	61.59	45.64
760M params / 30B tokens											
Transformer++	25.21	27.64	35.78	66.92	42.19	51.95	60.38	32.46	39.51	60.37	48.69
RetNet	26.08	24.45	34.51	67.19	41.63	52.09	63.17	32.78	38.36	57.92	48.46
Mamba	28.12	23.96	32.80	66.04	39.15	52.38	61.49	30.34	37.96	57.62	47.22
Mamba2	22.94	28.37	33.54	67.90	42.71	49.77	63.48	31.09	40.06	58.15	48.34
DeltaNet	24.37	24.60	37.06	66.93	41.98	50.65	64.87	31.39	39.88	59.02	48.97
TTT	24.17	23.51	34.74	67.25	43.92	50.99	64.53	33.81	40.16	59.58	47.32
Gated DeltaNet	21.18	22.09	35.54	68.01	44.95	50.73	66.87	33.09	39.21	59.14	49.69
Samba*	20.63	22.71	39.72	69.19	47.35	52.01	66.92	33.20	38.98	61.24	51.08
Gated DeltaNet-H2*	19.88	20.83	39.18	68.95	48.22	52.57	67.01	35.49	39.39	61.11	51.49
Titans (LMM)	20.04	21.96	37.40	69.28	48.46	52.27	66.31	35.84	40.13	62.76	51.56
Titans (MAC)	19.93	20.12	39.62	70.46	49.01	53.18	67.86	36.01	41.87	62.05	52.51
Titans (MAG)	18.61	19.86	40.98	70.25	48.94	52.89	68.23	36.19	40.38	62.11	52.50
Titans (MAL)	19.07	20.33	40.05	69.99	48.82	53.02	67.54	35.65	30.98	61.72	50.97

ent models and
attention allows
rate modeling
present a new
attend to the
stage of a fast
tion due to its
tory due to its
we introduce
ly incorporate
ing, genomics,
urrent models,
haystack tasks

논문에 따르면 2
에서 성능이 급격
분에 정확하게 정
(ABILong)에선 더
했다.
결정을 지원하는
으로 통합해 균형
으로 통합해 처리
를 지냈다.



출처 : <https://arxiv.org/pdf/2501.00663>



출처 : <https://blog.naver.com/ksf0803/110094061680>

MAC 아키텍처	뇌의 구조	역할 및 기능
Core	전두엽	입력 데이터를 통합하고 의사결정을 수행
Contextual Memory	해마	새로운 정보를 학습하고 기존 문맥을 업데이트
Persistent Memory	대뇌피질	안정적인 장기 기억을 저장
Retrieval	해마 ↔ 대뇌피질	단기와 장기 기억 간의 정보 검색 및 통합
Attention	시상, 전두엽	주의 집중을 통해 중요한 정보를 선택
Update	해마, 신경가소성	새로운 정보를 학습하며 기존 기억을 수정 및 갱신




Figure 3: Attention masks for different variants of Titans.




Figure 4: **Memory as a Gate (MAG) Architecture.** This architecture, similarly, has the three branches of (1) core, (2) contextual memory, and (3) persistent memory. It, however, incorporates only persistent memory into the context and combine memory with the core branch using a gating mechanism. At test time, the behavior is the same as Figure 2.





Figure 5: **Memory as a Layer (MAL) Architecture.** In this architecture, the memory layer is responsible to compress past and current context before the attention module.

특징	Titans 아키텍처	Jamba 아키텍처
핵심 기술	Memory as a Context (MAC) 기반	Mamba-Transformer 하이브리드 구조
긴 문맥 처리 능력	최대 2M 토큰 이상 지원	최대 256K 토큰 지원
효율성 전략	메모리 디케이 및 병렬 처리 최적화	MoE 및 블록-레이어 접근 방식 활용
응용 분야	언어 모델링, 유전체학, 시계열 분석 등	텍스트 생성, 요약, 정보 추출 등
주요 차별점	인간 기억 체계 모방	SSM과 트랜스포머의 결합으로 효율성 극대화




Inception : dLLM (diffusion LLM) - <https://chat.inceptionlabs.ai/>




Inception : dLLM (diffusion LLM)



출처 : <https://www.inceptionlabs.ai/news>







창업자는 천천히 생각하고 빠르게 움직여야 합니다.

데이터를 발견하고 직감적으로 반응하십시오.




라이언 셰퍼(Ryan Sheffer) · 뒤따르다

4분 분량의 글 · 2015년 12월 18일

데이터만으로는 충분하지 않습니다

실패에 대한 데이터를 확보한 후에는 이것만으로는 충분하지 않습니다. 시장이나 제품의 요구 사항을 확실하게 파악하는 것은 매우 중요하지만 행동에 나서야 합니다. 앞서 나가는 시스템 2의 두뇌가 분석에는 뛰어나지만 직관적인 시스템 1이 허용하는 즉각적인 행동 능력이 부족하다고 지적했다. 창업자로서 우리의 목표는 우리 자신의 직관에 속지 않고 대신 깊은 분석을 실행하는 것입니다. 그리고 데이터가 들어오면 조치를 취해야 합니다. 시장을 이해하는 데 시간을 할애하고 있다면 시장을 창조하는 것이 아닙니다.

창업자로서 우리는 이러한 수준의 심층적인 분석, 우리에게 기회가 없다고 말하는 이야기에 직면했을 때 두려움을 느끼지 않고, 우리가 그것을 알아냈다는 것을 알았을 때 즉각적으로 반응하기 위해 노력해야 합니다.



100원 200원 400원 500원 동전이 무한히 있다.
최소 동전 수로 800원 거스름돈을 주는 방법은?



동전이 무한히 있는 상황에서 최소 동전 수로 800원을 거슬러 주는 방법을 찾으려면, 가장 큰 금액의 동전부터 사용하면 됩니다.

1. 500원 동전 1개 사용: $800\text{원} - 500\text{원} = 300\text{원}$
2. 400원 동전 1개 사용: $300\text{원} - 400\text{원} = -100\text{원}$ (이 경우는 음수이므로 불가능합니다.)
3. 200원 동전 1개 사용: $300\text{원} - 200\text{원} = 100\text{원}$
4. 100원 동전 1개 사용: $100\text{원} - 100\text{원} = 0\text{원}$

따라서, 최소 동전 수로 800원을 거슬러 주는 방법은 500원 1개, 200원 1개, 100원 1개로 총 3개의 동전을 사용하는 것입니다.

추론 능력 : CoT → System2 강요



차근차근 주어진 질문에 답하십시오.
다음 형식을 사용하십시오.

질문 : 입력된 질문

생각 1차 : 질문에 대한 다양한 해결법 생각.

수행 1차 : 해결법을 하나씩 수행

관찰 1차 : 수행된 결과와 목표 비교 관찰

결과 1차 : 앞의 시도에서 나온 결과

생각 2차 : 1차보다 더 단순한 방법 고려

수행 2차 : 해결법을 하나씩 수행

관찰 2차 : 수행된 결과와 목표 비교 관찰

최종 답변 : 입력된 요청에 대한 최종 결과물

시작 ~~~

질문 : 100원 200원 400원 500원 동전이 무한히 있다.
최소 동전 수로 800원 거스름돈을 주는 방법은?

시작 ~~~

질문: 100원, 200원, 400원, 500원 동전이 무한히 있다. 최소 동전 수로 800원 거스름돈을 주는 방법은?

생각 2차:

1차 결과가 이미 최적의 방법처럼 보이지만, 더 단순한 동전 조합이 가능한지 검토.
다른 조합 (예: 400원을 활용)으로 동전 수를 줄일 수 있는지 확인.

수행 2차:

1. 400원 동전을 두 개 사용 $\rightarrow 800 - (400 \times 2) = 0$ 원.

총 사용 동전: 400원 2개 = 2개.

관찰 2차:

1차보다 더 적은 동전 수로 800원을 거슬러 줄 수 있었음.
최소 동전 수는 2개임.

결과 2차:

동전 2개 사용: 400원 2개.

최종 답변:

최소 동전 수로 800원을 거슬러 주는 방법은 400원 동전 2개를 사용하는 것입니다.

추론 능력 : o1 Reasoning → System 2 습득



100원 200원 400원 500원 동전이 무한히 있다.
최소 동전 수로 800원 거스름돈을 주는 방법은?

100원 200원 400원 500원 동전이 무한히 있다.
최소 동전 수로 800원 거스름돈을 주는 방법은?

+

🌐 검색

💡 이성

↑

Reasoning : 추론

5초 동안 이성 처리 완료 ✓

여기서 문제는 최소 코인 수로 800원 거스름돈을 주는 방법입니다. 100원, 200원, 400원, 500원의 동전이 있습니다.

500원 동전을 사용하면 300원이 남고, 200원과 100원 동전으로 총 3개의 동전(500, 200, 100)을 만들 수 있습니다. 하지만 잠깐만요, 400원 동전 두 개를 사용하면 동전 2개로 정확히 800원을 얻을 수 있습니다. 그것이 최소 코인 수입니다!

확인해보니 400원 동전 두 개를 사용하면 가장 적은 동전으로 800원 동전이 나옵니다(총 2동). 500원 동전을 시도했다면 나머지 300원에는 200원과 100원 동전이 필요하며, 이는 두 개의 400원 동전에서 2동전보다 많은 3개의 동전을 합산합니다. 따라서 최종 답변은 두 개의 400원 동전을 사용하는 것이 가장 좋고 코인 사용을 최소화합니다.

800원을 최소 동전 수로 거슬러 주기 위해서는 400원 동전을 2개 사용하면 됩니다.

풀이:

- 사용 가능한 동전: 100원, 200원, 400원, 500원
- 400원 동전 2개를 사용하면 $400 + 400 = 800$ 원이 되어, 동전 수는 2개로 최소가 됩니다.

따라서, **400원 동전 2개**가 최소 동전 수의 해법입니다.

number of coins. We have

th 200원 and 100원 coins,

es us exactly 800원 with only

n the fewest coins — just 2

ires 200원 and 100원 coins,

400원 coins. So, the final

s coin usage.

면 됩니다.

2개로 최소가 됩니다.

中 AI 벤처의 추론 모델..."오픈AI o1 성능 능가"

기사입력 : 2025년01월22일 09:37 | 최종수정 : 2025년01월22일 09:37

[베이징=뉴스핌] 조용성 특파원 = 중국의 AI(인공지능) 스타트업인 딥시크(DeepSeek, 중국명 선두추쉬, 深度求索)가 오픈AI의 o1에 버금가는 추론형 AI 모델을 발표했다.

딥시크가 21일 추론형 AI 모델인 딥시크-R1을 발표했다고 중국 매체 차이렌서(财联社)가 22일 전했다.

딥시크는 R1 모델이 주요 AI 벤치마크인 AIME와 MATH-500 지표에서 오픈AI의 추론형 AI 모델인 o1보다 높은 성능을 보였다고 소개했다. 또한 딥시크는 R1의 이용 가격이 o1보다 90% 이상 저렴하다고 덧붙였다.

대표적인 대화형 AI 대형 모델(LLM)인 챗GPT가 일반인들과의 대화를 목적으로 만들어졌다면, 추론형 AI 모델인 o1은 연구자나 전문직 종사자를 대상으로 수학, 과학, 코딩 등 복잡한 문제 해결 및 고급 추론 작업을 위해 만들어졌다.

딥시크의 R1은 오픈AI의 o1과 비슷한 대형 모델이다. 6710억 개의 매개변수를 포함하고 있으며, 복잡한 문제 해결에 필요한 방대한 데이터를 처리할 수 있다.

이에 앞서 딥시크는 지난해 12월 말 대화형 AI 대형 모델인 V3를 출시해 업계를 놀라게 했다. 출시 당시 딥시크는 "V3는 코딩 벤치마크(성능 평가)에서 오픈AI의 'GPT-4o', 메타의 '라마 3.1'을 넘어섰다"고 발표했다.

출처 : <https://www.newspim.com/news/view/20250122000227>

질문 : 100원 200원 400원 500원 동전이 무한히 있다. 최소 동전 수로 800원 거스름돈을 주는 방법은?

또 아니면 $400 + 400 = 800$, 즉 2개의 동전입니다.

따라서 네, 가장 효율적인 방법인 듯합니다.

의

또 다른 생각: 200원 동전 3개와 100원 동전 2개를 사용하면 어떨까요?

그러면 $600 + 200 = 800$ 개가 되지만, 5개로 2개보다 나쁩니다.

잠깐

따라서 400원 동전 2개를 사용하는 것이 확실히 더 나은 선택입니다.

아니

총 따라서 결론은 400원 동전 2개를 사용하는 것이 800원을 만드는 데 필요한 최소 동전 수라는 것입니다.

아니 </think>

수요

400 사용 가능한 액면가(100, 200, 400, 500)를 사용하여 800원을 만드는 데 필요한 최소 동전 수는 2개입니다. 이것은 400원 동전 2개를 사용하여 달성됩니다.

다른

요? 답: 400원 동전 2개를 사용하여 800원을 만들면 최소 동전 수(2)가 됩니다.



Shifting focus from next-word prediction to reasoning models

	Chat Models 	Reasoning Models 
Scaling paradigm	<u>Next-token-prediction</u>	<u>RL on CoT</u>
Reasoning type	<u>System 1 (fast, intuitive)</u>	<u>System 2 (slow, effort-ful)</u>
Tell the model	How ("think step by step")	What ("here is the output i want")
Interaction	<u>Chat / "interactive"</u>	<u>Research or planning / "in the background"</u>

taken from Langchain notion notes

출처 : <https://medium.com/@mayadakhatab/the-era-of-reasoning-models-moving-beyond-chain-of-thought-prompting-fa24ce25c106>


1. Ollama란

'Ollama'는 대규모 언어 모델을 로컬 컴퓨터에서 설정하고 실행할 수 있게 해주는 고급 AI 도구입니다. 이는 AI 기술의 민주화에 있어 중요한 발전으로, 사용자가 Llama 3나 gemma와 같은 언어 모델을 직접 활용할 수 있는 가능성을 제공합니다. 개발자, 연구자, 데이터 과학자에게 필수적인 다양한 자연어 처리(NLP) 애플리케이션에서 중요한 역할을 하는 'Ollama'는 가볍고 확장 가능한 프레임워크로, 복잡한 클라우드 기반 솔루션에 의존하지 않고도 모델의 기능을 로컬에서 직접 활용할 수 있도록 합니다. 이 도구는 언어 모델을 생성, 실행, 관리할 수 있는 간단한 API와 사전 구축된 모델 라이브러리를 제공하여 애플리케이션에 쉽게 통합할 수 있습니다. Ollama를 사용하면 Modelfile을 통해 모델 가중치, 구성, 데이터를 패키징하고 GPU 사용 등의 설정을 최적화할 수 있습니다.

2. Ollama 장점

- **로컬 실행:** 대규모 언어 모델의 로컬 실행 가능, 사용자에게 빠르고 효율적인 AI 처리 기능 제공
- **다양한 모델 지원:** (Meta)Llama3 , (Microsoft)Phi-3 , (Google)Gemma , mixtral, mistral ...
- **모델 커스터마이징:** 자신만의 모델을 자유롭게 커스터마이징하고 제작 가능
- **사용자 친화적인 인터페이스:** 도구의 디자인은 사용 편의성을 보장하여 빠르고 번거롭지 않은 설정 가능
- **다양한 시스템 환경 호환성:** macOS, Windows, Linux 지원

DeepSeek-R1-Distill-Qwen-1.5B테스트



DeepSeek-R1-Distill-Qwen-1.5B

```
ollama run deepseek-r1:1.5b
```

DeepSeek-R1-Distill-Qwen-7B

```
ollama run deepseek-r1:7b
```

DeepSeek-R1-Distill-Llama-8B

```
ollama run deepseek-r1:8b
```

DeepSeek-R1-Distill-Qwen-14B

```
ollama run deepseek-r1:14b
```

DeepSeek-R1-Distill-Qwen-32B

```
ollama run deepseek-r1:32b
```

DeepSeek-R1-Distill-Llama-70B

```
ollama run deepseek-r1:70b
```

Hugging Face 모델 카드 : <https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Qwen-1.5B>


프로그램 작성 에이전트 (DeepSeek_R1-Distill-Qwen-7B, Ollama)

Ollama 모델 리스트 : <https://ollama.com/library/deepseek-r1>

실습 링크 : https://colab.research.google.com/drive/1xmMfukXllliqaXWtebLjMh_la93xmzqi?usp=sharing


요약

- AI 활용 문턱을 낮추는 오픈 소스 모델
- 허깅페이스 : 인공지능 모델을 위한 깃허브
 - ✓ Models, Datasets, Spaces
 - ✓ Task에 적합한 모델 선택
 - ✓ 필요시 Fine Tuning을 위한 데이터셋 구성
 - ✓ MLOps 를 위한 Deployments 고려
- 속도와 정확 향상을 위한 새로운 아키텍처
 - ✓ MAMBA, SAMBA, JAMBA
 - ✓ Titans



- 오픈소스의 집단 지성과 협력
- 투명성과 보안 강화
- 다양한 분야로의 확장
- 기술 민주화 실현
- 기여 동기와 성장 기회
- 커뮤니티의 협력과 멘토링
- 혁신과 가능성의 확대

- 트랜스포머의 메모리, 속도 문제 개선 노력
 - ✓ RNN 의 기억 원리 : State Space Model
 - ✓ CNN 의 병렬 처리 : Parallel Scan
 - ✓ MAMBA : Selective State Space Model (S4)
- 트랜스포머와 MAMBA 결합
 - ✓ SAMBA, JAMBA
- 구글 Titans : 인간의 기억을 모방



감사합니다.