


교육 자료 Download



The screenshot displays the GitHub profile of user **swkang1062**. The profile includes a large circular avatar with a blue 'T' logo and the username **swkang1062** below it. The navigation bar shows **Overview** as the active tab, with **Repositories** (8), **Projects**, **Packages**, and **Stars** also visible. A search bar with the placeholder text "Type / to search" is located in the top right. Below the navigation bar, the **Popular repositories** section is displayed. It contains five repository cards, each with a title, description, and a "Public" label. The repository **Advanced_LLM_training** is highlighted with a red rectangular box. Below the repository list, there is a large empty rectangular area, also outlined with a red border.

Repository Name	Description	Language	Stars	Public
ChatGPT_Test	OpenAI API Test		1	Public
Test		Python	3	Public
HF_training				Public
Agent_Training				Public
Advanced_LLM_training				Public

강의 목표



허깅페이스
플랫폼 소개



다양한 AI
모델 활용



관련
기술 소개



최신 연구 동향

허깅페이스 기초

2025년 01월

- 허깅페이스(Hugging Face)
- 모델 사용하기
- 요약

허깅페이스(Hugging Face)



허깅페이스(Hugging Face) : AI Startup



2023년 8월 24일 - 경제

AI 스타트업 허깅페이스(Hugging Face)는 현재 45억 달러의 가치를 인정받고 있습니다.



기아 코칼라체바, 의 저자 [악시오스 프로 라타](#)

AI 개발을 위한 오픈 소스 도구 제공업체인 허깅페이스(Hugging Face)는 세일즈포스 벤처스(Salesforce Ventures)가 주도하는 45억 달러의 포트 머니 밸류에이션으로 시리즈 D 펀딩에서 2억 3,500만 달러를 조달했습니다.

중요한 이유: 뉴욕에 본사를 둔 이 회사는 성장하는 [AI 개발자 커뮤니티](#)의 중심에 있습니다.

- Hugging Face는 스스로를 "기계 학습을 위한 GitHub"라고 부릅니다.

그들이 말하는 것 : 허깅페이스의 공동 창립자이자 CEO인 클레망 들랑그(Clément Delangue)는 악시오스(Axios)와의 잠재적 경쟁에 대한 질문에 "[깃허브는] 코드에 매우 집중하고 있고, 우리는 AI에 매우 집중하고 있으며, 실제로 그들과 많은 협업을 하고 있다"고 말했다.

- 마이크로소프트 소유의 깃허브(GitHub)에 대한 델랑계의 걱정이 없어 보이는 것은 이 기술 대기업이 AI에 적극적으로 뛰어들 것을 감안할 때 주목할 만하다. 이미 [일부 제품에 이 기술을 배포](#)하고 있습니다([GitHub의 2년 된 AI 비서는 꽤 인기가 있습니다](#)).

큰 그림: Hugging Face의 마지막 펀딩 라운드는 2022년이었습니다. 올해 자금을 조달한 것은 인바운드 관심과 여름까지 2023년 사업 목표를 달성했기 때문이라고 Delangue는 말합니다.

- 포브스(Forbes)와 더 인포메이션(The Information)은 이 회사의 시리즈 D를 처음 보도했다.

확대: 세일즈포스(Salesforce)와 사운드 벤처스(Sound Ventures)와 함께 허깅페이스의 새로운 후원자로는 구글(Google), 아마존(Amazon), 엔비디아(Nvidia), 인텔(Intel), AMD, 퀄컴(Qualcomm), IBM(IBM) 등 주요 기술 기업들이 다수 포함되어 있다.

- "과거에는 전통적인 VC의 길을 더 많이 갔지만, 우리가 정말 흥분한 것은 생태계 라운드를 할 수 있는 능력입니다"라고 Delangue는 설명합니다. "그것은 중립적인 플랫폼으로서 우리의 위치를 공고히합니다 또는 스위스 ... AI를 위해."
- 들랑그는 새로운 자금 조달이 [일부 AI 회사들이](#) 체결한 거래와 달리 기술 자원이나 기업 후원자에 대한 다른 조건에 대한 특별한 접근을 제공하지 않는다고 지적했다.

숫자로 : 이 회사는 현재 500,000개의 모델, 250,000개의 데이터 세트 및 250,000개의 앱을 호스팅하고 있으며 2024년에 그 수를 세 배로 늘리는 것을 목표로 하고 있다고 말합니다.

- 최근 리포지토리 100만 개를 넘어섰으며 내년에는 "수천만 개"에 도달하는 것을 목표로 하고 있습니다.
- Forbes는 2021년에 1,000만 달러의 매출을 올렸고 현재 연간 매출은 3,000만 달러에서 5,000만 달러 사이라고 [보고](#)했습니다. Delangue는 구체적인 수치에 대한 언급을 거부했지만 올해 매출이 5배 증가했으며 현재 10,000명의 유료 고객(엔터프라이즈 기능 판매)을 보유하고 있다고 말했습니다.
- 매출 성장은 더 많은 유료 고객([3월 말 기준 약 3,000명](#))을 확보하고 지출을 늘린 결과입니다.

결론: AI 기업에 대한 괴물 밸류에이션의 메가 라운드가 거의 끝나지 않았습니다.

허깅페이스(Hugging Face) : 미래를 건설하는 AI 커뮤니티



Hugging Face

<https://huggingface.co> ▼



Hugging Face – The AI community building the future.

웹 Give your team the most advanced platform to build AI with enterprise-grade security, access controls and dedicated support. Getting started. Starting at \$20/user/month. Single Sign-On ...

Models

Models - Hugging Face – The AI community building the future.

Datasets

Datasets - Hugging Face – The AI community building the future.

Spaces

Hugging Face. Models; Datasets; Spaces; Posts; Docs; Solutions Pricing Log In ...

Docs

Fast training and inference of HF Transformers with easy to use hardware ...

Pricing

Leveling up AI collaboration and compute. Users and organizations already use the ...

Log In

Log In - Hugging Face – The AI community building the future.

Sign Up

Hugging Face – The AI community building the future.

Stabilityai Stable-Diffusion-X...

Stabilityai Stable-Diffusion-XI-Base-1.0 - Hugging Face – The AI community ...



포옹하는 얼굴

<https://huggingface.co> ▼



Hugging Face - 미래를 건설하는 AI 커뮤니티.

웹 엔터프라이즈급 보안, 액세스 제어 및 전담 지원을 통해 AI를 구축할 수 있는 가장 진보된 플랫폼을 팀에 제공하십시오. 시작. 사용자당 월 \$20부터 시작합니다. 싱글 사인온...

모델

모델 - Hugging Face - 미래를 건설하는 AI 커뮤니티.

데이터

데이터 세트 - Hugging Face - 미래를 구축하는 AI 커뮤니티.

공간

포옹하는 얼굴. 모델; 데이터; 공간; 게시물; 문서; 솔루션 가격 로그인 ...

문서

사용하기 쉬운 하드웨어로 HF 변압기의 빠른 교육 및 추론 ...

가격

AI 협업 및 컴퓨팅 수준을 높입니다. 사용자와 조직은 이미 ...

로그인

로그인 - 허깅페이스 - 미래를 건설하는 AI 커뮤니티.

등록하세요

Hugging Face - 미래를 건설하는 AI 커뮤니티.

Stabilityai 안정 확산 -X ...

Stabilityai Stable-Diffusion-XI-Base-1.0 - 허깅 페이스 - AI 커뮤니티 ...

허깅페이스(Hugging Face)



- 트랜스포머 모델 등 다양한 AI 모델, 데이터 셋 등을 공유할 수 있는 플랫폼
- 인공지능 모델을 위한 깃허브
 - ✓ 모델(Model) : 훈련된 모델을 공유 - [Models - Hugging Face](#)
 - ✓ 데이터셋(Datasets) : 훈련 데이터 공유 - [Hugging Face – The AI community building the future.](#)
 - ✓ 스페이스(Spaces) : 머신러닝 앱 테스트 공간 - [Spaces - Hugging Face](#)



Stable Diffusion 2.1 Demo

Stable Diffusion 2.1 is the latest text-to-image model from StabilityAI. [Access Stable Diffusion 1 Space here](#)
For faster generation and API access you can try [DreamStudio Beta](#).

A cute baby cat with glasses

Enter a negative prompt

Generate image

안경 낀 귀여운 새끼 고양이

Enter a negative prompt

Generate image



등록된 AI 모델 143만개...개발자들이 교류하는 플랫폼

| 세계 최대 AI 플랫폼 '허깅 페이스'

기사전송 2025-02-20 00:36 최종수정 2025-02-20 10:20

중국 스타트업 딥시크가 지난달 말 인공지능(AI) 언어 모델 'R1'을 공개하자마자 세계적으로 화제가 될 수 있었던 배경에는 한 사이트가 있다. 전 세계 오픈소스 AI 모델이 한데 모이는 '허깅 페이스(Hugging Face)'다. 오픈소스는 소프트웨어 설계도라 할 수 있는 '소스코드'를 대외적으로 공개해 누구나 내려받아 수정·배포할 수 있게 개방하는 것을 말한다. 딥시크는 자신들이 개발한 AI 모델을 늘 허깅 페이스에 공개하고 교류하며 기술력을 끌어올렸고, 연구자나 개발자들이 모델 아키텍처(구조)와 가중치를 직접 살펴볼 수 있게 한 덕분에 기술력을 빠르게 인정받았다.

허깅 페이스에 등록된 AI 모델은 현재 143만개에 달한다. AI를 학습시키는 데 사용하는 데이터 뭉치도 30만개 이상 업로드돼 있다. 개발자라면 누구나 쉽게 이곳에서 AI 모델을 무료로 내려받을 수 있고, 원하는 언어와 분야별 특화된 데이터 뭉치로 학습시켜 자신만의 AI 모델로 개량할 수 있다. 전 세계 AI 개발자들이 허깅 페이스에 몰리는 배경이다. 딥시크 R1만 해도 공개한 지 채 한 달밖에 되지 않았지만 다운로드 수는 406만회에 달한다.

허깅 페이스는?

창업 연도·본사	2016년·미국 뉴욕
창업자	클레망 들랑그, 줄리앙 쇼몽, 토마스 울프(프랑스 기업가)
주요 사업	오픈소스 기반 AI 모델 공유 라이브러리 운영
기업 가치	45억달러(약 6조4900억원)
누적 투자 유치액	3억9600만달러(약 5700억원)
주요 투자자	세쿼이아캐피털·구글·엔비디아·아마존·AMD·인텔·IBM·퀄컴·세일즈포스 등

Meta Llama 3 릴리즈: GPT4급 Open-Source 모델의 탄생

daewoo kim · Follow
11 min read · Apr 21, 2024

Llama 3의 성능


Llama3는 이전 세대인 Llama2에 비해 모든 벤치마크에서 대폭적인 도약을 이루었다.

Base pretrained models (Llama2 vs Llama3)

- **Llama3 70B:** 모든 모델 벤치마크에서 Llama3 70B의 성능을 증가한다.
- **Llama3 8B:** 모든 모델 벤치마크에서 Llama2 7B, 13B보다 더 우수한 성능을 보인다. BoolQ 벤치마크의 경우, Llama3 8B이 Llama2 70B보다 더 우수한 성능을 나타낸다.

Category	Benchmark	Llama2 7B	Llama2 13B	Llama2 70B	Llama 3 8B	Llama 3 70B
General	MMLU (5-shot)	45.7	53.8	69.7	66.6	79.5
	AGIEval English (3-5 shot)	28.8	38.7	54.8	45.9	63
	CommonSenseQA (7-shot)	57.6	67.6	78.7	72.6	83.8
	Winogrande (5-shot)	73.3	75.4	81.8	76.1	83.1
	BIG-Bench Hard (3-shot, CoT)	38.1	47	65.7	61.1	81.3
	ARC-Challenge (25-shot)	53.7	67.6	85.3	78.6	93
Knowledge reasoning	TriviaQA-Wiki (5-shot)	72.1	79.6	87.5	78.5	89.7
Reading comprehension	SQuAD (1-shot)	72.2	72.1	82.6	76.4	85.6
	QuAC (1-shot, F1)	39.6	44.9	49.4	44.4	51.1
	BoolQ (0-shot)	65.5	66.9	73.1	75.7	79
	DROP (3-shot, F1)	37.9	49.8	70.2	58.4	79.7

Base Pretrained Models(Llama2 vs Llama3)



Meta Llama 3 Instruct Human Evaluation

Pre-training 시 scaling law 개발

Meta는 downstream 벤치마크 평가를 위해 일련의 scaling law을 개발하였다. 이 scaling law를 통해 모델을 실제로 학습하기 전에 주요 task(e.g. HumanEval 벤치마크)에 대해 가장 큰 모델의 성능을 예측할 수 있었다.

새로운 관찰 결과

Meta는 Llama3 개발 시 scaling law에 대한 새로운 사실을 관찰하였다.

- Chinchilla-optimal에 따라 8B 모델의 최적 학습 토큰량은 약 200B 개지만, 200B보다 더 많은 토큰을 학습하였을 때 모델 성능은 계속 증가한다.
- Llama3 8B, 70B를 최대 15T 토큰으로 학습하였을 때 모델 성능 로그 선형적으로 계속 개선되었다.

LLM 선택 : LLM 모델 계통도






Fig. 1. The evolutionary tree of modern LLMs traces the development of language models in recent years and highlights some of the most well-known models. Models on the same branch have closer relationships. Transformer-based models are shown in non-grey colors: decoder-only models in the blue branch, encoder-only models in the pink branch, and encoder-decoder models in the green branch. The vertical position of the models on the timeline represents their release dates. Open-source models are represented by solid squares, while closed-source models are represented by hollow ones. The stacked bar plot in the bottom right corner shows the number of models from various companies and institutions.

[용어] Encoder, Decoder, Encoder-Decoder 모델



Hugging Face Models



모델 찾기 : Tasks



작업

Hugging Face Search models, datasets

Models Datasets Spaces Docs Enterprise Pricing

Tasks Libraries Datasets Languages Licenses Other

Filter Tasks by name

Multimodal

- Audio-Text-to-Text
- Image-Text-to-Text
- Visual Question Answering
- Document Question Answering
- Video-Text-to-Text
- Any-to-Any

Computer Vision

Models 1,165,879 Filter by name Full-text search Sort: Trending

- Qwen/QwQ-32B-Preview**
Text Generation • Updated 2 days ago • 14.8k • 783
- AIDC-AI/Marco-o1**
Text Generation • Updated 8 days ago • 7.51k • 565
- Lightricks/LTX-Video**
Image-to-Video • Updated 8 days ago • 26.8k • 499
- Djirango/Qwen2vl-Flux**

모델 찾기 : 대표적인 tasks



Task	대표 모델	설명
자연어 처리 (NLP)	BERT, GPT, T5	텍스트 생성, 문장 분류, 질의응답, 기계번역 등 다양한 NLP 작업에 활용.
기계 번역	Transformer (원 논문)	영어-프랑스어, 영어-독일어 등 기계 번역 작업.
텍스트 요약	T5, PEGASUS	문서 요약 및 추출 기반 요약.
텍스트 생성	GPT 시리즈, OPT, LLaMA	고품질 텍스트 생성, 대화 모델 등.
감성 분석	BERT, RoBERTa	문장의 감정이나 톤을 분류하는 작업.
질의 응답 (QA)	ALBERT, BERT, T5	사용자의 질문에 적절한 답변 생성.
자연어 추론 (NLI)	RoBERTa, DeBERTa	두 문장의 논리적 관계를 분석 (모순, 중립, 함의).

음성 인식	Wav2Vec, Whisper	음성 데이터를 텍스트로 변환.
이미지 생성	DALL-E, Stable Diffusion	텍스트 기반 이미지 생성.
이미지 분류	ViT (Vision Transformer), Swin	Transformer를 활용한 이미지 분류.
물체 검출	DETR (Detection Transformer)	Transformer 기반의 객체 검출.
비디오 이해	TimeSformer, Video Swin Transformer	비디오 데이터의 의미를 분석.
멀티모달 작업	CLIP, Flamingo	이미지와 텍스트를 동시에 처리하여 문맥 이해.
추천 시스템	SASRec, BERT4Rec	사용자 행동 시퀀스를 기반으로 추천 시스템을 구현.
강화 학습	Decision Transformer	시퀀스 모델링으로 강화 학습 작업 수행.

● 작업

Hugging Face는 모든 기계 학습 작업을 위한 홈입니다. 여기에서 시작하는 데 필요한 것을 찾을 수 있습니다. 작업: 데모, 사용 사례, 모델, 데이터 세트 등!

복합



**임의-임의-임의
(any-to-any)**
7,463개 모델

기여하다 🍌



**오디오-텍스트-
텍스트 변환**
107 모델



문서 질문 답변
231 모델



**시각적 문서 검
색**
71 모델



**이미지 텍스트-
텍스트**
5,154개 모델



**비디오 텍스트-
텍스트**
163 모델



**시각적 질문 답
변**
504 모델

자연어 처리



특징 추출
13,923개 모델



필 마스크
15,181 모델



질문 답변
12,856개 모델



문장 유사성
12,279 모델



요약
2,432개 모델



**테이블 질문 답
변**
160개 모델



텍스트 분류
98,662 모델



텍스트 생성
267,691 모델



텍스트 순위
463 모델

모델 찾기 : Task page



Image-to-Image

Image-to-image is the task of transforming an input image to possible manipulations and enhancements, such as super-resolution, inpainting, colorization, and more.

Inputs




Image-to-Image Model

About Image-to-Image

Compatible libraries

fal/AuraSR-v2

Image-to-Image Transformers Safetensors PyTorch art super-resolution License: apache-2.0

Model card Files and versions Community 16

AuraSR-v2



Downloads last month
2,474

Safetensors Model size 618M params Tensor type F32 Files info

Inference Providers NEW

Image-to-Image

This model isn't deployed by any Inference Provider. Ask for provider support

Spaces using fal/AuraSR-v2 22

- gokaygokay/AuraSR-v2
- rupeshs/fastdcpu
- ZENLLC/AuraUpscale
- nikitatupitsyn/iconDDDzilla
- yuyutsu07/Pseudo3D
- nikitatupitsyn/iconDDDzilla_test
- nikitatupitsyn/iconDDDzilla_bot_backend
- tejani/Another
- philipp-zettl/OS-upscaler-AuraSR
- takarajordan/flux-lightning
- ardha27/AuraSR-v2
- Rooc/flux-lightning
- + 10 Spaces

Collection including fal/AuraSR-v2

모델 찾기 : Open LLM Leaderboard





Open LLM Leaderboard Archived

Comparing Large Language Models in an open and reproducible way

786 / 4576ResetAdvanced Filters?

Supports strict search and regex • Use semicolons for multiple terms

Quick FiltersFor Edge Devices - 786For Consumers - 430Mid-range - 3185For the GPU-rich - 165☐ Only Official Providers - 470

table optionscolumn visibility

	Rank	Type	Model	Average	IFEval	BBH	MATH	GPQA	MUSR	MMLU-PRO	CO ₂ Cost
푸	1379	🗨️	LGAI-EXAONE/EXAONE-3.5-2.4B-Instruct	27.14 %	79.50 %	15.95 %	36.78 %	2.13 %	3.17 %	25.34 %	1.21 kg
푸	1551	🔴	qingy2024/Benchmaxx-Llama-3.2-1B-Instruct	25.70 %	20.14 %	76.70 %	48.04 %	4.47 %	3.58 %	1.25 %	0.31 kg
푸	1865	🔴	iFaz/llama32_3B_en_emo_2000_stp	23.91 %	73.69 %	23.42 %	15.33 %	4.47 %	3.25 %	23.31 %	0.90 kg
푸	1909	🔴	iFaz/llama32_3B_en_emo_300_stp	23.75 %	72.56 %	22.94 %	16.01 %	3.24 %	3.89 %	23.87 %	0.87 kg
푸	1934	🔴	iFaz/llama32_3B_en_emo_1000_stp	23.65 %	72.95 %	23.11 %	14.65 %	3.69 %	3.89 %	23.59 %	0.90 kg

- 성능이 높은 모델 빠르게 찾기 ➡ 필터 사용

모델 찾기 : Open LLM Leaderboard



Advanced Filters

Precision format ⓘ
☐ bfloat16 · 3423 ☒ float16 · 1151 ☐ 4bit · 2

Model Type ⓘ
☒ Pretrained · 333 ☐ Continuously Pretrained · 0
☐ Fine-tuned · 1785 ☒ Chat · 718
☐ Merge · 1724 ☒ Multimodal · 9

Parameters ⓘ
11 39
All 7B 70B 140B

Flags ⓘ
☒ Mixture of Experts · 76 ☒ Merged model · 715
☒ Potentially contaminated model · 1
☐ Unavailable model · 1683

Official Models

Show only models that are officially provided and maintained by their original creators.

☐ Only Official Providers · 470

• Filter inactive

table options column visibility

	Rank	Type	Model	Average ⓘ	IFEval ⓘ	BBH ⓘ	MATH ⓘ	GPQA ⓘ	MUSR ⓘ	MMLU-PRO ⓘ	CO ₂ Cost ⓘ
푸	100	🗨️	jpacifico/Chocolatine-14B-Instruct-DPO-v1.3	● 42.42 %	70.40 %	54.85 %	56.19 %	12.19 %	12.29 %	48.60 %	1.70 kg
푸	276	🗨️	Qwen/Qwen2.5-Coder-32B-Instruct	● 39.89 %	72.65 %	52.27 %	49.55 %	13.20 %	13.72 %	37.92 %	9.39 kg
푸	435	🗨️	LGAI-EXAONE/EXAONE-3.5-32B-Instruct	● 37.60 %	83.92 %	39.82 %	51.28 %	5.03 %	5.15 %	40.41 %	31.00 kg
푸	740	🗨️	jpacifico/Chocolatine-14B-Instruct-DPO-v1.2	● 33.80 %	68.52 %	49.85 %	20.92 %	10.07 %	12.35 %	41.07 %	3.08 kg

- 성능이 높은 모델 빠르게 찾기 ➔ 필터 사용

모델 찾기 : Libraries



사용 라이브러리

Hugging Face Search models, dataset Models Datasets Spaces Docs Enterprise Pricing

Tasks **Libraries 2** Datasets Languages Licenses Other

Filter Libraries by name Reset Libraries

PyTorch TensorFlow JAX Transformers Safetensors PEFT TensorBoard GGUF Diffusers stable-baselines3 ONNX sentence-transformers ml-agents TF-Keras Adapters setfit timm sample-factory MLX MLX Flair Keras Transformers.js OpenVINO spaCy fastai ESPnet Joblib NeMo Core ML BERTopic TF Lite

Models 172,494 Filter by name Full-text search Sort: Trending

- meta-llama/Llama-3.2-1B
Text Generation • Updated Oct 25 • 1.58M • 1.08k
- meta-llama/Llama-3.1-8B-Instruct
Text Generation • Updated Sep 26 • 6.62M • 3.15k
- briiaai/RMBG-2.0
Image Segmentation • Updated 11 days ago • 53.7k • 456
- jinaai/jina-clip-v2
Feature Extraction • Updated 1 day ago • 5.61k • 89
- meta-llama/Llama-3.2-3B-Instruct

모델 찾기 : Datasets



사용 데이터셋

Hugging Face Search models, dataset Models Datasets Spaces Docs Enterprise Pricing

Tasks Libraries **Datasets** Languages Licenses Other

Filter Datasets by name

- mozilla-foundation/common_voice_7_0
- mozilla-foundation/common_voice_11_0
- HuggingFaceH4/ultrafeedback_binarized
- teknium/OpenHermes-2.5
- cis-lmu/Glot500
- HuggingFaceH4/ultrachat_200k
- fka/awesome-chatgpt-prompts
- allenai/MADLAD-400
- Open-Orca/OpenOrca
- marsyas/gtzan
- allenai/c4
- LDJnr/Capybara

Models 1,165,923 Filter by name Full-text search Sort: Trending

- Qwen/QwQ-32B-Preview**
Text Generation • Updated 2 days ago • 14.8k • 785
- AIDC-AI/Marco-o1**
Text Generation • Updated 8 days ago • 7.51k • 565
- Lightricks/LTX-Video**
Image-to-Video • Updated 8 days ago • 26.8k • 500
- Djrango/Qwen2v1-Flux**
Text-to-Image • Updated 4 days ago • 280

모델 찾기 : Languages



지원 언어

Hugging Face Search models, datasets, spaces, docs, enterprise, pricing

Tasks Libraries Datasets **Languages 2** Licenses Other

Filter Languages by name Reset Languages

English × Chinese French German Spanish Japanese Korean × Italian Portuguese Russian Hindi Arabic Thai Indonesian Polish Turkish Dutch Vietnamese multilingual Finnish Romanian Swedish Czech Persian Ukrainian Greek Danish Catalan Bengali Hebrew Bulgarian Tamil Hungarian Swahili

Models 2,770 Filter by name Full-text search Sort: Trending

- OuteAI/OuteTTS-0.2-500M
Text-to-Speech • Updated 2 days ago • 7.73k • 196
- OuteAI/OuteTTS-0.2-500M-GGUF
Text-to-Speech • Updated 2 days ago • 3.1k • 57
- mistralai/Pixtral-Large-Instruct-2411
Updated 11 days ago • 382 • 345
- jinaai/jina-clip-v2
Feature Extraction • Updated 1 day ago • 5.61k • 89
- openai/whisper-large-v3

모델 찾기 : Licenses



라이선싱 방식

Hugging Face Search models, datasets, spaces, docs, enterprise, pricing

Tasks Libraries Datasets Languages **Licenses** Other

Filter Licenses by name

- apache-2.0 mit other openrail
- creativeml-openrail-m cc-by-nc-4.0 llama2
- llama3 cc-by-4.0 openrail++ gemma
- llama3.1 cc-by-nc-sa-4.0 afl-3.0
- cc-by-sa-4.0 gpl-3.0 llama3.2 cc
- artistic-2.0 bsd-3-clause
- bigscience-openrail-m bigscience-bloom-rail-1.0
- cc-by-nc-nd-4.0 bigcode-openrail-m wtfpl
- agpl-3.0 cc0-1.0 unlicense

Models 1,165,927 Filter by name Full-text search Sort: Trending

- Qwen/QwQ-32B-Preview
Text Generation • Updated 2 days ago • 14.8k • 785
- AIDC-AI/Marco-o1
Text Generation • Updated 8 days ago • 7.51k • 565
- Lightricks/LTX-Video
Image-to-Video • Updated 8 days ago • 26.8k • 500
- Djrrango/Qwen2v1-Flux
Text-to-Image • Updated 4 days ago • 280
- black-forest-labs/FLUX.1-dev

대표적인 오픈소스 라이선스 정책



라이선스	주요 특징	소스코드 공개 의무	상업적 사용 가능 여부	복제(left) 조항
MIT License	자유롭게 사용, 수정, 배포 가능. 저작권 및 라이선스 표시 유지 필수.	없음	가능	없음
Apache License 2.0	특허 사용 허가 포함, 변경 내용 명시 필수, 상표권 보호는 제외.	없음	가능	없음
GPL (General Public License)	수정 및 배포 시 동일한 GPL 유지 필수. 소스코드 공개 의무.	필수	가능	강함
LGPL (Lesser GPL)	GPL 완화 버전. 라이브러리 사용 시 소스 공개 의무 없음. 수정 시 공개 필요.	수정된 라이브러리만 필수	가능	약함
BSD License	사용, 수정, 배포 가능. 저작권 및 라이선스 표시 유지. 일부 버전은 광고 문구 요구.	없음	가능	없음

라이선스	주요 특징	소스코드 공개 의무	상업적 사용 가능 여부	복제(left) 조항
Creative Commons (CC)	콘텐츠 전용. 저작자 표시, 비상업적 사용, 변경 금지 등 조건 설정 가능.	조건에 따라 다름	조건에 따라 다름	없음
MPL (Mozilla Public License)	소스코드 파일 단위로 공개 의무. 독립적인 부분은 비공개 가능.	수정된 파일만 필수	가능	약함
EPL (Eclipse Public License)	수정된 소스코드 공개 의무. 특허 조항 포함.	필수	가능	약함
AGPL (Afero GPL)	네트워크 제공 소프트웨어도 소스코드 공개 필수. 클라우드 환경에 적합.	필수	가능	강함
Unlicense	퍼블릭 도메인 배포. 사용, 수정, 배포에 제한 없음.	없음	가능	없음

대표적인 오픈소스 라이선스 정책



GNU AGPLv3

Permissions of this strongest copyleft license are conditioned on making available complete source code of licensed works and modifications, which include larger works using a licensed work, under the same license. Copyright and license notices must be preserved. Contributors provide an express grant of patent rights. When a modified version is used to provide a service over a network, the complete source code of the modified version must be made available.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- Disclose source
- License and copyright notice
- Network use is distribution
- Same license
- State changes

Limitations

- Liability
- Warranty

[View full GNU Affero General Public License v3.0 »](#)

GNU GPLv3

Permissions of this strong copyleft license are conditioned on making available complete source code of licensed works and modifications, which include larger works using a licensed work, under the same license. Copyright and license notices must be preserved. Contributors provide an express grant of patent rights.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- Disclose source
- License and copyright notice
- Same license
- State changes

Limitations

- Liability
- Warranty

[View full GNU General Public License v3.0 »](#)

GNU LGPLv3

Permissions of this copyleft license are conditioned on making available complete source code of licensed works and modifications under the same license or the GNU GPLv3. Copyright and license notices must be preserved. Contributors provide an express grant of patent rights. However, a larger work using the licensed work through interfaces provided by the licensed work may be distributed under different terms and without source code for the larger work.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- Disclose source
- License and copyright notice
- Same license (library)
- State changes

Limitations

- Liability
- Warranty

[View full GNU Lesser General Public License v3.0 »](#)

Mozilla Public License 2.0

Permissions of this weak copyleft license are conditioned on making available source code of licensed files and modifications of those files under the same license (or in certain cases, one of the GNU licenses). Copyright and license notices must be preserved. Contributors provide an express grant of patent rights. However, a larger work using the licensed work may be distributed under different terms and without source code for files added in the larger work.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- Disclose source
- License and copyright notice
- Same license (file)

Limitations

- Liability
- Trademark use
- Warranty

[View full Mozilla Public License 2.0 »](#)

Apache License 2.0

A permissive license whose main conditions require preservation of copyright and license notices. Contributors provide an express grant of patent rights. Licensed works, modifications, and larger works may be distributed under different terms and without source code.

Permissions

- Commercial use
- Distribution
- Modification
- Patent use
- Private use

Conditions

- License and copyright notice
- State changes

Limitations

- Liability
- Trademark use
- Warranty

[View full Apache License 2.0 »](#)

MIT License

A short and simple permissive license with conditions only requiring preservation of copyright and license notices. Licensed works, modifications, and larger works may be distributed under different terms and without source code.

Permissions

- Commercial use
- Distribution
- Modification
- Private use

Conditions

- License and copyright notice

Limitations

- Liability
- Warranty

[View full MIT License »](#)

Boost Software License 1.0

A simple permissive license only requiring preservation of copyright and license notices for source (and not binary) distribution. Licensed works, modifications, and larger works may be distributed under different terms and without source code.

Permissions

- Commercial use
- Distribution
- Modification
- Private use

Conditions

- License and copyright notice for source

Limitations

- Liability
- Warranty

[View full Boost Software License 1.0 »](#)

The Unlicense

A license with no conditions whatsoever which dedicates works to the public domain. Unlicensed works, modifications, and larger works may be distributed under different terms and without source code.

Permissions

- Commercial use
- Distribution
- Modification
- Private use

Conditions

Limitations

- Liability
- Warranty

[View full The Unlicense »](#)

모델 찾기 : 기타



기 타

Warm 모델:
즉시 사용 가능

Cold 모델:
필요 시 로딩

Frozen 모델:
API로 실행할 수 없음

The screenshot shows the Hugging Face homepage. A red arrow points from the Korean text '기 타' to the 'Other' button in the left sidebar. The sidebar also shows 'Tasks', 'Libraries', 'Datasets', 'Languages', and 'Licenses'. The 'Other' button is highlighted with a red box. Below it, the 'Inference status' section shows three buttons: 'Warm' (orange), 'Cold' (blue), and 'Frozen' (grey). The 'Warm' button is also highlighted with a red box. Below the 'Inference status' section, the 'Misc' section shows various filters: 'Inference Endpoints', 'AutoTrain Compatible', 'text-generation-inference', 'Eval Results', '4-bit precision', 'Merge', 'text-embeddings-inference', 'custom_code', '8-bit precision', 'Carbon Emissions', and 'Mixture of Experts'. The main content area shows a list of models, including 'Qwen/QwQ-32B-Preview', 'AIDC-AI/Marco-o1', 'Lightricks/LTX-Video', 'Django/Qwen2vl-Flux', and 'black-forest-labs/FLUX.1-dev'.

실습 : 5분

한국어를 지원하는
상업적 이용 가능한
STT (Speech To Text) 모델 찾기

데이터셋(datasets)




- dataset download

```
1 from datasets import load_dataset
2
3 str_dataset = "yelp_review_full"
4 # dataset = load_dataset(str_dataset)
5
6 # or load the separate splits if the dataset has train/validation/test splits
7 train_dataset = load_dataset(str_dataset, split="train")
8 # valid_dataset = load_dataset(str_dataset, split="validation")
9 test_dataset = load_dataset(str_dataset, split="test")
```

예제 : https://colab.research.google.com/drive/17rAF6KwD_0R1oE5V8X6MOhXjA89Io4Y6#scrollTo=FduMZ9wQqC6A

- 데이터셋의 상세 내용은 데이터셋 카드(Dataset Card)에서 확인



Data Fields

- 'text': The review texts are escaped using double quotes ("), and any internal double quote is escaped by 2 double quotes ("). New lines are escaped by a backslash followed with an "n" character, that is "\n".
- 'label': Corresponds to the score associated with the review (between 1 and 5).

Data Splits

The Yelp reviews full star dataset is constructed by randomly taking 130,000 training samples and 10,000 testing samples for each review star from 1 to 5. In total there are 650,000 training samples and 50,000 testing samples.

Datasets:  **microsoft/rStar-Coder**   like 185  Follow  Microsoft 14.1k  Dataset card  Data Studio

Subset (5)
seed_sft · 592k rows

Split (1)
train · 592k rows

Search this dataset

question_id string	question string	starter_code string	response string	code string	verified bool	is_p bool
seed_0	Chef has a cubic die with 6 faces kept on an infinite plane. Each face has a distinct integer in the range [1,6] written on it, but the exact arrangement of the numbers on the faces of the die is unknown to Chef. Curiosity gets the better of		Okay, so I need to solve this problem where Chef rolls a die multiple times and records the top faces each time. The goal is to figure out the opposite faces of the die. Hmm, let's see how to approach this. The key is to model the die's possible configurations after each step, considering all possible directions the die could have been rolled. Since each roll is a 90-degree turn in one of four directions (like north, south, east, west?), but the direction is unknown, each step's transition between the current top and next top depends on the die's current orientation. First, I need to figure out how the die's top, front, and other faces change when it rolls in a direction. Wait, but maybe there's a standard way to model the die's state. Let's think of the die as having a current top face, front face, etc. However, direction is ambiguous here. Alternatively, perhaps the key is to track the current top and bottom faces, along with the	<pre>def generate_all_pairings(): nums = [1, 2, 3, 4, 5, 6] all_pairings = [] def backtrack(remaining, current): if not remaining: all_pairings.append(current.copy()) return first = remaining[0] for i in range(1, len(remaining)): pair = (first, remaining[i]) new_remaining = remaining[1:i] + remaining[i+1:] current.append(pair) backtrack(new_remaining, current) current.pop() backtrack(nums, []) # Deduplicate by sorting pairs and lists unique = set() for p in all_pairings:</pre>	false	

예시 링크 : https://huggingface.co/datasets/microsoft/rStar-Coder/viewer/seed_sft/train?row=0&views%5B%5D=seed_sft

함수호출(Function Calling) 훈련 데이터



Datasets: Salesforce/xlam-function-calling-60k

Split (1)
train · 60k rows

Search this dataset

id int64	query string · lengths	answers string · lengths	tools string · lengths
0-6k	16-148	33-509	153-1.13k
10%	80.1%	99.8%	56.8%
21	Fetch detailed information about a product with ID 12345.	[{"name": "get_product", "arguments": {"is_id": 12345}}]	[{"name": "facebook_ad_copy", "description": "Generates a Facebook ad copy using AI based on the provided description and name.", "parameters": {"description": {"description": "The description to be used for generating the ad copy.", "type": "str", "default": "Apple designs, manufactures and markets smartphones, personal computers, tablets, wearables and accessories, and sells a variety of related services."}, "name": {"description": "The name to be used for generating the ad copy.", "type": "str", "default": "Apple"}}}, {"name": "get_product", "description": "Fetches product details from a RapidAPI endpoint using the provided product ID and RapidAPI key.", "parameters": {"is_id": {"description": "The ID of the product to retrieve information about.", "type": "int", "default": ""}}}]
22	Could you fetch recommendations for experiment 24680 in the technology...	[{"name": "recommend", "arguments": {"experiment_id": 24680}}]	[{"name": "recommend", "description": "Fetches a recommendation for a given experiment ID using the..."}]
	Can you fetch the location details	[{"name": "location", "arguments": ...}]	[{"name": "location", "description": "Fetches the..."}]

예시 링크 : <https://huggingface.co/datasets/Salesforce/xlam-function-calling-60k/viewer/dataset/train?views%5B%5D=train&row=21>

SUM (Synthetic Unanswerable Math) 훈련 데이터



Datasets: lime-nlp/Synthetic_Unanswerable_Math like 13 Follow Language, Intelligence,... 11 Dataset card Data Studio		
Split (2) train · 36.5k rows		
Search this dataset		
answerable_question string · lengths	unanswerable_question string · lengths	ground_truth string · lengths
 7↔410 89.5%	 4↔224 61.1%	 1↔124 100%
The operation $\otimes$ is defined for all nonzero numbers by a $\otimes$ b = a^2/b . Determine $[(1 \otimes 2) \otimes 3] - [1 \otimes (2 \otimes 3)]$.	The operation $\otimes$ is used to combine two nonzero numbers. Determine $[(1 \otimes 2) \otimes 3] - [1 \otimes (2 \otimes 3)]$.	$-\frac{2}{3}$
Doug constructs a square window using 8 equal-size panes of glass. The ratio of the height to width for each pan...	Doug constructs a square window using equal-size panes of glass. The ratio of the height to width for each pan...	26
Let P(x) be a polynomial of degree 3n such that P(0) = P(3) = ... = P(3n) = 2, P(1) = P(4) = ... = P(3n+1-2) =...	Let P(x) be a polynomial of degree 3n such that P(0) = P(3) = ... = P(3n) = 2, P(1) = P(4) = ... = P(3(n-1)+1)...	1
At Euclid Middle School the mathematics teachers are Mrs. Germain, Mr. Newton, and Mrs. Young. There are \$11...	At Euclid Middle School the mathematics teachers are Mrs. Germain, Mr. Newton, and Mrs. Young. In Mrs. ...	28
If $991+993+995+997+999=5000-N$, then N=	If $991 + 993 + p + 997 + 999 = 5000 - N$, then N equals what, given that p is an unspecified number?	25
The total in-store price for an appliance is \$99.99\$. A television commercial advertises the same product for...	The total in-store price for an appliance is \$99.99\$. A television commercial advertises the same product for...	7

예시 링크 : https://huggingface.co/datasets/lime-nlp/Synthetic_Unanswerable_Math/viewer/synthetic_unanswerable_math/train?views%5B%5D=train&row=0

추론 훈련 데이터



Datasets: openai/gsm8k like 830 Follow OpenAI 16.8k Dataset card	
Subset (2) main · 8.79k rows	Split (2) train · 7.47k rows
Search this dataset	
question string · lengths  137-232 46%	answer string · lengths  50-168 19.9%
Natalia sold clips to 48 of her friends in April, and then she sold half as many clips in May. How many clips did Natalia sell altogether in April and May?	Natalia sold $48/2 = 24$ clips in May. Natalia sold $48+24 = 72$ clips altogether in April and May. ### 72
Weng earns \$12 an hour for babysitting. Yesterday, she just did 50 minutes of babysitting. How much did she earn?	Weng earns $12/60 = 0.2$ per minute. Working 50 minutes, she earned $0.2 \times 50 = 10$. ### 10
Betty is saving money for a new wallet which costs \$100. Betty has only half of the money she needs. Her parents decided to give her...	In the beginning, Betty has only $100 / 2 = 50$. Betty's grandparents gave her $15 \times 2 = 30$. This means, Betty...
Julie is reading a 120-page book. Yesterday, she was able to read 12 pages and today, she read twice as many pages as yesterday. If she...	Maila read $12 \times 2 = 24$ pages today. So she was able to read a total of $12 + 24 = 36$ pages since yesterday...
James writes a 3-page letter to 2 different friends twice a week. How many pages does he write a year?	He writes each friend $3 \times 2 = 6$ pages a week So he writes $6 \times 2 = 12$ pages every week That means he writes $12 \times 52 = \dots$
Mark has a garden with flowers. He planted plants of three different	There are $80/100 \times 10 = 8$ more purple flowers than

예시 링크 : <https://huggingface.co/datasets/openai/gsm8k>

스페이스(Spaces)



Spaces
Discover amazing AI apps made by the community!

Create new Space or [Learn more about Spaces](#)

Browse [ZeroGPU Spaces](#) Full-text search [Sort: Most likes](#)

Running on CPU UPGRADE 11.9k

Open LLM Leaderboard 2

Track, rank and evaluate open LLMs and chatbots

open-llm-leaderboard 17 days ago

Running on CPU UPGRADE 10.8k

Stable Diffusion 2-1

stabilityai Oct 8

Running on CPU UPGRADE 8.71k

AI Comic Factory

Create your own AI comic with a single prompt

jbilcke-hf Oct 16

Open LLM Leaderboard
The previous Leaderboard version is live [here](#) Feeling lost? Check out our [documentation](#)
You'll notably find explanations on the evaluations we are using, reproducibility guidelines, best practices on how to submit a model, and our [FAQ](#).

LLM Benchmark Submit Model Vote

Separate multiple queries with ";"

Select Columns to Display:

☒ Average ☒ IFEval ☐ IFEval Raw ☒ BBH ☐ BBH Raw ☒ MATH Lvl 5 ☐ MATH Lvl 5 Raw

☒ GPQA ☐ GPQA Raw ☒ MUSR ☐ MUSR Raw ☒ MMLU-PRO ☐ MMLU-PRO Raw ☐ Type

☐ Architecture ☐ Precision ☐ Not_Merged ☐ Hub License ☐ #Params (B) ☐ Hub ☒ Heart

☐ Model sha ☐ Submission Date ☐ Upload To Hub Date ☐ Chat Template ☐ Generation

☐ Base Model ☒ CO2 cost (kg)

Model types

☒ chat models (RLHF, DPO, IFT, ...)

☒ fine-tuned on domain-specific datasets ☒ base merges and moerges

☒ pretrained ☒ multimodal ☒ continuously pretrained

Precision

☒ bfloat16 ☒ float16 ☒ 4bit


Select the number of parameters (B)

Hide models

☒ Deleted/incomplete ☒ Merge/MoErg ☐ MoE ☒ Flagged ☐ Show only maintainer's highlight

T	Model	Average	IFEval	BBH	MATH Lvl 5	GPQA	MUSR	MMLU-PRO	CO2 cost (kg)
	dfuxman/CalmeRys-78B-Orpo-v0.1	51.24	81.63	61.92	40.71	20.02	36.37	66.8	13
	MaziyarPanahi/calme-3.1-instruct-78b	51.2	81.36	62.41	38.75	19.46	36.5	68.72	32.22
	MaziyarPanahi/calme-2.4-ys-78b	50.71	80.11	62.16	40.41	20.36	34.57	66.69	12.98
	xombodawg/Rombos-LLM-V2.5-Open-72b	45.91	71.55	61.27	50.68	19.8	17.32	54.83	16.03

Stable Diffusion 2.1 Demo
Stable Diffusion 2.1 is the latest text-to-image model from StabilityAI. [Access Stable Diffusion 1 Space here](#)
For faster generation and API access you can try [DreamStudio Beta](#).



The screenshot shows the HuggingFace website's documentation for leaderboards. The top navigation bar includes the HuggingFace logo, a search bar, and links to Models, Datasets, Spaces, and Posts. The left sidebar is titled 'Leaderboards' and contains a search bar, language selectors (MAIN, EN), and a list of links under 'LEADERBOARDS ON THE HUB' and 'OPEN LLM LEADERBOARD'. The main content area is titled 'Leaderboards and Evaluations' and contains an introductory paragraph, a bulleted list of points, and two call-to-action boxes. At the bottom of the main content area is a link to 'Update on GitHub'.

Hugging Face Search models, datasets, users...

Models Datasets Spaces Posts

Leaderboards Search documentation Ctrl+K

MAIN EN 15

Leaderboards

LEADERBOARDS ON THE HUB

- Introduction to leaderboards
- Finding leaderboards
- Building your leaderboard
- Extras

OPEN LLM LEADERBOARD

- About
- How to submit your model
- FAQ
- Scores Normalization
- C02 calculation
- Archived versions

Leaderboards and Evaluations

As the number of open and closed source machine learning models explodes, it can be very hard to find the correct model for your project. This is why we started our evaluations projects:

- the **Open LLM Leaderboard** evaluates and ranks open source LLMs and chatbots, and provides reproducible scores separating marketing fluff from actual progress in the field.
- Leaderboards on the Hub** aims to gather machine learning leaderboards on the Hugging Face Hub and support evaluation creators.

Explore machine learning rankings to find the best model for your use case, or build your own leaderboard, to test specific capabilities which interest you and the community!

Leaderboards on the Hub

A small introduction to all things leaderboards on the hub.

Open LLM Leaderboard

Curious about the Open LLM Leaderboard? Start here!

[Update on GitHub](#)

HuggingFace Leaderboards



Open Ko-LLM LeaderBoard

The previous Leaderboard version is live [here](#) 🇺🇸

🚀 The Open Ko-LLM Leaderboard2 KR objectively evaluates the performance of Korean Large Language Model (LLM). When you submit a model on the "Submit here!" page, it is automatically evaluated.

This leaderboard is co-hosted by [Upstage](#), and [NIA](#) that provides various Korean Data Sets through [AI-Hub](#), and operated by [Upstage](#). The GPU used for evaluation is operated with the support of [KT](#) and [AICA](#). If Season 1 focused on evaluating the capabilities of the LLM in terms of reasoning, language understanding, hallucination, and commonsense through academic benchmarks, Season 2 will focus on assessing the LLM's practical abilities and reliability. The datasets for this season are sponsored by [Flitto](#), [SELECTSTAR](#), and [KAIST AI](#). The evaluation dataset is exclusively private and only available for evaluation process. More detailed information about the benchmark dataset is provided on the "About" page.

You'll notably find explanations on the evaluations we are using, reproducibility guidelines, best practices on how to submit a model, and our FAQ.

🏆 LLM Benchmark About Submission Info

🔍 Search for your model (separate multiple queries with `;`) and press ENTER...

Select columns to show

- ☒ Average 📊
- ☒ Ko-GPQA
- ☒ Ko-Winogrande
- ☒ Ko-GSM8k
- ☒ Ko-EQ Bench
- ☒ Ko-IFEval
- ☒ KorNAT-CKA
- ☒ KorNAT-SVA
- ☒ Ko-Harmlessness
- ☒ Ko-Helpfulness
- ☐ Type
- ☐ Architecture
- ☐ Precision
- ☐ Merged
- ☐ Hub License
- ☐ #Params (B)
- ☐ Hub ❤️
- ☐ Available on the hub
- ☐ Model sha
- ☐ Flagged

☐ Show private/deleted models☐ Show merges☐ Show flagged models

Model types

- ☒ pretrained
- ☒ continuously pretrained
- ☒ fine-tuned on domain-specific datasets
- ☒ chat models (RLHF, DPO, IFT, ...)
- ☒ base merges and moerges
- ☒ ? other

Precision

- ☒ float16
- ☒ bfloat16
- ☒ 8bit
- ☒ 4bit
- ☒ GPTQ
- ☒ ?

Model sizes (in billions of parameters)

- ☒ Unknown
- ☒ 0~3B
- ☒ 3~7B
- ☒ 7~13B
- ☒ 13~35B
- ☒ 35~60B
- ☒ 60B+

T ▲	Model1 ▲	Average 📊 ▲	Ko-GPQA ▲	Ko-Winogrande ▲	Ko-GSM8k ▲	Ko-EQ Bench ▲	Ko-IFEval ▲	KorNAT-CKA ▲	KorNAT-SVA ▲	Ko-Harmlessness ▲	Ko-Help: ▲
🗨	nbeerbower/gemma2-gutenberg-27B	55.93	27.27	70.24	71.72	58.56	74.68	38.05	45.89	65.86	51.1
🏆	byroneverson/gemma-2-27b-it-abliterated	55.5	27.27	69.69	70.81	57.84	72.87	38.75	48.67	63.09	50.52
🗨	unsloth/gemma-2-27b-it	55.49	27.78	70.09	71.11	58.38	72.48	37.57	44.87	65.88	51.3

출처 : <https://huggingface.co/spaces/upstage/open-ko-llm-leaderboard>

AI startups Anthropic and Inflection AI recently announced AI models that each claimed to achieve state-of-the-art performance. They used benchmarking to compare model performance. Benchmarking is a way to compare model performance by measuring the speed, accuracy, etc. of a model performing a specific task. However, critics argue that benchmarking metrics don't fully reflect real-world usage. Because benchmarking measures the performance of a model performing a specific task in an artificial environment, it does not take into account the various variables that occur in the real world. Therefore, a model that performs well in benchmarking does not guarantee better results in the real world. **Be 2024.03.08** ing metrics are poorly correlated with real-world usage, it can be misleading to judge model performance based on benchmarking results alone.

최근 인공지능 스타트업 앤트로픽(Anthropic)과 인플렉션 AI(Inflection AI)는 각각 최첨단 성능을 달성했다고 주장하는 인공지능 모델을 발표했다. 이들은 모델 성능 비교를 위해 벤치마킹을 활용했다. 벤치마킹은 특정 작업을 수행하는 모델의 속도, 정확도 등을 측정하여 모델 성능을 비교하는 방법이다. 하지만 벤치마킹 지표가 실제 사용 환경을 충분히 반영하지 못한다는 비판이 있다. 벤치마킹은 인공적인 환경에서 특정 작업을 수행하는 모델의 성능을 측정하기 때문에 실제 사용 환경에서 발생하는 다양한 변수를 고려하지 못하기 때문이다. 따라서 벤치마킹 결과에서 우수한 성능을 보인 모델이 실제 사용 환경에서도 더 나은 결과를 보장하지는 않는다. 벤치마킹 지표가 실제 사용 환경과 상관관계가 낮기 때문에 벤치마킹 결과만으로 모델 성능을 판단하는 것은 무의미할 수 있다.

Hugging Face and Pollen Robotics show off first project: an open source robot that does chores



Reachy Full Kit + Mobile Base - €39,990



Reachy Full Kit - €27,990



Reachy Starter Kit - €19,990



Reachy Arm Kit - €9,990






Remi Cadene · Jun 7, 2024

@RemiCadene · [Follow](#)

We made Reachy2 from @pollenrobotics autonomously doing household chores and interacting with us. It can move its full body, including its neck. Even the dog was impressed! 🐕 You can do the same at home on smaller robots with github.com/huggingface/le... and github.com/dora-rs/dora



허깅페이스 오픈소스 휴머노이드



Walkthrough

```
.
├── examples                    # contains demonstration examples, start here to learn about LeRobot
│   └── advanced                # contains even more examples for those who have mastered the basics
├── lerobot
│   ├── configs                # contains hydra yaml files with all options that you can override in the comm
│   │   ├── default.yaml      # selected by default, it loads pusht environment and diffusion policy
│   │   ├── env               # various sim environments and their datasets: aloha.yaml, pusht.yaml, xarm.
│   │   └── policy            # various policies: act.yaml, diffusion.yaml, tdmpc.yaml
│   ├── common                 # contains classes and utilities
│   │   ├── datasets          # various datasets of human demonstrations: aloha, pusht, xarm
│   │   ├── envs              # various sim environments: aloha, pusht, xarm
│   │   ├── policies          # various policies: act, diffusion, tdmpc
│   │   └── utils              # various utilities
│   └── scripts                # contains functions to execute via command line
│       ├── eval.py           # load policy and evaluate it on an environment
│       ├── train.py          # train a policy via imitation learning and/or reinforcement learni
│       ├── push_dataset_to_hub.py # convert your dataset into LeRobot dataset format and upload it to
│       └── visualize_dataset.py # load a dataset and render its demonstrations
├── outputs                    # contains results of scripts execution: logs, videos, model checkpoints
└── tests                      # contains pytest utilities for continuous integration
```


허깅페이스, 휴머노이드형 동반자 로봇 '리치 미니' 판매 시작

✎ 장길수 | ⌚ 입력 2025.07.09 18:02 | ⌚ 수정 2025.07.09 21:03 | 📄 댓글 0

인공지능 플랫폼 기업 허깅 페이스(Hugging Face)가 299 달러짜리 소형 휴머노이드 동반자 로봇 '리치 미니(Reachy Mini)'를 공식 발표했다. 리치 미니는 '리치 미니 라이트'와 '리치 미니 와이어리스'(449달러)로 구분된다. 우선 라이트 버전의 주문 판매를 시작하고, 연내 와이어리스 버전을 판매한다.

머신러닝 분야의 깃허브(GitHub)로 불리는 허깅 페이스는 이번 출시를 통해 수백만 개발자에게 AI 기반 로봇 기술을 보급하고, 전통적으로 폐쇄적이고 고가였던 로봇 산업의 패러다임을 전환하겠다는 포부를 밝혔다.

11인치 크기의 데스크톱형 동반자 로봇 '리치 미니'는 인공지능 기술 확산을 위한 허깅 페이스의 야심찬 하드웨어 프로젝트로 평가된다. 이번 발표는 허깅 페이스 플랫폼 사용자가 1000만 명을 돌파한 시점에 맞춰 이뤄졌으며, 클레망 델랑그(Clément Delangue) CEO는 "AI 개발자들 사이에서 로봇공학에 대한 관심과 참여가 빠르게 증가하고 있다"고 밝혔다.

델랑그 CEO는 "로봇공학 개발의 가장 큰 장벽 중 하나는 '접근성'"이라며, "대부분의 사람들은 7만달러에 달하는 고가의 산업용 로봇이나 테슬라 옵티머스(예상가 2만~3만달러) 같은 최신 로봇을 구매할 수 없다"고 말했다. 리치 미니는 이러한 현실적 한계를 극복하기 위해 설계되었으며, 노트북 옆에 둘 수 있을 만큼 소형으로 제작됐다.

이 로봇은 허깅 페이스가 지난 4월 프랑스 로봇 스타트업 폴렌 로보틱스(Pollen Robotics)를 인수하면서 탄생한 첫번째 하드웨어 결과물이다. 특히 리치 미니는 허깅페이스의 대표적인 플랫폼인 '허깅 페이스 허브(Hub)' 및 '스페이스스(Spaces)'와 완전히 통합돼, 개발자들이 수천 개의 사전 학습 AI 모델에 접근하고 자신만의 로봇 애플리케이션을 제작·공유할 수 있다.

출처 : <https://www.irobotnews.com/news/articleView.html?idxno=41136>



허깅페이스 허브의 기업 활용



•허깅페이스 허브

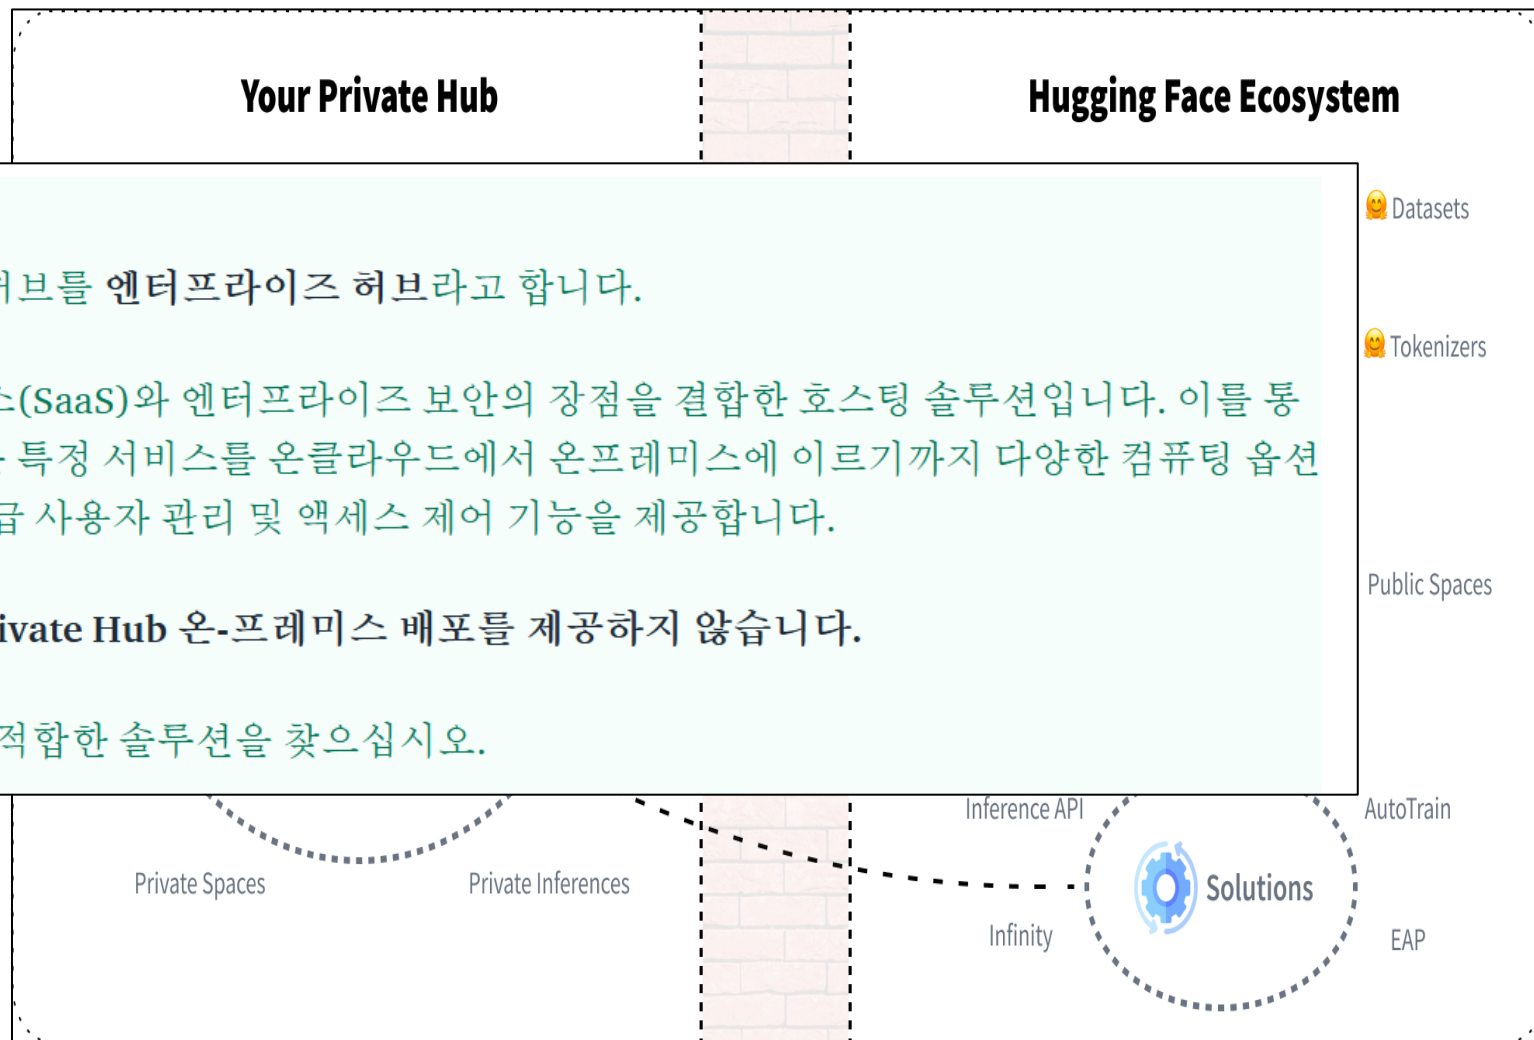
- ✓ 모델, 데이터셋, 스페이스

•프라이빗 허브

- ✓ A
 - ✓ A
 - ✓ S
 - ✓ I
 - ✓ P
- 2023년 6월 업데이트: 이제 프라이빗 허브를 엔터프라이즈 허브라고 합니다.
- Enterprise Hub는 클라우드 관리 서비스(SaaS)와 엔터프라이즈 보안의 장점을 결합한 호스팅 솔루션입니다. 이를 통해 고객은 **Inference Endpoints**와 같은 특정 서비스를 온클라우드에서 온프레미스에 이르기까지 다양한 컴퓨팅 옵션에 배포할 수 있습니다. SSO를 통한 고급 사용자 관리 및 액세스 제어 기능을 제공합니다.
- 이 실험은 이제 중단되므로 더 이상 **Private Hub** 온-프레미스 배포를 제공하지 않습니다.
- [Enterprise](#) 팀에 연락하여 귀사에 가장 적합한 솔루션을 찾으십시오.

•종류

- ✓ 관리형 프라이빗 허브(SaaS)
- ✓ 클라우드 내 프라이빗 허브
- ✓ 온-프레미스 Private Hub



모델 사용하기

모델 사용 : pipeline (= processor + model)




- Task : 수행할 작업
- model : task를 수행을 위한 훈련된 모델
- processor(tokenizer) : model에 따른 토큰화 모듈
- pipeline : AI 모델 + 토큰나이저

```
from transformers import pipeline
```

```
camembert_fill_mask = pipeline("fill-mask", model="camembert-base")  
results = camembert_fill_mask("Le camembert est <mask> :)")
```

```
[  
  {'sequence': 'Le camembert est délicieux :)', 'score': 0.49091005325317383, 'token': 7200, 'token_str': 'délicieux'},  
  {'sequence': 'Le camembert est excellent :)', 'score': 0.1055697426199913, 'token': 2183, 'token_str': 'excellent'},  
  {'sequence': 'Le camembert est succulent :)', 'score': 0.03453313186764717, 'token': 26202, 'token_str': 'succulent'},  
  {'sequence': 'Le camembert est meilleur :)', 'score': 0.0330314114689827, 'token': 528, 'token_str': 'meilleur'},  
  {'sequence': 'Le camembert est parfait :)', 'score': 0.03007650189101696, 'token': 1654, 'token_str': 'parfait'}  
]
```

Tasks



모델 사용법 : model, processor(tokenizer)



- 클래스 지정

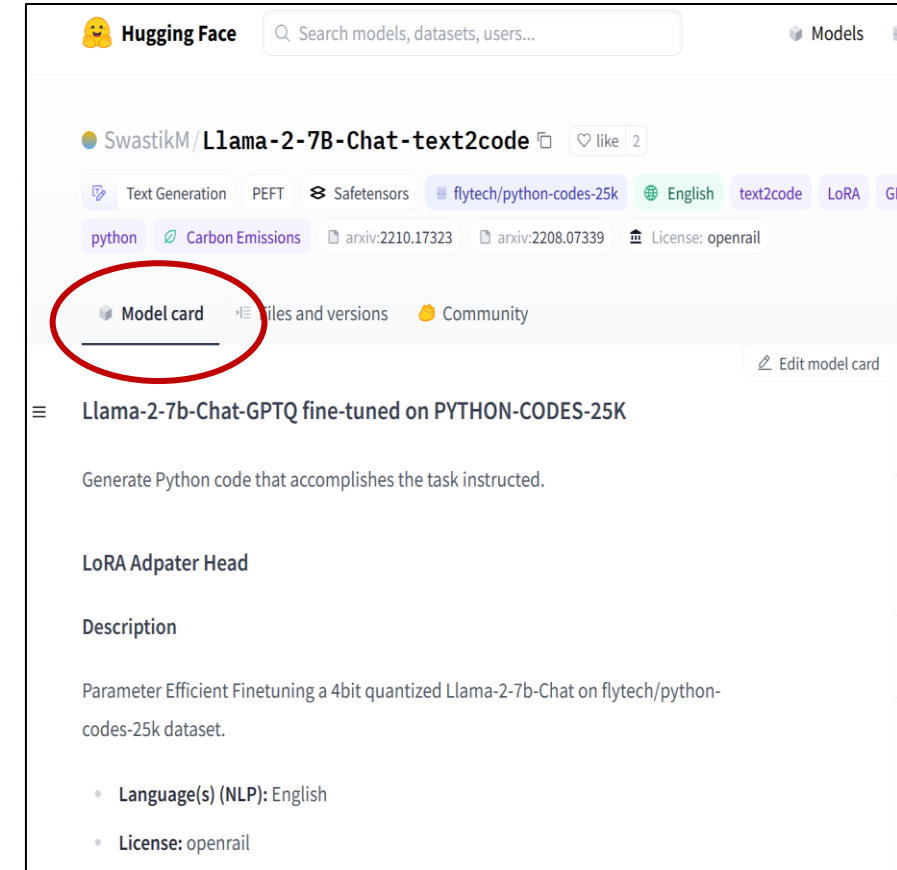
```
from transformers import CamembertTokenizer, CamembertForMaskedLM

tokenizer = CamembertTokenizer.from_pretrained("camembert-base")
model = CamembertForMaskedLM.from_pretrained("camembert-base")
```

- 클래스 자동 선택

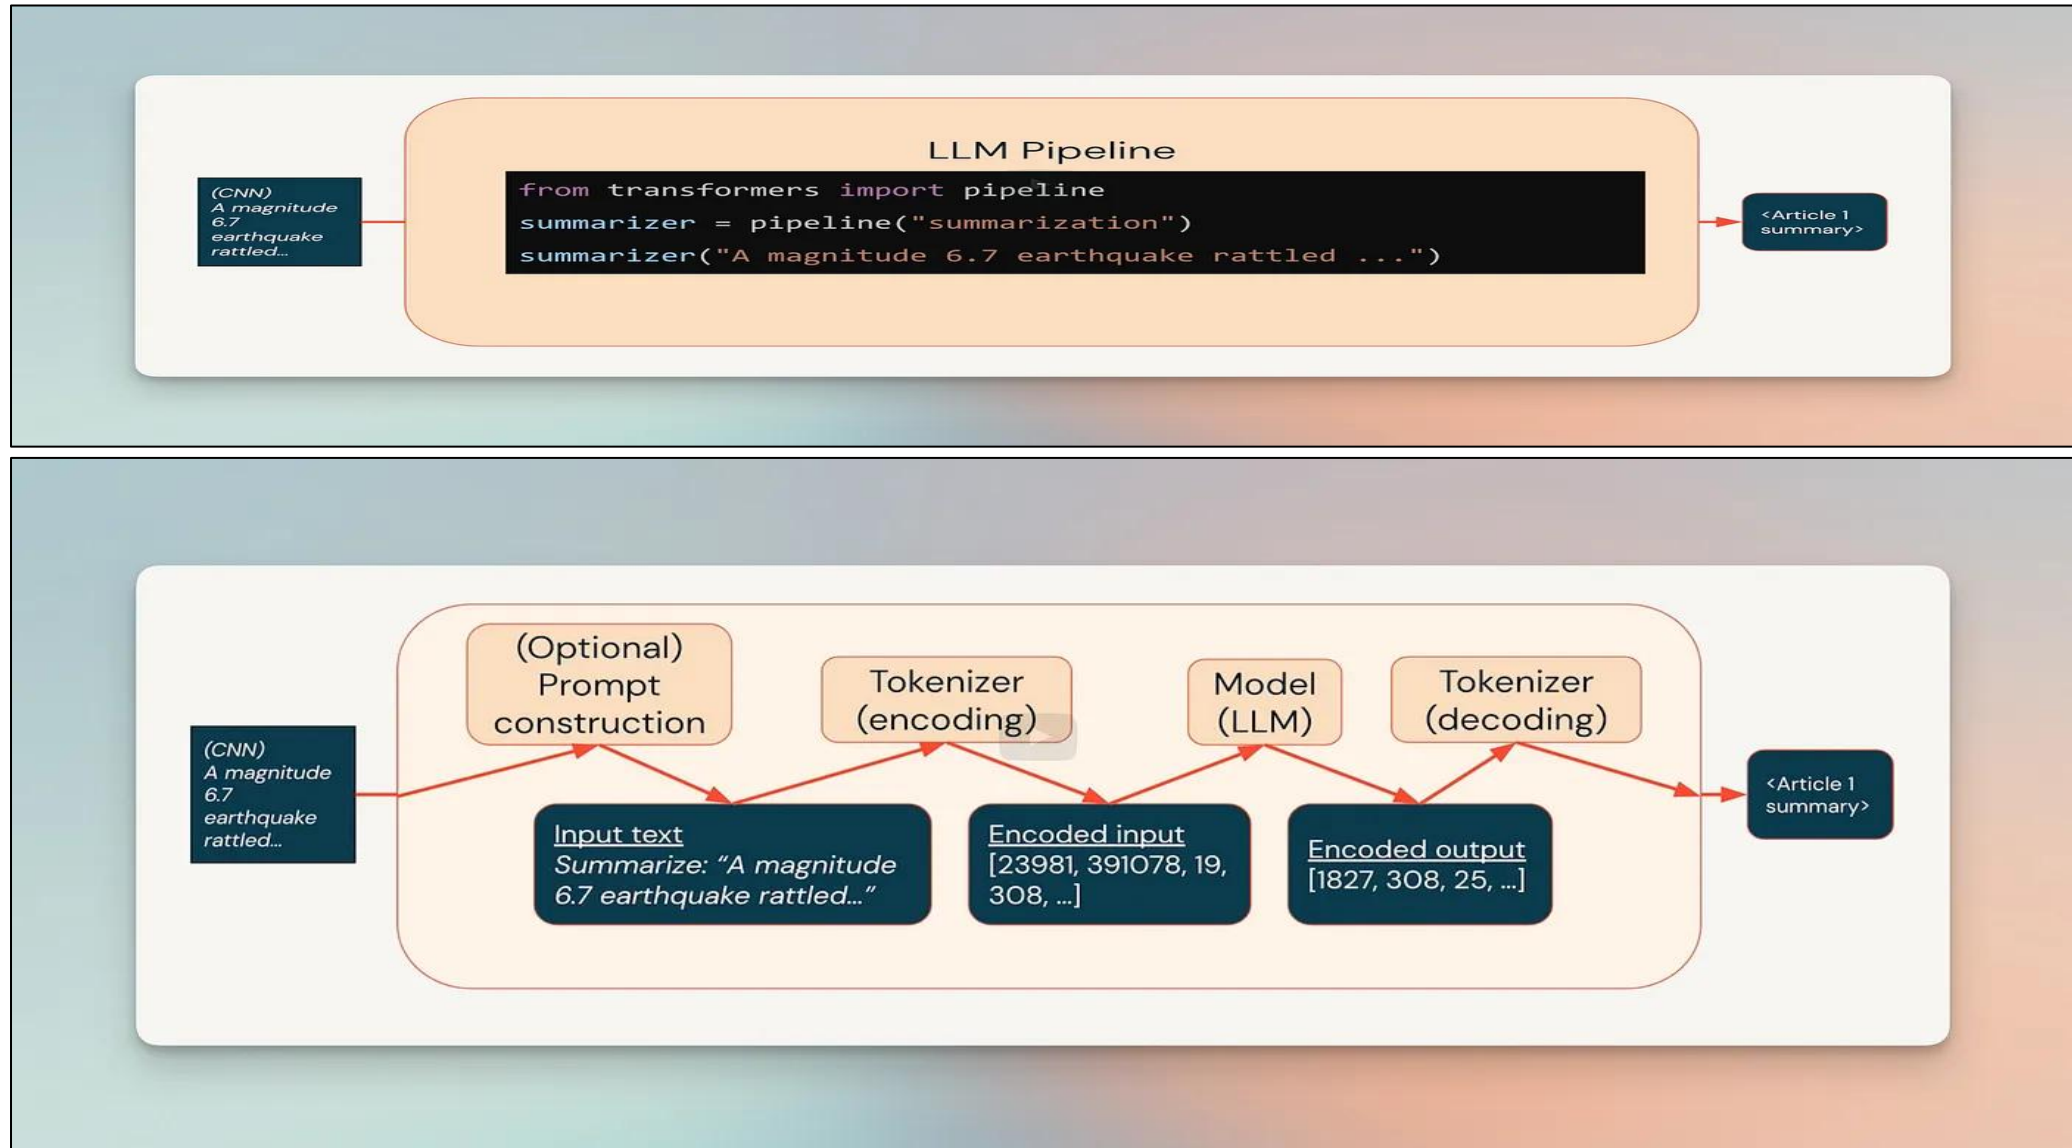
```
from transformers import AutoTokenizer, AutoModelForMaskedLM

tokenizer = AutoTokenizer.from_pretrained("camembert-base")
model = AutoModelForMaskedLM.from_pretrained("camembert-base")
```



모델의 상세 내용은 모델 카드(Model Card)에서 확인

pipeline = model + processor(tokenizer)



모델 사용법 : FastLanguageModel



특징	AutoModel 계열	FastLanguageModel
지원하는 모델 아키텍처	다양한 모델 아키텍처(BERT, GPT, T5 등)를 자동으로 식별하고 로드할 수 있습니다.	주로 Llama, Mistral 등 특정 아키텍처의 모델을 지원합니다.
메모리 최적화 기능	기본적으로 메모리 최적화 기능을 제공하지 않으며, 추가적인 설정이나 도구가 필요할 수 있습니다.	4비트 양자화와 같은 메모리 최적화 기능을 내장하여, 대형 모델을 단일 GPU에서도 효율적으로 활용할 수 있습니다.
사용 편의성	Hugging Face의 표준 인터페이스를 따르므로, 기존 Transformers 생태계와의 호환성이 높습니다.	Unsloth 라이브러리에 특화되어 있어, 해당 라이브러리의 기능을 활용하려는 경우에 적합합니다.
최대 시퀀스 길이 지원	모델에 따라 다르며, RoPE 스케일링과 같은 기능은 기본적으로 제공되지 않습니다.	RoPE 스케일링을 통해 최대 시퀀스 길이를 조정할 수 있는 기능을 제공합니다.
커뮤니티 및 지원	Hugging Face의 넓은 사용자 기반과 커뮤니티 지원을 받을 수 있습니다.	Unsloth는 비교적 새로운 프로젝트로, 커뮤니티 지원이 제한적일 수 있습니다.

```
pip install unsloth
```

```
from unsloth import FastLanguageModel

model_name = "unsloth/mistral-7b-bnb-4bit" # 사용할 모델 이름
max_seq_length = 2048 # 최대 시퀀스 길이 설정
load_in_4bit = True # 4비트 양자화 로드 설정

model, tokenizer = FastLanguageModel.from_pretrained(
    model_name=model_name,
    max_seq_length=max_seq_length,
    load_in_4bit=load_in_4bit,
)
```

0. 초기 GPT : SKT KoGPT2(skt/kogpt2-base-v2)



```
1 str_model_name = "skt/kogpt2-base-v2"
2
3 from transformers import GPT2LMHeadModel
4 base_model = GPT2LMHeadModel.from_pretrained(
5     str_model_name,
6 )
7 base_model.eval()
8
```

```
GPT2LMHeadModel(
  (transformer): GPT2Model(
    (wte): Embedding(51200, 768)
    (wpe): Embedding(1024, 768)
    (drop): Dropout(p=0.1, inplace=False)
    (h): ModuleList(
      (0-11): 12 x GPT2Block(
        (ln_1): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
        (attn): GPT2Attention(
          (c_attn): Conv1D()
          (c_proj): Conv1D()
          (attn_dropout): Dropout(p=0.1, inplace=False)
          (resid_dropout): Dropout(p=0.1, inplace=False)
        )
        (ln_2): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
        (mlp): GPT2MLP(
          (c_fc): Conv1D()
          (c_proj): Conv1D()
          (act): NewGELUActivation()
          (dropout): Dropout(p=0.1, inplace=False)
        )
      )
    )
    (ln_f): LayerNorm((768,), eps=1e-05, elementwise_affine=True)
  )
  (lm_head): Linear(in_features=768, out_features=51200, bias=False)
)
```

Model Test

```
[17] 1 # Test Prompt
2
3 test_input = "안녕하세요?"
4 # test_input = "조선시대 최고의 장군은 누구야?"
5 # test_input = "Who is the best general in Chosun Dynasity?"
6 input_ids = tokenizer.encode(test_input, return_tensors="pt")
```

```
[18] 1 # Greedy Search
2 #
3 with torch.no_grad():
4     generated_ids = base_model.generate(
5         input_ids,
6         do_sample=False,
7         min_length=10,
8         max_length=50,
9     )
10     print(tokenizer.decode([el.item() for el in generated_ids[0]]))
```

```
안녕하세요?"
"그럼, 그건 뭐예요?"
"그럼, 그건 뭐예요?"
"그럼, 그건 뭐예요?"
"그럼, 그건 뭐예요?"
```

모델 카드 : <https://huggingface.co/skt/kogpt2-base-v2>

실습 링크 : <https://colab.research.google.com/drive/1wHdK0G7a57JwvO2l2AYldvndCN3fOwl4?usp=sharing>

1. 음악 생성 모델 : MusicGen - Small - 300M (facebook/musicgen-small)



모델을 개발한 조직: Meta AI의 FAIR 팀.

모델 날짜: MusicGen은 2023년 4월부터 2023년 5월 사이에 훈련되었습니다.

모델 버전: 이는 모델의 버전 1입니다.

모델 유형: MusicGen은 오디오 토큰화를 위한 EnCodec 모델, 음악 모델링을 위한 트랜스포머 아키텍처를 기반으로 하는 자동 회귀 언어 모델로 구성됩니다. 이 모델은 300M, 1.5B 및 3.3B 매개변수의 다양한 크기로 제공되며, 두 가지 변형이 있습니다. 텍스트-음악 생성 작업을 위해 훈련된 모델과 멜로디 가이드 음악 생성을 위해 훈련된 모델입니다.

더 많은 정보가 있는 논문이나 자료: 더 많은 정보는 [Simple and Controllable Music Generation](#) 논문에서 찾아볼 수 있습니다.

데이터: 모델을 훈련하는 데 사용된 데이터 소스는 음악 전문가가 생성하고 권리 보유자와의 법적 계약으로 보호됩니다. 모델은 20,000시간 분량의 데이터로 훈련되었으며, 더 큰 데이터 세트로 모델을 확장하면 모델의 성능을 더욱 개선할 수 있다고 생각합니다.

완화책: 해당 태그를 사용하여 데이터 소스에서 보컬을 제거한 다음, 오픈 소스 [Hybrid Transformer for Music Source Separation](#) (HT-Demucs) 이라는 최첨단 음악 소스 분리 방법을 사용했습니다.

제한 사항:

- 이 모델은 현실적인 보컬을 생성할 수 없습니다.
- 이 모델은 영어 설명을 바탕으로 훈련되었기 때문에 다른 언어로는 성능이 좋지 않습니다.
- 이 모델은 모든 음악 스타일과 문화에 동일하게 적용되지는 않습니다.
- 이 모델은 가끔 노래가 끝나갈 즈음에 갑자기 침묵 속으로 사라지기도 합니다.
- 어떤 유형의 텍스트 설명이 가장 좋은 세대를 제공하는지 평가하기 어려울 때가 있습니다. 만족스러운 결과를 얻으려면 신속한 엔지니어링이 필요할 수 있습니다.

- Text-to-Music : 텍스트 설명이나 오디오 프롬프트에 따라 고품질 음악 샘플 생성
- 4 가지 버전 : small(300M), medium(1.5B), large(3.3B), melody (1.5B)
- MIT 라이선스

라이선스	주요 특징	소스코드 공개 의무	상업적 사용 가능 여부	복제(left) 조항
MIT License	자유롭게 사용, 수정, 배포 가능. 저작권 및 라이선스 표시 유지 필수.	없음	가능	없음

모델 카드 : <https://huggingface.co/facebook/musicgen-small>


실습 링크 : <https://colab.research.google.com/drive/1mElktUpSG8IBqvpBT5Ctrg5FLSAZHlpO?usp=sharing>

Self Test & Review : 5분

2. 언어 모델 : FLAN-T5 (`google/flan-t5-xl`)



- Google FLAN(Finetuned LAnguage Models are zero-shot Learners)
- T5 (Text-to-Text Transfer Transformer), Apache 2.0 라이선스



Model Variant	Number of Parameters	Model Size (GB)
google/flan-t5-small	80M	0.3
google/flan-t5-base	250M	1
google/flan-t5-large	780M	4
google/flan-t5-xl	3B	12
google/flan-t5-xxl	10B	40


출처 : <https://huggingface.co/google/flan-t5-xl>

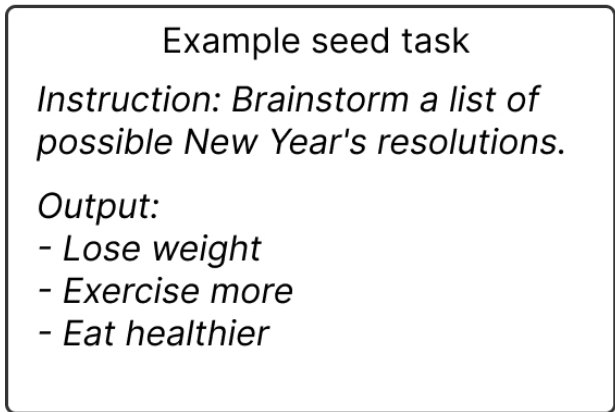
모델 카드 : <https://huggingface.co/google/flan-t5-xl>

실습 링크 : https://colab.research.google.com/drive/1_qKOPkKkKYvMneQt0SSTYdAXYZhy00Se?usp=sharing


Self Test & Review : 5분

LLM 선택 : LLaMA 계열





*Output:
... incorporating flexible
components, such as moveable
walls and furniture ...*



지식 증류(Knowledge Distillation)



[Submitted on 9 Mar 2015]

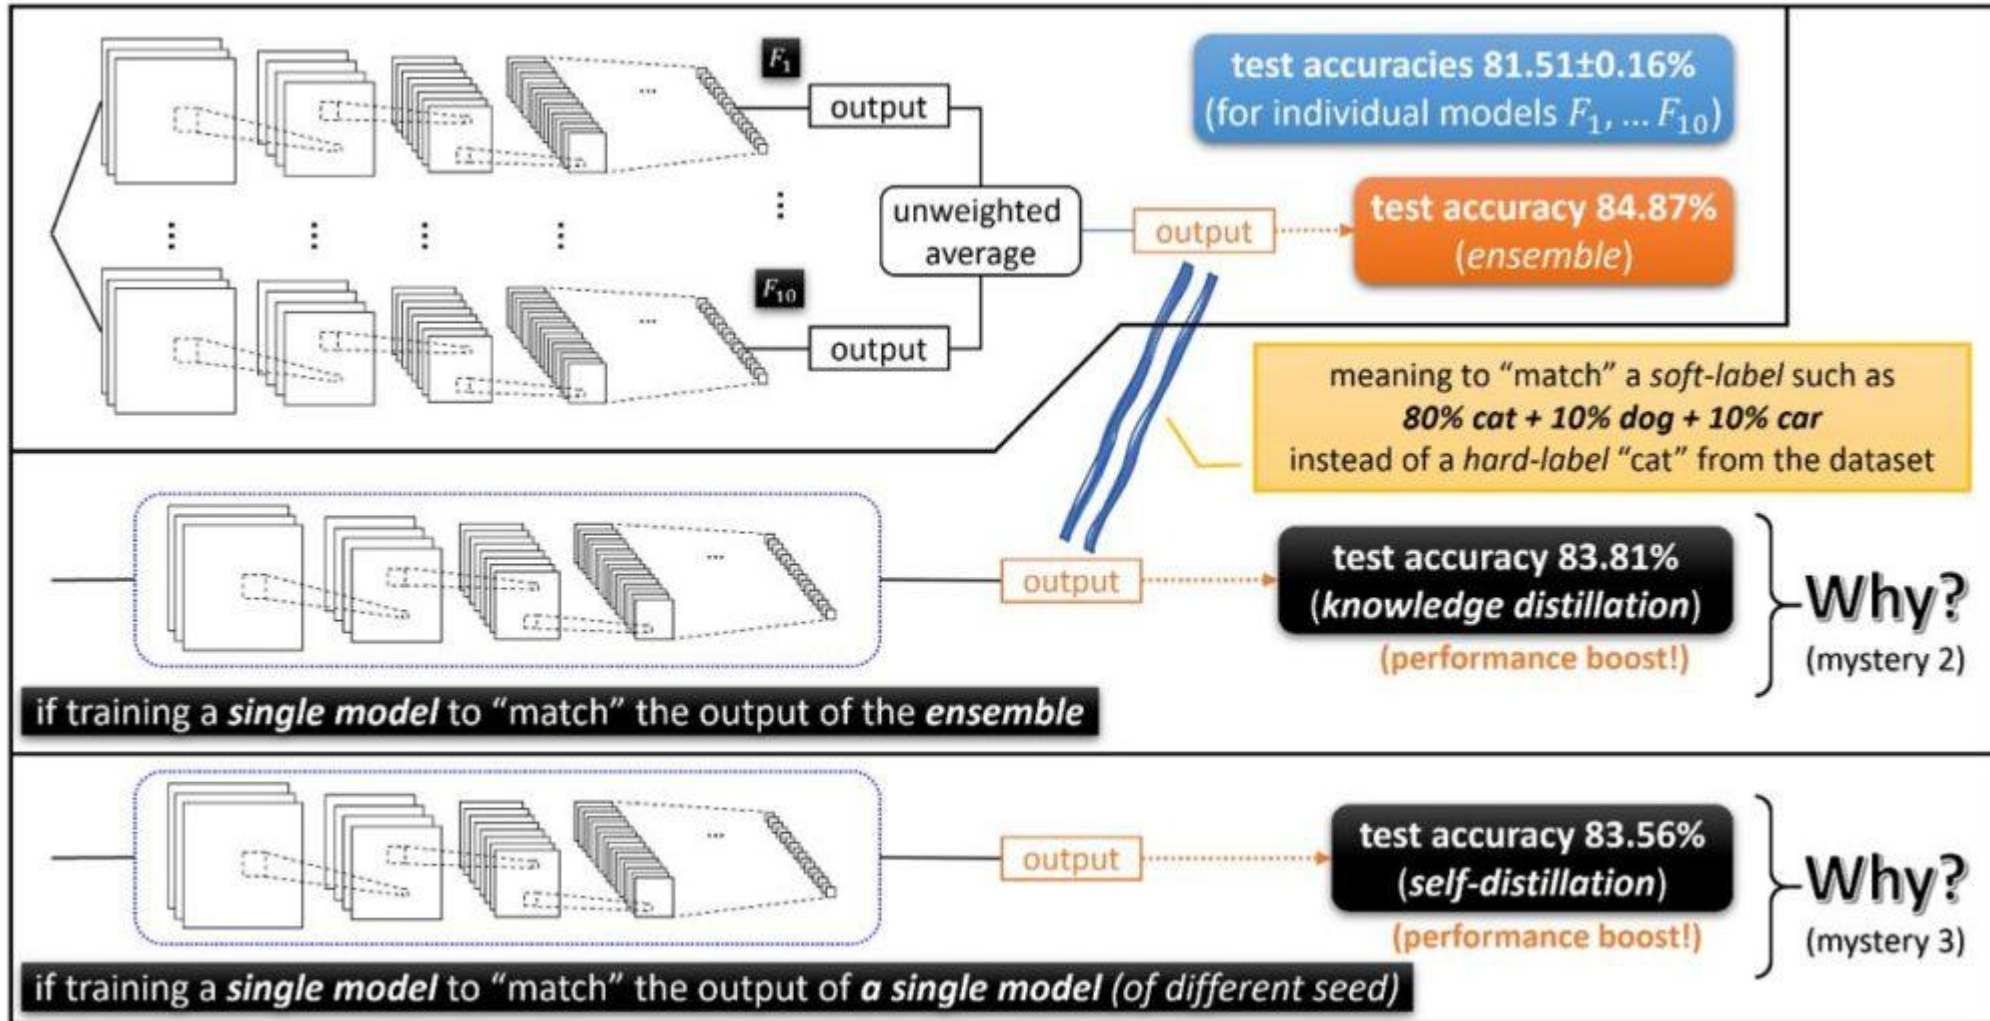
Distilling the Knowledge in a Neural Network

Geoffrey Hinton, Oriol Vinyals, Jeff Dean

A very simple way to improve the performance of almost any machine learning algorithm is to train many different models on the same data and then to average their predictions. Unfortunately, making predictions using a whole ensemble of models is cumbersome and may be too computationally expensive to allow deployment to a large number of users, especially if the individual models are large neural nets. Caruana and his collaborators have shown that it is possible to compress the knowledge in an ensemble into a single model which is much easier to deploy and we develop this approach further using a different compression technique. We achieve some surprising results on MNIST and we show that we can significantly improve the acoustic model of a heavily used commercial system by distilling the knowledge in an ensemble of models into a single model. We also introduce a new type of ensemble composed of one or more full models and many specialist models which learn to distinguish fine-grained classes that the full models confuse. Unlike a mixture of experts, these specialist models can be trained rapidly and in parallel.

System	Test Frame Accuracy	WER
Baseline	58.9%	10.9%
10xEnsemble	61.1%	10.7%
Distilled Single model	60.8%	10.7%

System & training set	Train Frame Accuracy	Test Frame Accuracy
Baseline (100% of training set)	63.4%	58.9%
Baseline (3% of training set)	67.3%	44.5%
Soft Targets (3% of training set)	65.4%	57.0%



배경 & 목적

- LLM(대형언어모델)은 강력하지만 비용·지연·프라이버시 이슈 존재
- SLM(소형언어모델)은 경량 장점 있지만 추론 능력 부족
- 연구 목적: LLM을 활용해 SLM에게 고급 추론 전략을 "가르치기"

주요 개념 정의

- LLM → SLM 학습: LLM이 생성한 추론 과정을 SLM에 가르침
- Prompt Erasure: LLM의 원 프롬프트는 숨기고 추론 전략만 전달
- Cautious Reasoner: SLM이 단계적 사고 + 추론 전략을 선택
- Instruction Tuning: 입력-출력 쌍 기반 fine-tuning

Orca-2 사례 연구

- 기반: LLaMA-2 7B/13B
- 훈련 목표: 단계적 처리, 추출-생성, 직접 응답 등 다양한 전략 학습
cobusgreyling.substack.com/p/llms-training-slm-8b7d5e7c637a
- Zero-shot 벤치마크 성능: 5-10배 큰 모델과 동등하거나 우수
blog.kore.ai/p/llms-training-slm-8b7d5e7c637a

훈련 기법 상세

A. Prompt Erasure

- 훈련 시, SLM에 원 프롬프트는 주지 않고 LLM의 reasoning output만 제공

B. Partial Answer Masking (PAM)

- 일부 정답을 마스킹 → SLM이 자기 점검(self-evaluation) 및 자기 수정 학습
[blog.kore.ai](https://blog.kore.ai/p/llms-training-slm-8b7d5e7c637a)

C. Random Chain-of-Thought + Self-eval

- 여러 CoT 생성 + LLM self-evaluation → SLM에 다양한 reasoning + 내부 평가 능력 distill
[blog.kore.ai](https://blog.kore.ai/p/llms-training-slm-8b7d5e7c637a)

추론 예시

John-Mark 역설

- 단계적 전략:
 - 사건 정리
 - 제한된 정보 바탕 인식
 - 각자의 기대 (John: box, Mark: basket) 추론
- 결과: 올바른 메타인퍼런스 + 설명
[blog.kore.ai](https://blog.kore.ai/p/llms-training-slm-8b7d5e7c637a)[blog.kore.ai](https://blog.kore.ai/p/llms-training-slm-8b7d5e7c637a)[blog.kore.ai](https://blog.kore.ai/p/llms-training-slm-8b7d5e7c637a)

SLM의 활용 & 장점

- 경량/로컬 배포 가능: 은행, 고객센터, 엣지 디바이스 등에서 효율적 사용
- RAG 결합: SLM은 추론/대화, LLM은 지식 응답 분리
- 비용·지연·프라이버시 절감



데이터 중심 접근

- SLM 성능은 “어떤 데이터로 어떻게 학습시키는지”가 핵심
- 데이터 설계**: Prompt Erasure, PAM 등 목적 기반 structuring
blog.kore.ai+9blog.kore.ai+9blog.kore.ai+9


정리 및 시사점

- LLM 기반 “교사 → SLM 학생” 학습이 유망
- Prompt Erasure, PAM 등 혁신적 데이터 기술이 열쇠
- SLM도 충분한 추론 가능**, LLM 의존도를 줄일 수 있음
- 향후: 안전성 강화, self-eval 고도화, 도메인 특화 SLM 발전 가능

카테고리	LLM (Large Language Model)	SLM (Small Language Model)
모델 크기	수십억 ~ 수천억 개의 파라미터	수억 ~ 수십억 개의 파라미터
추론 능력	높음 (강한 다단계 추론)	보통 (파인튜닝으로 개선 가능)
훈련 비용	매우 높음 (수백만 달러)	낮음 (저렴한 파인튜닝 가능)
지연 시간	높음 (강력한 인프라 필요)	낮음 (로컬 실행 가능)
배포	어려움 (클라우드/GPU 필요)	쉬움 (엣지 디바이스에서 실행)
활용 사례	ChatGPT, Claude, Gemini, 범용 어시스턴트	로컬 챗봇, 임베디드 시스템, RAG 강화 애플리케이션

데이터 설계 기법	요약 설명
Prompt Erasure	프롬프트를 제거하고 정답만으로 학습하여 추론 능력 강화
Partial Answer Masking	정답 일부를 마스킹하여 자기 점검 능력을 키움
Random Chain-of-Thought	다양한 CoT 생성으로 추론 다양성 확보
LLM Self-Evaluation	LLM 자체 평가를 통해 고품질 학습 데이터 확보
Strategy Tuning	다양한 응답 전략을 데이터로 학습시켜 다중 전략 적용 가능

AlpacaFarm: 인간의 피드백을 통해 학습하는 방법을 위한 시뮬레이션 프레임워크

출처 : [Stanford CRFM](https://openreview.net/forum?id=4hturzLcKX&utm_source=chatgpt.com)논문 : https://openreview.net/forum?id=4hturzLcKX&utm_source=chatgpt.com

Chat Completions vs. Completions

The chat completions format can be made similar to the completions format by constructing a request using a single user message. For example, one can translate from English to French with the following completions prompt:

```
Translate the following English text to French: "{text}"
```



And an equivalent chat prompt would be:

```
[{"role": "user", "content": "Translate the following English text to French"}]
```



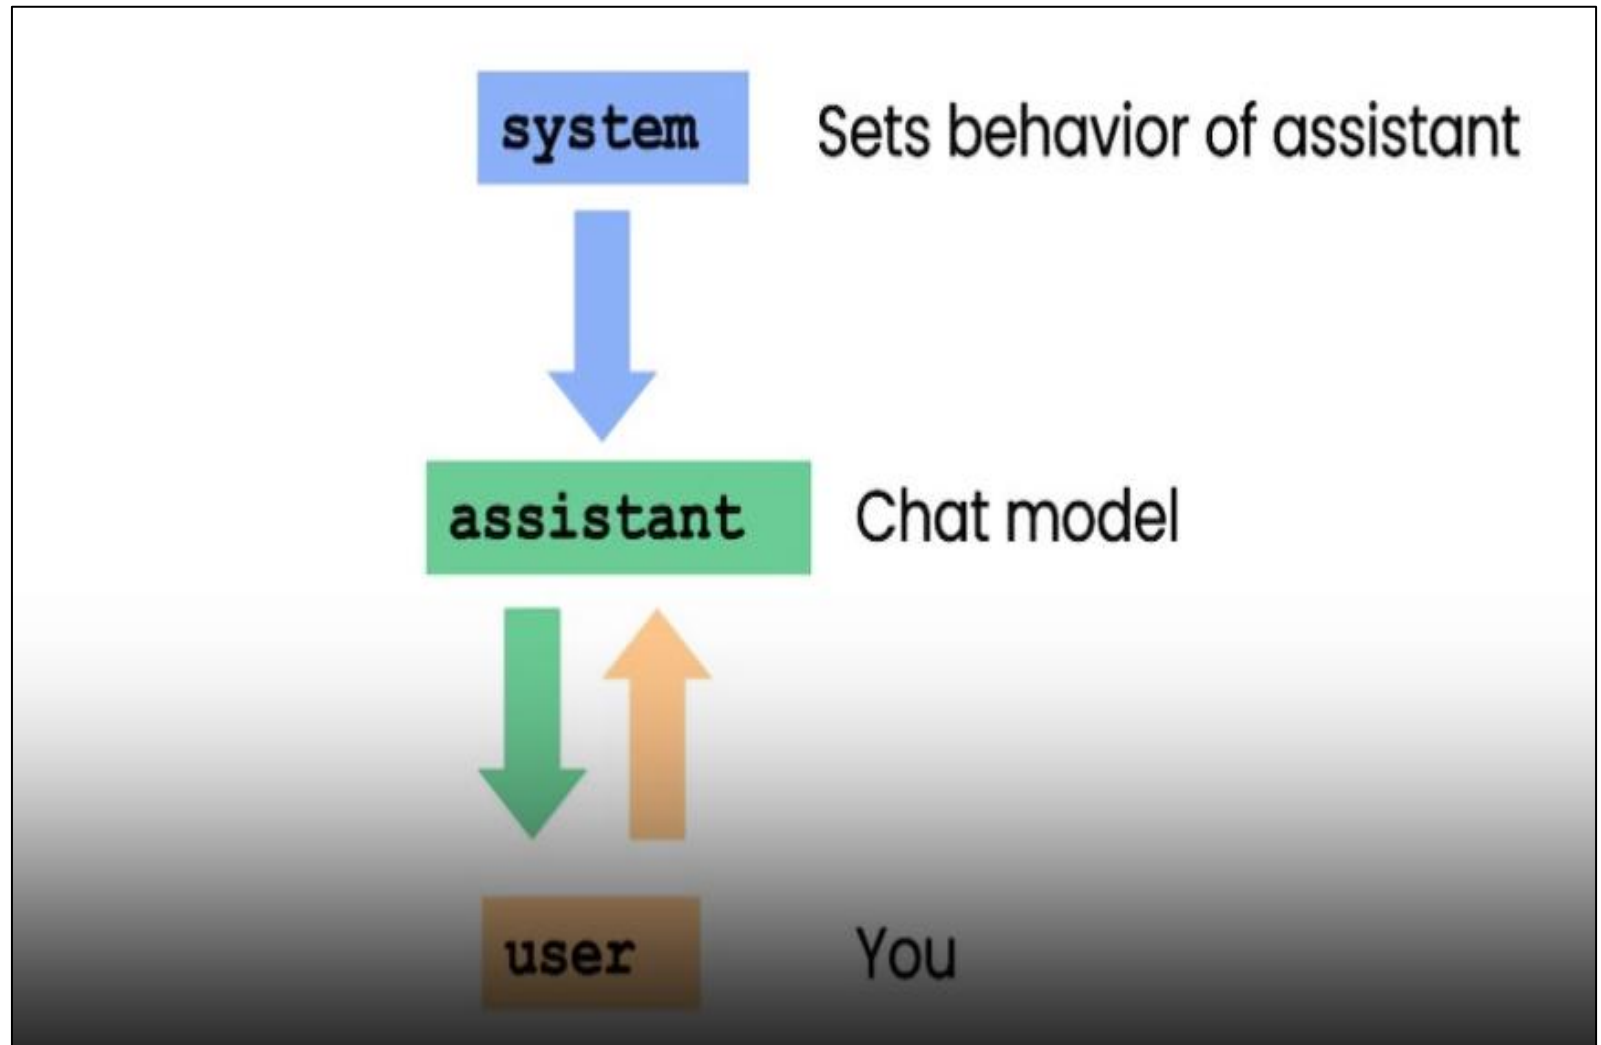
Likewise, the completions API can be used to simulate a chat between a user and an assistant by formatting the input [accordingly](#).

The difference between these APIs derives mainly from the underlying GPT models that are available in each. The chat completions API is the interface to our most capable model (`gpt-4`), and our most cost effective model (`gpt-3.5-turbo`). For reference, `gpt-3.5-turbo` performs at a similar capability level to `text-davinci-003` but at 10% the price per token! See pricing details [here](#).

OpenAI ChatCompletion API



- System
 - ✓ 전반적인 AI 역할 지시
- user
 - ✓ 사용자의 요청
- assistant
 - ✓ AI 답변

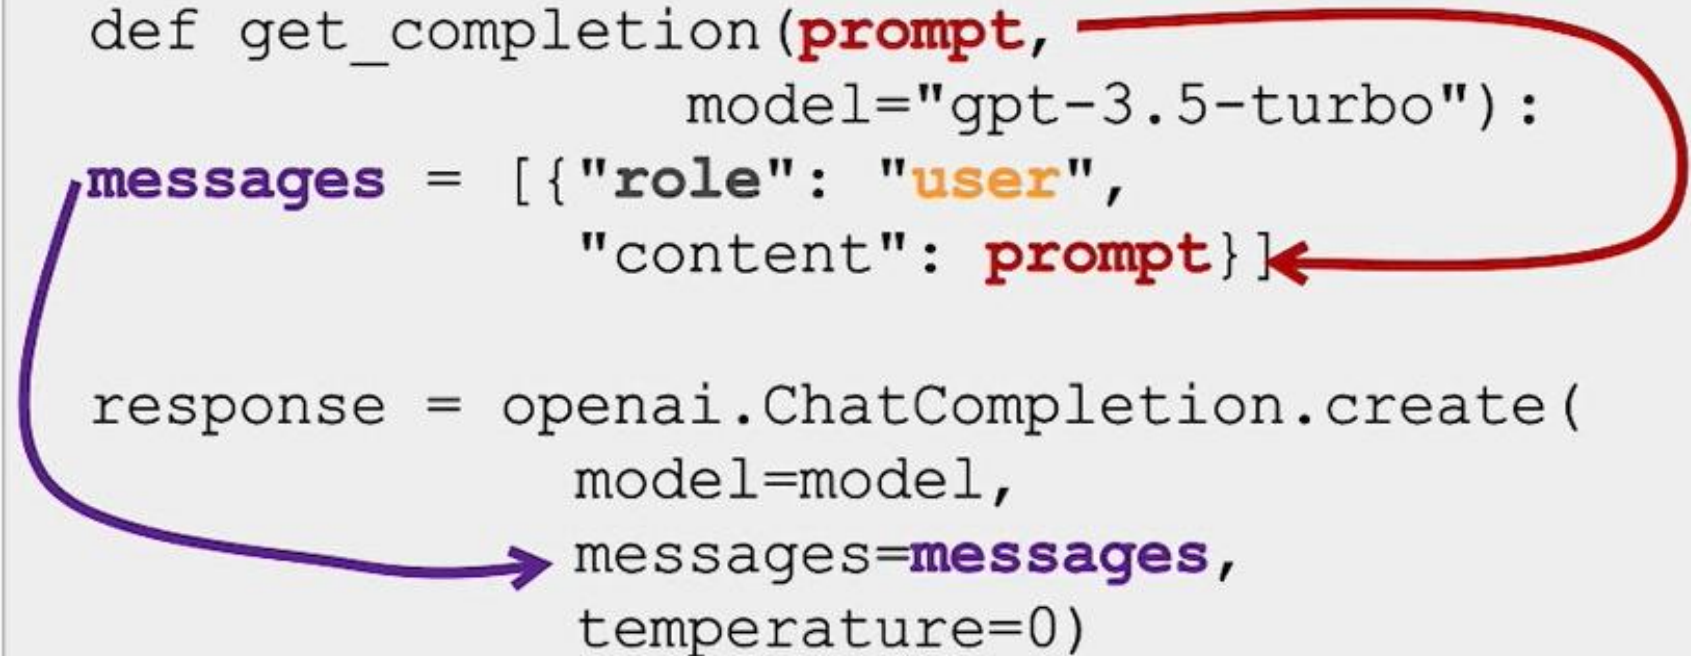


Role

```
messages =  
[  
  {"role": "system",  
    "content": "You are an assistant... "},  
  {"role": "user",  
    "content": "tell me a joke "},  
  {"role": "assistant",  
    "content": "Why did the chicken... "},  
  ...  
]
```

OpenAI API call

```
def get_completion(prompt,
                    model="gpt-3.5-turbo"):
    messages = [{"role": "user",
                  "content": prompt}]
    response = openai.ChatCompletion.create(
        model=model,
        messages=messages,
        temperature=0)
```



Token	Description
< begin_of_text >	This is equivalent to the BOS token.
< eot_id >	This signifies the end of the message in a turn.
< start_header_id >{role}< end_header_id >	These tokens enclose the role for a particular message. The possible roles can be: system, user, assistant.
< end_of_text >	This is equivalent to the EOS token. On generating this token, Llama 3 will cease to generate more tokens

<|begin_of_text|>

<|start_header_id|>system<|end_header_id|>

You are a honest and unbiased AI assistant who answers User queries with accurate responses.

<|eot_id|>

<|start_header_id|>user<|end_header_id|>

What's the capital of Australia?

<|eot_id|>

<|start_header_id|>assistant<|end_header_id|>

The capital of Australia is Canberra.

LLaMA 4 프롬프트 구조 : Multi-Modal &




특수 토큰	설명
<begin_of_text>	프롬프트 시작
<header_start>	역할 지정 시작
<header_end>	역할 지정 종료
<eot>	차례 종료

특수 토큰	설명
<image_start>	이미지 데이터의 시작
<image_end>	이미지 데이터의 끝
<patch>	입력 이미지의 부분 집합
<tile_x_separator>	이미지의 x 타일을 분리
<tile_y_separator>	이미지의 y 타일을 분리
<image>	일반 크기의 이미지 토큰을 다운사이즈된 버전과 분리

특수 토큰	설명
<system>	Llama와 상호작용할 때의 컨텍스트를 설정
<user>	Llama와 상호작용하는 인간 사용자
<assistant>	사용자에게 응답을 생성하는 Llama
<ipython>	도구 호출의 출력을 Llama에게 다시 보낼 때 나타냄

데모 링크 : https://colab.research.google.com/drive/16INyDIHkMciM1XF_pPUtFpEtkQAC8Nrv#scrollTo=5p5xaJRNntGB

Temperature : 출력 결과 변화



Temperature

Word	Logits	Softmax	Softmax with temperature 0.1
flowers	20	0.881	1.000
trees	18	0.119	0.000
herbs	5	0.000	0.000
bugs	2	0.000	0.000

Softmax

$$\text{Softmax}_{\theta}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}}$$

Softmax with temperature θ

$$\text{Softmax}_{\theta}(z_i) = \frac{e^{\frac{z_i}{\theta}}}{\sum_{j=1}^n e^{\frac{z_j}{\theta}}}$$

3. 언어 생성 모델: LLaMA 3 Endpoint(meta-llama/Meta-Llama-3-8B-Instruct)



모델 세부 정보

Meta는 8B 및 70B 크기의 사전 훈련되고 명령어 조정된 생성 텍스트 모델 모음인 대규모 언어 모델(LLM)의 Meta Llama 3 제품군을 개발 및 출시했습니다. Llama 3 명령어 조정 모델은 대화 사용 사례에 최적화되어 있으며 일반적인 업계 벤치마크에서 사용 가능한 많은 오픈 소스 채팅 모델보다 성능이 뛰어납니다. 또한 이러한 모델을 개발할 때 유용성과 안전성을 최적화하기 위해 세심한 주의를 기울였습니다.

모델 개발자 메타

변형 Llama 3는 8B 및 70B 매개변수의 두 가지 크기로 제공되며 사전 훈련 및 명령 조정 변형으로 제공됩니다.

입력 모델은 입력 텍스트만 입력합니다.

출력 모델은 텍스트와 코드만 생성합니다.

모델 아키텍처 Llama 3는 최적화된 트랜스포머 아키텍처를 사용하는 자동 회귀 언어 모델입니다. 조정된 버전은 SFT(Supervised Micro-Tuning) 및 RLHF(Reinforcement Learning with Human Feedback)를 사용하여 유용성과 안전성에 대한 인간의 선호도에 맞춥니다.

라마 3 모델 제품군. 토큰 수는 사전 학습 데이터만 참조합니다. 8 및 70B 버전 모두 향상된 추론 확장성을 위해 GQA(Grouped-Query Attention)를 사용합니다.

모델 출시일 2024년 4월 18일.

상태 오프라인 데이터 세트에서 학습된 정적 모델입니다. 조정된 모델의 향후 버전은 커뮤니티 피드백을 통해 모델 안전성을 개선하는 대로 출시될 예정입니다.

면허 맞춤형 상업용 라이선스는 다음에서 사용할 수 있습니다

<https://llama.meta.com/llama3/license>

모델에 대한 질문이나 의견을 보낼 수 있는 위치 모델에 대한 피드백이나 의견을 제공하는 방법에 대한 지침은 모델 [README](#)에서 찾을 수 있습니다. 생성 매개 변수 및 애플리케이션에서 Llama 3를 사용하는 방법에 대한 자세한 기술 정보는 여기에서 확인할 수 있습니다.

- Text-to-Text : 텍스트 지시에 따른 텍스트 생성
- 2 가지 버전 : 8B, 70B, llama 3.3 라이선스

모델 카드 : <https://huggingface.co/meta-llama/Meta-Llama-3-8B-Instruct>

실습 링크 : https://colab.research.google.com/drive/1R3fbsoPhlic-Bb26b_jCc1nAeowEvdnf?usp=sharing

Self Test & Review : 5분

운영을 위한 GPU 메모리



Numbers ¹⁰⁰ every LLM Developer should know *

Prompts

40-90% Amount saved by appending "Be Concise" to your prompt

1.3 Average tokens per word

Training and Fine Tuning

~\$1 million Cost to train a 13 billion parameter model on 1.4 trillion tokens

< 0.001 Cost ratio of fine tuning vs training from scratch

Price

~50 Cost Ratio of GPT-4 to GPT-3.5 Turbo

5 Cost Ratio of generation of text using GPT-3.5-Turbo vs OpenAI embedding

10 Cost Ratio of OpenAI embedding to Self-Hosted embedding

6 Cost Ratio of OpenAI base vs fine tuned model queries

1 Cost Ratio of Self-Hosted base vs fine-tuned model queries

GPU Memory

16GB V100 GRAM capacity
24GB A10G GRAM capacity
40/80GB A100 GRAM capacity

2x number of parameters Typical GPU memory requirements of an LLM for serving

~1GB Typical GPU memory requirements of an embedding model

>10x Throughput improvement from batching LLM requests

1 MB GPU Memory required for 1 token of output with a 13B parameter model

* Check out bit.ly/llm-dev-numbers for how we calculated the numbers

Presented by  RAY &  **anyscale** with  Join the community ray.io or Request a Trial anyscale.com/signup today

출처 : <https://www.anyscale.com/blog/num-every-llm-developer-should-know>

Numbers ¹⁰⁰ every LLM Developer should know *

Prompts

40-90% Amount saved by appending "Be Concise" to your prompt

1.3 Average tokens per word

Price

~50

5

10

6

1

Training and Fine Tuning

~\$1 million Cost to train a 13 billion parameter model on 1.4 trillion tokens

60,001 Cost ratio of fine tuning vs training

Word	Abbreviation	Approximate Size (Number of Bytes)	Approximate (Word)	Actual Bytes
Kilo	K or KB	1,000	Thousand	2 ¹⁰ or 1,024
Mega	M or MB	1,000,000	Million	2 ²⁰ or 1,048,576
Giga	G or GB	1,000,000,000	Billion	2 ³⁰ or 1,073,741,824
Tera	T or TB	1,000,000,000,000	Trillion	2 ⁴⁰ or 1,099,511,627,776
Peta	P or PB	1,000,000,000,000,000	Quadrillion	2 ⁵⁰ or 1,125,899,906,842,624
Exa	E or EB	1,000,000,000,000,000,000	Quintillion	2 ⁶⁰ or 1,152,921,504,606,846,976

Cost Ratio of Self-Hosted base vs fine-tuned model queries

1 MB

GPU Memory required for 1 token of output with a 13B parameter model

* Check out bit.ly/llm-dev-numbers for how we calculated the numbers

GPU 메모리 구성




(GPU Memory) =
(모델 크기) * 정밀도 +
(Forward 계산 용량 : 배치 크기 유동적) +
(Gradient 계산 메모리 : 모델 크기) +
(Optimizer 특성에 따른 메모리 :
SGD : 0, RMSProp : 1, Adam : 2)

- FP32 정밀도 : (파라미터 수) * 4
- FP16 정밀도 : (파라미터 수) * 2
- INT8 Quantization : (파라미터 수) * 1

예) 7B FP16 모델 : $2 * (7G) = 14GB$


- Forward 계산 연관성 : batch size, 입력 크기, Precision



Model Quantization

PEFT (parameter-efficient finetuning techniques)

[참고] Quantization 과 LoRA



Loading a Model in 4-bit Quantization

One of the key features of this integration is the ability to load models in 4-bit quantization. This can be done by setting the `load_in_4bit=True` argument when calling the `.from_pretrained` method. By doing so, you can reduce memory usage by approximately fourfold.

Loading a Model in 8-bit Quantization

For further memory optimization, you can load a model in 8-bit quantization. This can be achieved by using the `load_in_8bit=True` argument when calling `.from_pretrained`. This reduces the memory footprint by approximately half.

QLoRA : Quantized LLMs with Low-Rank Adapters




Figure 1: Different finetuning methods and their memory requirements. QLoRA improves over LoRA by quantizing the transformer model to 4-bit precision and using paged optimizers to handle memory spikes.

GPU, NPU, LPU, TPU



특징	GPU (Graphics Processing Unit)	NPU (Neural Processing Unit)	LPU (Language Processing Unit)	TPU (Tensor Processing Unit)
주요 용도	그래픽 렌더링, 병렬 컴퓨팅, AI 모델 훈련 및 추론	AI 추론 , 엣지 디바이스 및 모바일 환경에서의 실시간 처리	NLP 및 대규모 언어 모델(LLM) 추론	딥러닝 모델 훈련 및 추론 , 특히 TensorFlow 기반 작업
강점	- 다양한 AI 및 병렬 작업 처리 - 성숙한 소프트웨어 생태계 - 대규모 데이터 처리에 적합	- 저전력 소비 - 엣지 디바이스의 실시간 AI 작업 - 반복적이고 간단한 AI 작업	- NLP 작업에 최적화 - LLM 추론에서 고성능 - 예측 가능한 성능 제공	- 딥러닝 행렬 연산에 최적화 - 높은 에너지 효율성 - TensorFlow와의 긴밀한 통합
약점	- 높은 전력 소비 - 순차 처리 성능 부족 - 복잡한 프로그래밍 필요	- 대규모 AI 모델 훈련에 부적합 - 범용성이 부족	- NLP 외의 작업에는 제한적 - 소프트웨어 생태계가 미성숙	- TensorFlow 외의 프레임워크(PyTorch 등)에서 사용 어려움 - 범용성이 부족
아키텍처	수천 개의 코어를 활용한 병렬 처리	인간 뇌의 뉴런 동작을 모방한 병렬 처리와 저정밀 연산 지원	텍스트 기반 순차 처리에 최적화된 구조 (Tensor Streaming Processor 등)	행렬 연산을 위한 ASIC 기반의 Systolic Array 구조
저장소 요구 사항	고대역폭 메모리(HBM, GDDR) 사용	온칩 메모리와 연산 통합	대규모 언어 모델 가중치와 임베딩 저장을 위한 온칩 메모리 필요	HBM과 같은 고대역폭 메모리를 사용하여 대규모 데이터 처리
인터커넥트	NVLink 또는 PCIe와 같은 고속 데이터 전송 인터페이스 활용	온칩 메모리와의 효율적인 통합	메모리와 프로세싱 유닛 간의 저지연 연결	TPU 클러스터를 통한 확장성과 고속 데이터 전송
사용 사례	게임, 과학 시뮬레이션, AI 훈련, 이미지/비디오 처리	이미지/음성 인식, 엣지 컴퓨팅, 모바일 기기	챗봇, 기계 번역, 텍스트 생성, 감정 분석	딥러닝 훈련(Transformer, CNN 등), 자연어 처리(NLP), 의료 데이터 분석
전력 소비	상대적으로 높음	매우 낮음	GPU 대비 낮음	GPU 대비 낮은 전력 소비
대표 예시	NVIDIA A100, AMD Radeon Instinct	Qualcomm Snapdragon NPU, Apple Neural Engine	Groq LPU	Google TPU v4/v5/v6

업스테이지, 퓨리오사AI 반도체에 자사 언어모델 '솔라' 탑재한다


발행일 : 2025-06-25 14:09 지면 : 2025-06-26

업스테이지가 퓨리오사AI와 '신경망처리장치(NPU) 기반 생성형 인공지능(AI) 사업 협력'을 위한 양해각서(MOU)를 교환했다.

이번 협력의 핵심은 국산 NPU와 거대언어모델(LLM)의 결합이다. 업스테이지는 자체 LLM '솔라'를 퓨리오사AI의 차세대 NPU '레니게이드'에 최적화해 탑재할 계획이다. 양사는 NPU 기반으로 구동하는 온프레미스 AI 구축 사업을 공동 추진하고, 국내는 물론 글로벌 시장까지 함께 공략할 방침이다.

양사는 국산 NPU 기반 생성형 AI 솔루션의 상용화가 해외 기술 의존도를 낮추고, AI 인프라의 자립화와 기술 주권 확보에 기여할 것으로 기대했다.

김성훈 업스테이지 대표는 “AI 소프트웨어부터 하드웨어까지 모두 국내 기술로 구현하는 이번 협력은 국내 AI 산업 자립화를 향한 의미 있는 발걸음”이라며 “업스테이지는 퓨리오사AI와의 긴밀한 협력을 바탕으로 글로벌 시장에서도 'K-AI'의 기술 경쟁력을 입증해 나가겠다”고 밝혔다.



백준호 퓨리오사 대표(좌)와 이활석 업스테이지 CTO(우)가 MOU 교환 후 기념촬영을 하고 있는 모습

4. 언어 생성 모델: EXAONE(beomi/EXAONE-3.5-2.4B-Instruct-Llamafied)



EXAONE-3.5-2.4B-지시

소개

우리는 LG AI Research에서 개발 및 출시한 2.4B에서 32B 매개변수에 이르는 명령어 조정 이중 언어(영어 및 한국어) 생성 모델 컬렉션인 EXAONE 3.5를 소개합니다. EXAONE 3.5 언어 모델은 다음과 같습니다. 1) 소규모 또는 리소스가 제한된 장치에 배포하도록 최적화된 **2.4B 모델**, 2) **이전 모델**과 크기가 동일하지만 성능이 향상된 7.8B 모델, 3) 강력한 성능을 제공하는 **32B 모델**. 모든 모델은 최대 32K 토큰의 장기 컨텍스트 처리를 지원합니다. 각 모델은 실제 사용 사례와 장기 컨텍스트 이해에서 최첨단 성능을 보여주는 동시에 최근에 출시된 비슷한 크기의 모델과 비교했을 때 일반 도메인에서 경쟁력을 유지합니다.

자세한 내용은 [기술 보고서](#), [블로그](#), [GitHub](#) 을 참조하세요.

이 저장소에는 다음과 같은 기능을 갖춘 명령어 조정 2.4B 언어 모델이 포함되어 있습니다.

- 매개변수 수(임베딩 없음): 2.14B
- 레이어 수: 30
- 주의 헤드 수: 32개 Q 헤드와 8개 KV 헤드가 있는 GQA
- 어휘 크기: 102,400
- 컨텍스트 길이: 32,768 토큰
- Tie Word Embeddings: True(7.8B 및 32B 모델과 달리)

빠른 시작

`transformers` v4.43 이상을 사용하는 것이 좋습니다.

- Text-to-Text : 텍스트 지시에 따른 텍스트 생성, exaone 라이선스

모델 카드 : <https://huggingface.co/beomi/EXAONE-3.5-2.4B-Instruct-Llamafied>

실습 링크 : <https://colab.research.google.com/drive/1HZ9p0haSZNdTDXIECvf3IngqBsDMiX63?usp=sharing>

Self Test & Review : 5분

5. 언어 생성 모델: LLaMA 3(meta-llama/Meta-Llama-3-8B-Instruct)



meta-llama/**Meta-Llama-3-8B-Instruct** like 3.74k Follow Meta Llama 17.5k

Text Generation Transformers Safetensors PyTorch English llama facebook meta llama-3 conversational text-generation-inference Inference Endpoints License: llama3

Model card Files and versions Community 200

A newer version of this model is available: [meta-llama/Llama-3.1-8B-Instruct](#)

Gated model You have been granted access to this model

Model Details

Meta developed and released the Meta Llama 3 family of large language models (LLMs), a collection of pretrained and instruction tuned generative text models in 8 and 70B sizes. The Llama 3 instruction tuned models are optimized for dialogue use cases and outperform many of the available open source chat models on common industry benchmarks. Further, in developing these models, we took great care to optimize helpfulness and safety.

Model developers Meta

Variations Llama 3 comes in two sizes — 8B and 70B parameters — in pre-trained and instruction tuned variants.

Downloads last month **1,062,304**

Safetensors Model size 8.03B params Tensor type BF16

Inference API Warm

Text Generation Examples

Input a message to start chatting with meta-llama/Meta-Llama-3-8B-Instruct.

- LLaMA 와 LangChain 연동 테스트 , llama 3.3 라이선스

모델 카드 : <https://huggingface.co/meta-llama/Meta-Llama-3-8B-Instruct>

실습 링크 : https://colab.research.google.com/drive/1T41ZhIMFKR5rFxtZf_bt8chpr6eFuEkZ?usp=sharing

Self Test & Review : 5분

6. 음성 생성 (1) : VITS (kakao-enterprise/vits-ljs)



카카오엔터프라이즈 / 비츠-LJS

TTS(텍스트 음성 변환) 트랜스포머 파이토치 세이프텐서 VITS(영문) 텍스트를 오디오로 변환 추론 엔드포인트 면허: MIT (미트)

모델 카드 파일 및 버전 커뮤니티 1

기차 전개시키다 이 모델 사용

모델 카드 편집

VITS: 엔드투엔드 TTS(Text-to-End)를 위한 적대적 학습을 통한 조건부 변분 오토 인코더

BITS는 입력 텍스트 시퀀스에 따라 음성 파형을 예측하는 엔드 투 엔드 음성 합성 모델입니다. 그것은 이다 조건부 변이 오토인코더(VAE)는 사후 인코더, 디코더 및 조건부 사전으로 구성됩니다. 이 저장소 [LJ Speech](#) 데이터 세트에서 훈련된 공식 VITS 체크포인트에 대한 가중치가 포함되어 있습니다.

모델 세부 정보

VITS(V, 종단 간 Text-to-Speech에 대한 적대적 학습을 사용한 Variational Inference)는 종단 간 분석입니다. 입력 텍스트 시퀀스에 따라 음성 파형을 예측하는 음성 합성 모델입니다. 조건부 변이입니다. 오토인코더(VAE)는 사후 인코더, 디코더 및 조건부 사전으로 구성됩니다.

지난달 다운로드 수
1,404

세이프텐서 모델 크기 36.3M 매개변수 텐서 유형 F32 키

추론 예제 TTS(텍스트 음성 변환)

이 모델에는 아직 Inference API(서버리스)에 배포할 수 있는 충분한 활동이 없습니다. 소셜을 늘리십시오. 가시성을 확보하고 나중에 다시 확인하거나, 대신 [추론 엔드포인트\(전용\)](#)에 배포할 수 있습니다.

모델 트리 카카오엔터프라이즈 / VITS-LJS



- Text-to-Speech : 주어진 문장을 음성으로 변환
- 영어 만 지원 (영어 훈련 데이터셋)
- MIT 라이선스

모델 카드 : <https://huggingface.co/kakao-enterprise/vits-ljs>

실습 링크 : <https://colab.research.google.com/drive/1-dNKchuhO5TAbW65tzuAj724hFqmWeG0?usp=sharing>

한국어를 지원하는 TTS 찾기 : 5분

7. 음성 생성 (2) : Suno Bark (suno/bark)



- Text-to-Speech : 주어진 문장을 음성으로 변환
- 한국어 지원 , MIT 라이선스

모델 카드 : <https://huggingface.co/suno/bark>

실습 링크 : https://colab.research.google.com/drive/1bELEs_k4P2SvqicLPsdJinWKb55MJ0hr?usp=sharing

한국 대학생 두 명이 오픈AI 제쳤다... “충격적 AI 순간”

2025.04.28. 오후 7:26

“나리 랩스(Nari Labs)의 ‘Dia(다이아)’는 제가 본 것 중 가장 표현력이 뛰어난 AI 음성을 구현했습니다.”
에단 몰릭(Ethan Mollick) 와튼 스쿨 교수는 22일(현지시각) 소셜미디어를 통해 “충격적인 AI 모멘트
(moment, 순간)였다”며 이같이 밝혔습니다.

실리콘밸리 VC 멘로벤처스의 AI 투자자 디디 다스 역시 “Dia가 텍스트(text, 문자) 스피치(speech, 음성) 변환
을 해결했다”며 나리 랩스를 언급했습니다. TTS(text-to-speech) 변환 AI의 정점을 보여줬다는 극찬이었죠. 이
런 반응, 평가가 나온 이유는 무엇일까요?

왜 중요한가:

저도 데모(demo, 시연) 음성을 들어보고 정말 충격을 받았습니다. 현재까지 가장 앞서 있다는 주요 기업의 TTS
AI 모델 대비 훨씬 자연스럽고 훌륭한 결과물이 생성됐기 때문입니다.

웃음소리, 기침을 포함한 상황의 뉘앙스까지 표현이 되고, 화제 등 응급 현장의 긴박함도 텍스트 기반으로 파악해
AI가 표현해 내는 걸 들으니 소름이 돋을 정도였습니다.

디디 다스는 Dia가 이 분야 선두 주자인 일레븐랩스(ElevenLabs)와 세서미(Sesame)를 확실하게 제쳤다고 평가
했고, 미국 테크 미디어 벤처비트는 오픈AI의 TTS 모델도 위협할 수 있다고 평가했습니다. 깃허브 스타(star, 일
종의 즐겨 찾기) 개수는 사흘 만에 9000개를 돌파했습니다.

더 놀라운 건 이런 성과를 한국의 대학생(서울대, 카이스트) 두 명이 아무런 투자금 없이 만들어 냈다는 점입니
다. 클레망 델랑그(Clément Delangue) 허깅페이스 CEO는 Dia가 허깅페이스 트랜딩(인기 모델) 1위에 오른
사진을 공유하며 “2명의 팀이 마이크로소프트, 엔비디아, 바이트댄스, 구글을 제쳤다”고 치켜세웠습니다.
김도엽 엔지니어에 따르면 나리 랩스는 구글 클라우드(TRC)의 지원으로 구글 TPU를 사용해 모델을 개발할 수 있
었습니다. 결국 3개월만에 모델을 완성했고, 이번 성과를 토대로 일반 사용자용 Dia 앱을 출시한다는 계획입니
다.

현실적인 대화 생성을 위한 Dia: 1.6B 파라미터 TTS 모델 및 오픈소스 공개

Nari Labs에서 개발한 1.6B 파라미터 텍스트-음성 변환(TTS) 모델인 Dia를 소개합니다. Dia는 텍
스트 스크립트에서 직접적으로 매우 현실적인 대화 생성을 목표로 합니다. 기존 TTS 모델의 단조로
운 음성 생성을 넘어서, Dia는 오디오 프롬프트를 통한 감정 및 어조 제어, 그리고 웃음, 기침 등 비언
어적 표현 생성을 가능하게 하는 기능을 포함합니다. 연구 가속화를 위해 사전 훈련된 모델 체크포인
트와 추론 코드를 Hugging Face를 통해 공개적으로 제공합니다(현재 영어만 지원). 또한, 모델의
기능을 시연하고 비교할 수 있는 데모 페이지와 ZeroGPU Space 환경을 제공하여 접근성을 높였
습니다. Dia는 화자 태그([S1], [S2])를 이용한 대화 생성, 비언어적 표현 합성, 오디오 프롬프트를
이용한 음성 복제 등 다양한 기능을 지원하며, 연구 및 개발 커뮤니티의 기여를 장려하기 위해 Apac
he 2.0 라이선스로 배포됩니다. Dia는 고품질 GPU 환경에서 실시간에 가까운 추론 속도를 보이며,
향후 최적화 및 양자화 버전 추가를 계획하고 있습니다.

Self Test & Review : 5분

8. 객체 탐지 : Meta 의 DETR (facebook/detr-resnet-50)



객체 감지 변압기 파이토치 세이프텐서 머리 데트르 비전 추론 엔드포인트

모델 카드 파일 및 버전 지역 사회 23


ResNet-50 백본을 사용한 DETR(End-to-End Object Detection) 모델

Detection Transformer(DETR) 모델은 COCO 2017 객체 감지(118k 주석 이미지)에서 종단간 학습되었습니다. 이 모델은 Carion 등이 작성한 [End-to-End Object Detection with Transformers](#) 논문에서 소개되었으며 [이 저장소](#)에 처음 공개되었습니다.

면책 조항: DETR을 출시한 팀은 이 모델에 대한 모델 카드를 작성하지 않았으므로 이 모델 카드는 Hugging Face 팀에서 작성했습니다.

모델 설명

DETR 모델은 합성곱 백본을 갖춘 인코더-디코더 변환기입니다. 객체 감지를 수행하기 위해 디코더 출력 위에 두 개의 헤드가 추가됩니다. 클래스 레이블을 위한 선형 레이어와 바운딩 박스를 위한 MLP(다중 레이어 퍼셉트론)입니다. 이 모델은 소위 객체 쿼리를 사용하여 이미지에서 객체를 감지합니다. 각 객체 쿼리는 이미지에서 특정 객체를 찾습니다. COCO의 경우 객체 쿼리 수는 100으로 설정됩니다.



- ObjectDetection : 이미지 내의 객체 탐지
- ResNet-50 기반 DETR(End-to-End Object Detection) , Apache 2.0 라이선스

모델 카드 : <https://huggingface.co/facebook/detr-resnet-50>

실습 링크 : <https://colab.research.google.com/drive/1CYebuAHD9t27qiqvchROv2AikquEMBrJ?usp=sharing>

Self Test & Review : 5분

Methodology | [Open access](#) | Published: 12 October 2023



Deep encoder/decoder dual-path neural network for speech separation in noisy reverberation environments

Chunxi Wang, Maoshen Jia  & Xinfeng Zhang

EURASIP Journal on Audio, Speech, and Music Processing **2023**, Article number: 41 (2023) | [Cite this article](#)

Abstract

In recent years, the speaker-independent, single-channel speech separation problem has made significant progress with the development of deep neural networks (DNNs). However, separating the speech of each interested speaker from an environment that includes the speech of other speakers, background noise, and room reverberation remains challenging. In order to solve this problem, a speech separation method for a noisy reverberation environment is proposed. Firstly, the time-domain end-to-end network structure of a deep encoder/decoder dual-path neural network is introduced in this paper for speech separation. Secondly, to make the model not fall into local optimum during training, a loss function stretched optimal scale-invariant signal-to-noise ratio (SOSISNR) was proposed, inspired by the scale-invariant signal-to-noise ratio (SISNR). At the same time, in order to make the training more appropriate to the human auditory system, the joint loss function is extended based on short-time objective intelligibility (STOI). Thirdly, an alignment operation is proposed to reduce the influence of time delay caused by reverberation on separation performance. Combining the above methods, the subjective and objective evaluation metrics show that this study has better separation performance in complex sound field environments compared to the baseline methods.



방법론 | [오픈 액세스](#) | 게시됨: 12 10월 2023



심층 인코더/디코더, 잡음이 많은 잔향 환경에서 음성 분리를 위한 이중 경로 신경망

왕춘시, 마오셴 지아 & 신평 장


[오디오, 음성 및 음악 처리에 관한 EURASIP 저널](#) **2023**, 문서 번호: 41(2023) | [이 기사 인용](#)

음성 분리는 각테일 파티 문제로 널리 알려져 있습니다[1, 2]. 목표는 대상 화자의 음성을 복잡한 음장 환경(다른 화자, 배경 소음 및 잔향)에서 분리하는 것입니다. 인간은 강력한 음성 분리 능력을 가지고 있으며 복잡한 환경에서도 대상 화자의 음성을 인식할 수 있습니다. 그러나 기계 시스템에는 여전히 중요한 과제가 있습니다.

최근 몇 년 동안 화자 독립적인 단일 채널 음성 분리 문제는 심층 신경망(DNN)의 개발과 함께 상당한 진전을 이루었습니다. 그러나 관심 있는 각 화자의 음성을 다른 화자의 음성, 배경 소음 및 실내 잔향을 포함하는 환경에서 분리하는 것은 여전히 어려운 일입니다. 이러한 문제점을 해결하기 위해, 시끄러운 잔향 환경에 대한 음성 분리 방법을 제안한다. 첫째, 본 논문에서는 음성 분리를 위해 딥 인코더/디코더 이중 경로 신경망의 시간 영역 중단 간 네트워크 구조를 소개합니다. 둘째, 훈련 중에 모델이 국소 최적에 빠지지 않도록 하기 위해 스케일 불변 신호 대 잡음비(SISNR)에서 영감을 받은 손실 함수 스트레치 최적 스케일 불변 신호 대 잡음비(SOSISNR)가 제안되었습니다. 동시에 훈련을 인간의 청각 시스템에 더 적합하게 만들기 위해 단시간 객관적 명료도(STOI)를 기반으로 관절 손실 기능을 확장합니다. 셋째, 잔향에 의한 시간 지연이 분리 성능에 미치는 영향을 줄이기 위해 정렬 동작을 제안한다. 위의 방법을 결합하면 주관적 및 객관적 평가 지표는 이 연구가 기본 방법에 비해 복잡한 음장 환경에서 더 나은 분리 성능을 가지고 있음을 보여줍니다.



음성 분리 : 지정된 사람의 목소리 분리



출처 : <https://github.com/maum-ai/voicefilter>

음성 분할 샘플 : <https://swpark.me/voicefilter/>

9. 화자 구분/분할 : pyannote/speaker-diarization-3.1, speechbrain/sepformer-wham



이 오픈 소스 모델을 프로덕션에서 사용하고 계신가요?
더 빠르고 더 나은 옵션을 위해 [pyannoteAI](#)로 전환하는 것을 고려하십시오.

스피커 디아리제이션 3.1

이 파이프라인은 문제가 있는 사용을 제거한다는 점을 제외하고는 [pyannote/speaker-diarization-3.0](#)과 동일합니다.

이제 스피커 세분화와 임베딩이 모두 순수 PyTorch에서 실행됩니다. 이렇게 하면 배포가 쉬워지고 추론 속도가 빨라질 수 있습니다.

pyannote.audio 버전 3.1 이상이 필요합니다.`onnxruntime`

16kHz로 샘플링된 모노 오디오를 인제스트하고 화자 분할을 [Annotation](#) 인스턴스로 출력합니다.

- 스테레오 또는 다중 채널 오디오 파일은 채널 평균을 계산하여 자동으로 모노로 다운믹스됩니다.
- 다른 속도로 샘플링된 오디오 파일은 로딩 시 자동으로 16kHz로 리샘플링됩니다.

SepFormer는 WHAM에서 훈련되었습니다!

이 저장소는 SpeechBrain으로 구현되고 [WHAM!](#) 데이터 세트는 기본적으로 환경 노이즈가 있는 WSJ0-Mix 데이터 세트 버전인 [SepFormer](#) 모델을 사용하여 오디오 소스 분리를 수행하는 데 필요한 모든 도구를 제공합니다. 더 나은 경험을 위해 [SpeechBrain](#)에 대해 자세히 알아보는 것이 좋습니다. 모델 성능은 WHAM의 테스트 세트에서 16.3dB SI-SNRi입니다! 데이터 세트.

석방	테스트 세트 SI-SNRi	SDRi 테스트 세트
09-03-21	16.3 데시벨	16.7 데시벨

SpeechBrain 설치

먼저 다음 명령을 사용하여 SpeechBrain을 설치하십시오.

```
pip install speechbrain
```

- 음성 파일(.wav) 에서 화자 별로 발성 부분 탐지(pyannote/speaker-diarization-3.1), MIT 라이선스
- 음성 파일에서 화자 별로 음성 분리 (speechbrain/sepformer-wham), Apache 2.0 라이선스

모델 카드 : <https://huggingface.co/pyannote/speaker-diarization-3.1>, <https://huggingface.co/speechbrain/sepformer-wham>

9. 화자 구분/분할 : deepseek-ai/DeepSeek-V3, openai/whisper-large-v3-turbo



조리스코스/ConvTasNet_Libri2Mix_sepclean_16k

오디오-오디오 소행성 파이토치 리브리2믹스 sep_clean 오디오

모델 카드 파일 및 버전 커뮤니티

소행성 모델 JorisCos/ConvTasNet_Libri2Mix_sepclean_16k

묘사:

이 모델은 Joris Cosentino가 Asteroid의 librimix 레시피를 사용하여 훈련했습니다. Libri2Mix 데이터 세트의 작업에 대해 훈련되었습니다. sep_clean

Whisper는 자동 음성 인식(ASR) 및 음성 번역을 위한 최첨단 모델로, Alec Radford의 Robust Speech Recognition via Large-Scale Weak Supervision 논문에서 제안되었습니다. OpenAI. >5M 시간의 레이블이 지정된 데이터로 훈련된 Whisper는 많은 사람들에게 일반화할 수 있는 강력한 능력을 보여줍니다. 제로샷(zero-shot) 설정의 데이터 세트 및 도메인.

Whisper large-v3-turbo는 정리된 Whisper large-v3의 미세 조정 버전입니다. 즉, 디코딩 계층의 수가 32개에서 4개로 줄어든 것을 제외하고는 정확히 동일한 모델입니다. 결과적으로, 모델은 훨씬 더 빠르지만 약간의 품질 저하가 발생합니다. 이에 대한 자세한 내용은 이 GitHub 토론에서 확인할 수 있습니다.

면책 조항: 이 모델 카드의 콘텐츠는 부분적으로 Hugging Face 팀에 의해 작성되었으며 일부는 복사되었으며 원래 모델 카드에서 붙여 넣습니다.

- 음성 파일에서 화자 별로 음성 분리 (JorisCos/ConvTasNet_Libri2Mix_sepclean_16k), CC 라이선스
- 음성 파일의 내용을 문자로 변환 (openai/whisper-large-v3-turbo), MIT 라이선스


모델 카드 : https://huggingface.co/JorisCos/ConvTasNet_Libri2Mix_sepclean_16k ,
<https://huggingface.co/openai/whisper-large-v3-turbo>

실습 링크 : https://colab.research.google.com/drive/1L4y8TBcv_QQI9algyCcKEhgyH5_zHUmW?usp=sharing

[openai](#)/whisper-large-v3-turbo 사용한
STT 부분구현하기 : 10분
➔ 솔루션 포함되어 있음


Self Test & Review : 5분

Transformer 기반 모델




- 트랜스포머 기반 모델 : ChatGPT, LLaMA . 자기지도 학습을 수행함.
- 일반화가 뛰어나며 파인튜닝도 가능함 (예: BERT).
- 대부분의 LLM과 FM(Foundation Model)은 트랜스포머 기반.
- NLP 이외에도 많이 활용하는 트랜스포머 모델 : **ViT**, **SAM**
- 트랜스포머의 핵심은 **자기-어텐션(self-attention)** 개념임.


SAM (Segment Anything Model) : 이미지 분할의 FM



(a) **Task:** promptable segmentation



(b) **Model:** Segment Anything Model (SAM)



(c) **Data:** data engine (top) & dataset (bottom)

Figure 1: We aim to build a foundation model for segmentation by introducing three interconnected components: a promptable segmentation *task*, a segmentation *model* (SAM) that powers data annotation and enables zero-shot transfer to a range of tasks via prompt engineering, and a *data* engine for collecting SA-1B, our dataset of over 1 billion masks.

1. Zero-shot Generalization을 가능하게 하는 Task는 무엇인가? → promptable segmentation
2. 대응되는 모델 아키텍처는 무엇인가? → prompt encoder(MAE, CLIP, Dense Prompt) Mask Decoder, Mask와 IoU
3. 어떤 데이터로 훈련시키면 될까? → Base Model 을 위한 대량 데이터셋 구성

SAM (Segment Anything Model) : 이미지 분할의 FM





Figure 4: Segment Anything Model (SAM) overview. A heavyweight image encoder outputs an image embedding that can then be efficiently queried by a variety of input prompts to produce object masks at amortized real-time speed. For ambiguous prompts corresponding to more than one object, SAM can output multiple valid masks and associated confidence scores.


- SAM은 이미지 임베딩을 생성하고 다양한 입력 프롬프트로 객체 마스크를 출력
- 실시간 속도로 동작하며, 애매한 프롬프트에 대해 다중 마스크와 신뢰도를 제공

10. Open Vocabulary Object Detection, SAM

Image-level contrastive pre-training



Transfer to open-vocabulary detection



모델 카드 1 : <https://huggingface.co/google/owlvit-base-patch32>

모델 카드 2 : <https://huggingface.co/CIDAS/clipseg-rd64-refined>

실습 링크 : <https://colab.research.google.com/drive/1XFQGXUXsekzM88B0p6tAoSU6yykKZPlj?usp=sharing>

Self Test & Review : 5분

추론 능력 : CoT → System2 강요



차근차근 주어진 질문에 답하십시오.
다음 형식을 사용하십시오.

질문 : 입력된 질문

생각 1차 : 질문에 대한 다양한 해결법 생각.

수행 1차 : 해결법을 하나씩 수행

관찰 1차 : 수행된 결과와 목표 비교 관찰

결과 1차 : 앞의 시도에서 나온 결과

생각 2차 : 1차보다 더 단순한 방법 고려

수행 2차 : 해결법을 하나씩 수행

관찰 2차 : 수행된 결과와 목표 비교 관찰

최종 답변 : 입력된 요청에 대한 최종 결과물

시작 ~~~

질문 : 100원 200원 400원 500원 동전이 무한히 있다.
최소 동전 수로 800원 거스름돈을 주는 방법은?

시작 ~~~

질문: 100원, 200원, 400원, 500원 동전이 무한히 있다. 최소 동전 수로 800원 거스름돈을 주는 방법은?

생각 2차:

1차 결과가 이미 최적의 방법처럼 보이지만, 더 단순한 동전 조합이 가능한지 검토.
다른 조합 (예: 400원을 활용)으로 동전 수를 줄일 수 있는지 확인.

수행 2차:

1. 400원 동전을 두 개 사용 $\rightarrow 800 - (400 \times 2) = 0$ 원.

총 사용 동전: 400원 2개 = 2개.

관찰 2차:

1차보다 더 적은 동전 수로 800원을 거슬러 줄 수 있었음.
최소 동전 수는 2개임.

결과 2차:

동전 2개 사용: 400원 2개.

최종 답변:

최소 동전 수로 800원을 거슬러 주는 방법은 400원 동전 2개를 사용하는 것입니다.

추론 능력 : o1 Reasoning → System 2 습득



100원 200원 400원 500원 동전이 무한히 있다.
최소 동전 수로 800원 거스름돈을 주는 방법은?

100원 200원 400원 500원 동전이 무한히 있다.
최소 동전 수로 800원 거스름돈을 주는 방법은?

+

🌐 검색

💡 이성

↑

Reasoning : 추론

5초 동안 이성 처리 완료 ✓

여기서 문제는 최소 코인 수로 800원 거스름돈을 주는 방법입니다. 100원, 200원, 400원, 500원의 동전이 있습니다.

500원 동전을 사용하면 300원이 남고, 200원과 100원 동전으로 총 3개의 동전(500, 200, 100)을 만들 수 있습니다. 하지만 잠깐만요, 400원 동전 두 개를 사용하면 동전 2개로 정확히 800원을 얻을 수 있습니다. 그것이 최소 코인 수입니다!

확인해보니 400원 동전 두 개를 사용하면 가장 적은 동전으로 800원 동전이 나옵니다(총 2동). 500원 동전을 시도했다면 나머지 300원에는 200원과 100원 동전이 필요하며, 이는 두 개의 400원 동전에서 2동전보다 많은 3개의 동전을 합산합니다. 따라서 최종 답변은 두 개의 400원 동전을 사용하는 것이 가장 좋고 코인 사용을 최소화합니다.

800원을 최소 동전 수로 거슬러 주기 위해서는 400원 동전을 2개 사용하면 됩니다.

풀이:

- 사용 가능한 동전: 100원, 200원, 400원, 500원
- 400원 동전 2개를 사용하면 $400 + 400 = 800$ 원이 되어, 동전 수는 2개로 최소가 됩니다.

따라서, **400원 동전 2개**가 최소 동전 수의 해법입니다.

number of coins. We have

th 200원 and 100원 coins,

es us exactly 800원 with only

n the fewest coins — just 2

ires 200원 and 100원 coins,

400원 coins. So, the final

s coin usage.

면 됩니다.

2개로 최소가 됩니다.

中 AI 벤처의 추론 모델..."오픈AI o1 성능 능가"

기사입력 : 2025년01월22일 09:37 | 최종수정 : 2025년01월22일 09:37

[베이징=뉴스핌] 조용성 특파원 = 중국의 AI(인공지능) 스타트업인 딥시크(DeepSeek, 중국명 선두추쉬, 深度求索)가 오픈AI의 o1에 버금가는 추론형 AI 모델을 발표했다.

딥시크가 21일 추론형 AI 모델인 딥시크-R1을 발표했다고 중국 매체 차이렌서(财联社)가 22일 전했다.

딥시크는 R1 모델이 주요 AI 벤치마크인 AIME와 MATH-500 지표에서 오픈AI의 추론형 AI 모델인 o1보다 높은 성능을 보였다고 소개했다. 또한 딥시크는 R1의 이용 가격이 o1보다 90% 이상 저렴하다고 덧붙였다.

대표적인 대화형 AI 대형 모델(LLM)인 챗GPT가 일반인들과의 대화를 목적으로 만들어졌다면, 추론형 AI 모델인 o1은 연구자나 전문직 종사자를 대상으로 수학, 과학, 코딩 등 복잡한 문제 해결 및 고급 추론 작업을 위해 만들어졌다.

딥시크의 R1은 오픈AI의 o1과 비슷한 대형 모델이다. 6710억 개의 매개변수를 포함하고 있으며, 복잡한 문제 해결에 필요한 방대한 데이터를 처리할 수 있다.

이에 앞서 딥시크는 지난해 12월 말 대화형 AI 대형 모델인 V3를 출시해 업계를 놀라게 했다. 출시 당시 딥시크는 "V3는 코딩 벤치마크(성능 평가)에서 오픈AI의 'GPT-4o', 메타의 '라마 3.1'을 넘어섰다"고 발표했다.

출처 : <https://www.newspim.com/news/view/20250122000227>

질문 : 100원 200원 400원 500원 동전이 무한히 있다. 최소 동전 수로 800원 거스름돈을 주는 방법은?

또 아니면 400 + 400 = 800, 즉 2개의 동전입니다.

따라서 네, 가장 효율적인 방법인 듯합니다.

의

또 다른 생각: 200원 동전 3개와 100원 동전 2개를 사용하면 어떨까요?

그러면 600 + 200 = 800개가 되지만, 5개로 2개보다 나쁩니다.

잠깐

따라서 400원 동전 2개를 사용하는 것이 확실히 더 나은 선택입니다.

아니

총 따라서 결론은 400원 동전 2개를 사용하는 것이 800원을 만드는 데 필요한 최소 동전 수라는 것입니다.

아니 </think>

수

400 사용 가능한 액면가(100, 200, 400, 500)를 사용하여 800원을 만드는 데 필요한 최소 동전 수는 2개입니다. 이것은 400원 동전 2개를 사용하여 달성됩니다.

다른

요? 답: 400원 동전 2개를 사용하여 800원을 만들면 최소 동전 수(2)가 됩니다.



Shifting focus from next-word prediction to reasoning models

	Chat Models 	Reasoning Models 
Scaling paradigm	<u>Next-token-prediction</u>	<u>RL on CoT</u>
Reasoning type	<u>System 1 (fast, intuitive)</u>	<u>System 2 (slow, effort-ful)</u>
Tell the model	How ("think step by step")	What ("here is the output i want")
Interaction	<u>Chat / "interactive"</u>	<u>Research or planning / "in the background"</u>

taken from Langchain notion notes


1. Ollama란

'Ollama'는 대규모 언어 모델을 로컬 컴퓨터에서 설정하고 실행할 수 있게 해주는 고급 AI 도구입니다. 이는 AI 기술의 민주화에 있어 중요한 발전으로, 사용자가 Llama 3나 gemma와 같은 언어 모델을 직접 활용할 수 있는 가능성을 제공합니다. 개발자, 연구자, 데이터 과학자에게 필수적인 다양한 자연어 처리(NLP) 애플리케이션에서 중요한 역할을 하는 'Ollama'는 가볍고 확장 가능한 프레임워크로, 복잡한 클라우드 기반 솔루션에 의존하지 않고도 모델의 기능을 로컬에서 직접 활용할 수 있도록 합니다. 이 도구는 언어 모델을 생성, 실행, 관리할 수 있는 간단한 API와 사전 구축된 모델 라이브러리를 제공하여 애플리케이션에 쉽게 통합할 수 있습니다. Ollama를 사용하면 Modelfile을 통해 모델 가중치, 구성, 데이터를 패키징하고 GPU 사용 등의 설정을 최적화할 수 있습니다.

2. Ollama 장점

- **로컬 실행:** 대규모 언어 모델의 로컬 실행 가능, 사용자에게 빠르고 효율적인 AI 처리 기능 제공
- **다양한 모델 지원:** (Meta)Llama3 , (Microsoft)Phi-3 , (Google)Gemma , mixtral, mistral ...
- **모델 커스터마이징:** 자신만의 모델을 자유롭게 커스터마이징하고 제작 가능
- **사용자 친화적인 인터페이스:** 도구의 디자인은 사용 편의성을 보장하여 빠르고 번거롭지 않은 설정 가능
- **다양한 시스템 환경 호환성:** macOS, Windows, Linux 지원

DeepSeek-R1-Distill-Qwen-1.5B테스트



DeepSeek-R1-Distill-Qwen-1.5B

```
ollama run deepseek-r1:1.5b
```

DeepSeek-R1-Distill-Qwen-7B

```
ollama run deepseek-r1:7b
```

DeepSeek-R1-Distill-Llama-8B

```
ollama run deepseek-r1:8b
```

DeepSeek-R1-Distill-Qwen-14B

```
ollama run deepseek-r1:14b
```

DeepSeek-R1-Distill-Qwen-32B

```
ollama run deepseek-r1:32b
```

DeepSeek-R1-Distill-Llama-70B

```
ollama run deepseek-r1:70b
```

Hugging Face 모델 카드 : <https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Qwen-1.5B>

프로그램 작성 에이전트 (DeepSeek_R1-Distill-Qwen-7B, Ollama)

Ollama 모델 리스트 : <https://ollama.com/library/deepseek-r1>


실습 링크 : https://colab.research.google.com/drive/1xmMfukXllliqaXWtebLjMh_la93xmzqi?usp=sharing

1. Groq 소개

Groq은 2016년 설립된 AI 솔루션 기업으로, AI 기술의 접근성 향상을 목표로 합니다. Google TPU의 발명가 Jonathan Ross에 의해 창립된 이 회사는 고성능 LPU(Language Processing Unit) 인퍼런스 엔진을 개발하여 AI 언어 처리의 속도와 효율성을 혁신적으로 향상시켰습니다.

Groq 설립 배경 및 비전

- 설립 연도 및 배경:** Groq는 2016년에 설립되었으며, Google Tensor Processing Unit (TPU)의 발명가 Jonathan Ross에 의해 창립되었습니다. AI 접근성을 향상시키고 모든 이가 AI의 혜택을 누릴 수 있는 세상을 만들겠다는 비전 아래 탄생했습니다.
- 회사 위치 및 글로벌 확장:** 본사는 캘리포니아 주 마운틴뷰에 위치하고 있으며, 샌디에이고, 오스틴, 뉴욕 시티 등 미국 내 여러 도시와 토론토, 리버티 레이크, 런던 등 세계 여러 지역에 직원을 두고 있는 글로벌 기업입니다.
- 비전과 목표:** Groq의 궁극적인 목표는 AI 기술을 통해 인간의 에이전시를 유지하면서 AI 경제를 구축하는 것입니다. 이를 위해, 가장 빠른 AI 언어 처리 기술을 제공하여 실시간 AI 애플리케이션을 가능하게 함으로써, AI 기술의 접근성과 활용도를 극대화하려고 합니다.



Billing

Free

Get started with our APIs

\$0

Current Plan

✓ Low Rate Limits

✓ Community Support

Developer

Scale up and pay as you go

Pay per Token

Coming Soon

✓ High Rate Limits

✓ Priority Support

Business

Custom solutions for large-scale needs.

Contact Us

✓ Custom Rate Limits

✓ Finetuned Models

✓ Custom SLAs

✓ Dedicated Support

Limits				
llama-3.1-70b-versatile	30	14,400	6,000	200,000
llama-3.1-8b-instant	30	14,400	20,000	500,000
llama-3.2-11b-text-preview	30	7,000	7,000	500,000
llama-3.2-11b-vision-preview	30	7,000	7,000	500,000
llama-3.2-1b-preview	30	7,000	7,000	500,000
llama-3.2-3b-preview	30	7,000	7,000	500,000
llama-3.2-90b-text-preview	30	7,000	7,000	500,000
llama-3.2-90b-vision-preview	15	3,500	7,000	250,000
llama-3.3-70b-specdec	30	1,000	6,000	100,000


오픈소스 LLaMA 4 테스트 (Groq : <https://groq.com/pricing>)



groq						Start Building	
		Products ▾	Enterprise ▾	Developers ▾	Resources ▾	Pricing	About ▾
Kimi K2 1T 128k	200			\$1.00 (1M / \$1)*		\$3.00 (333,333 / \$1)*	Try Now Model Card
Llama 4 Scout (17Bx16E) 128k	594			\$0.11 (9.09M / \$1)*		\$0.34 (2.94M / \$1)*	Try Now Model Card
Llama 4 Maverick (17Bx128E) 128k	562			\$0.20 (5M / \$1)*		\$0.60 (1.6M / \$1)*	Try Now Model Card
Llama Guard 4 12B 128k	325			\$0.20 (5M / \$1)*		\$0.20 (5M / \$1)*	Try Now Model Card
DeepSeek R1 Distill Llama 70B 128k	400			\$0.75 (1.33M / \$1)*		\$0.99 (1.01M / \$1)*	Try Now Model Card
Qwen3 32B 131k	662			\$0.29 (3.44M / \$1)*		\$0.59 (1.69M / \$1)*	Try Now Model Card

LLaMA 4 Image Grounding

이미지에서 길이를 측정하는 데 사용할 수 있는 도구는 무엇인가요?
인식된 모든 항목에 경계 상자를 제공하세요.



링크 : https://colab.research.google.com/drive/1toLwZeGlomzmOPoM1tAZXTFiPo5E_ukM?usp=sharing

요약

딥시크, API 매출 급증으로 첫 흑자..."매출보다 연구에 집중"

🕒 입력 2025.03.15 22:34

딥시크가 API 서비스를 통해 상당한 매출을 올린 것으로 알려졌다. 이미 외부 투자를 받지 않겠다고 밝힌 데 대해 힘이 실림에 따라, 당분간은 새로운 모델 출시에 전념할 것으로 결정한 것으로 전해졌다.

파이낸셜 타임스는 14일(현지시간) 소식통을 인용, 딥시크가 최근 상당한 월 매출을 거뒀으며 이를 통해 처음으로 운영 비용을 충당하는 데 성공했다고 보도했다.

이에 따르면 중국의 의료와 금융 분야의 기업들이 앞다퉈 '딥시크-R1'과 '딥시크-V3'의 API를 도입했으며, 수요가 너무 많아 비연구 목적으로 할당한 컴퓨팅 리소스가 부족해 일시적으로 서비스를 중단하는 사태까지 벌어졌다.

매출이 어느 정도인지는 구체적으로 알려지지 않았다. 이와 관련, 딥시크는 이달 초 트래픽을 기반으로 추정한 '이론상' 하루 매출이 56만2027달러(약 8억1686만원)에 달하며, 이익률은 545%에 달한다고 발표했다. 물론, 실제 수익은 훨씬 작다고 설명했다.

또 이 회사는 직원이 160여명에 불과하기 때문에, 직원 2000명이 넘는 오픈AI나 500여명에 달하는 앤트로픽에 비해 인건비가 훨씬 적게 들어간다.

량원평 창립자도 매출을 확대하는 전략 대신, 연구 개발에 집중하는 쪽을 선택한 것으로 알려졌다. 이 회사는 5월 출시 예정인 추론 모델 '딥시크-R2'와 비추론 모델 '딥시크-V4' 출시를 앞당기기 위해 서두르고 있다.

실제로 이 회사는 설립 이후 수익보다는 연구에만 집중했다. R1 모델이 출시되기 전에는 소비자용 챗봇도 출시하지 않았을 정도다.

소식통은 현재 용량을 초과하는 수요에 대비해 주로 다른 공급 업체를 활용해 컴퓨팅 인프라를 확장할 것이라고도 전했다.

특히 딥시크는 중국 정부의 지원을 받은 것으로 알려졌다. 정부가 지원하는 데이터센터를 통해 컴퓨팅 제약을 완화했다는 것이다.

같은 맥락으로 외부 투자는 현재 거부하고 있다. 중국의 빅테크와 벤처 캐피탈, 국가 지원 기금 등으로부터 빚발치는 면담 요청을 받았지만, 량 창립자를 만나려고 시도하는 것조차 힘들었다는 말이 나왔다.

중국의 한 기술 펀드 투자자는 "우리는 정부 최고위층과 연결해 어렵게 그들을 만났으나, '죄송하지만, 우리는 돈이 필요 없다'라는 말만 들었다"라고 말했다.

하지만, 컴퓨팅 인프라 확장을 위해 언젠가는 정부의 투자를 받아들여야 할 수도 있을 것이라는 분석이다. 딥시크는 매출 외에도 모회사인 헤지펀드 하이플라이어의 강력한 지원을 받고 있어 자금에는 문제가 없지만, 미국의 기술 제재로 인해 정상적인 방법으로 컴퓨팅 인프라를 확장하기는 어렵기 때문이다.

물론 이 경우에는 미국 정부의 블랙 리스트에 오를 가능성이 높다. 이미 오픈AI와 앤트로픽 등은 백악관에 딥시크 등 중국 모델의 사용을 금지하는 것은 물론, 미국 모델 접근도 막아야 한다고 주장하고 있다.

OpenAI도 오픈 소스로 전환할까?



오픈AI(OpenAI) CEO 샘 알트만(Sam Altman)은 '역사의 잘못된 편에 섰다'고 말한다.

OpenAI는 더 개방적일 수 있습니다. 그리고 그렇게 생각하는 것은 오픈 소스 옹호자만이 아닙니다. 최근 발언에 따르면 CEO도 그렇게 생각하고 있음을 알 수 있습니다.

작성자 : Matt Jancer 2025년 2월 3일 오후 8:25

중국 생성형 AI DeepSeek가 ChatGPT를 제치고 Apple App Store에서 가장 많이 다운로드된 무료 앱으로 등극한 지 불과 일주일 만에 보다 협력적인 OpenAI가 연구를 자유롭게 공유하는 것을 볼 수 있을까요?

그리고 며칠 후 그들은 자체 Janus-Pro 이미지 생성기를 사용하여 OpenAI의 DALL-E 이미지 생성기에 타격을 가했습니다. 도전자를 칭찬하고, 더 오픈 소스 접근 방식을 예고하고, 음, 그것에 대한 다른 질문은 무시하는 일주일이었습니다.

"저는 개인적으로 우리가 역사의 잘못된 편에 서 있다고 생각하며 다른 오픈 소스 전략을 찾아야 합니다. OpenAI의 모든 사람이 이러한 견해를 공유하는 것은 아니며 현재 우리의 최우선 순위도 아닙니다." OpenAI의 CEO인 Sam Altman은 지난 금요일 Reddit의 "무엇이든 물어보세요" 스레드에서 말했습니다.

그는 "모델 가중치를 공개하고 연구를 발표하는 것을 고려하시겠습니까?"라는 질문에 답하고 있었습니다.



OpenAI는 정보와 연구의 자유로운 흐름에 다소 폐쇄되어 있으며, 이에 대한 응답은 Altman이 그 접근 방식에 대해 다시 생각하고 있음을 암시합니다.

아마도 언젠가는 OpenAI가 실제로 운영의 커튼을 아주 조금만 뒤로 젖힌다면 오픈 소스에 대한 진정한 생각을 공개할 것입니다. 그러나 그때까지는 그들이 왜 덜 비밀로 하고 싶어하는지에 대한 추론은 재미있게도 비밀로 남아 있습니다.

AI 모델 및 도구: OpenAI

이번 주에 [OpenAI](#)는 몇 년 만에 처음으로 오픈 소스

ChatGPT의 창시자는 이 전략에 대한 피드백을 요청
데 도움이 되도록 개발자, 연구원 및 대중의 의견을

OpenAI에 따르면 오픈 소스 모델은 "몇 달 안에" 제

오픈AI는 2019년 GPT-2 LLM을 위해 오픈 소스 모

OpenAI는 Microsoft가 인공 지능(AI) 모델 개발을
자한 후 모델을 독점적으로 만들기로 결정했습니다.

마이크로소프트는 현재까지 오픈AI에 130억 달러
스 고객에게만 독점적으로 제공된다. OpenAI는 또
2025년 1월에 [종료되었습니다](#).

지난 6년 동안 OpenAI는 GPT-3부터 최신 GPT-4.5
다.

[OpenAI의 결정은 Meta의 Llama, Mistral의 LLM](#)

지난 3월 메타 CEO 마크 저커버그(Mark Zuckerbe
출시되었습니다.

메타는 [블로그 게시물](#)에서 "오픈 소스 AI는 모든 사

이 소셜 미디어 대기업은 Spotify가 Llama를 사용하
천을 제공한 회사 중 하나라고 말했습니다.



[Try gpt-oss](#) · [Guides](#) · [Model card](#) · [OpenAI blog](#)

Welcome to the gpt-oss series, [OpenAI's open-weight models](#) designed for powerful reasoning, agentic tasks, and versatile developer use cases.

We're releasing two flavors of these open models:

- gpt-oss-120b — for production, general purpose, high reasoning use cases that fit into a single 80GB GPU (like NVIDIA H100 or AMD MI300X) (117B parameters with 5.1B active parameters)
- gpt-oss-20b — for lower latency, and local or specialized use cases (21B parameters with 3.6B active parameters)

중국 인공지능 스타트업 딥시크(DeepSeek)는 급증하는 수요 때문에 API

회사는 모두 고객이 사용할 수 있도록 DeepSeek의 R1 추론 모델을 플랫

인 샘 알트만(Sam Altman)은 지난 1월 말 레딧(Reddit) 사용자들과의 커
찾아내야 할 것"이라고 말했다고 한다.


오픈 소스 모델이 주목을 받으
번째 오픈 소스 언어 모델을

소스 LLM은 GPT-2였습니
으며 o1 및 o3 추론 모델도

리바바(Alibaba), 바이두
ent)는 모두 딥시크
힘입어 지난 3월 새로운 AI

모델을 공개했다.

- AI 활용 문턱을 낮추는 오픈 소스 모델
- 허깅페이스 : 인공지능 모델을 위한 깃허브
 - ✓ Models, Datasets, Spaces
 - ✓ Task에 적합한 모델 선택
 - ✓ 필요시 Fine Tuning을 위한 데이터셋 구성
 - ✓ MLOps 를 위한 Deployments 고려



- 오픈소스의 집단 지성과 협력
- 투명성과 보안 강화
- 다양한 분야로의 확장
- 기술 민주화 실현
- 기여 동기과 성장 기회
- 커뮤니티의 협력과 멘토링
- 혁신과 가능성의 확대

감사합니다.